POLITECHNIKA
LUBELSKA
WYDZIAŁ ELEKTROTECHNIKI
I INFORMATYKI

# Praca dyplomowa magisterska

na kierunku Informatyka
na bloku dyplomowania Data Science

## Rozpoznawanie cech mówców na podstawie danych akustycznych z użyciem wybranych modeli neuronowych

## Recognition of selected speaker features based on acoustic data using selected neural models

Piotr Bednarski
097566

Tomasz Brzozowski
097572

Promotor dr Paweł Powroźnik

Lublin 2026

## Streszczenie

W pracy przedstawiono analizę porównawczą różnych metod uczenia głębokiego stosowanych do rozpoznawania wybranych cech mówcy na podstawie danych akustycznych. Analizowanymi cechami były płeć, wiek oraz akcent języka angielskiego. Celem badań było porównanie skuteczności różnych architektur sieci neuronowych w rozpoznawaniu tych cech w warunkach niezrównoważenia klas w zbiorze danych. W badaniach uwzględniono dwa sposoby wstępnego przetwarzania i reprezentacji sygnału audio. Wszystkie modele zostały zaprojektowane na potrzeby przeprowadzonych badań i wytrenowane od podstaw, bez wykorzystania modeli wstępnie wytrenowanych oraz uczenia transferowego. Skuteczność modeli oceniono z wykorzystaniem różnych miar klasyfikacji, a uzyskane wyniki przeanalizowano pod kątem zastosowanej architektury sieci neuronowej, rozpoznawanej cechy mówcy oraz sposobu przetwarzania sygnału.



**Słowa kluczowe:** uczenie głębokie, sieci neuronowe, Mel, MFCC, ekstrakcja cech akustycznych, rozpoznawanie cech mówcy



## Abstract

This thesis presents a comparative analysis of various deep learning methods used to recognise selected speaker features based on acoustic data. The characteristics analysed were gender, age, and English accent. The aim of the study was to compare the effectiveness of different neural network architectures in recognising these features under conditions of class imbalance in the dataset. Two methods of audio signal preprocessing and representation were considered. All models were designed specifically for the conducted study and trained from scratch, without the use of pre-trained models or transfer learning. The performance of the models was evaluated using various classification metrics, and the obtained results were analysed in terms of the neural network architecture used, the speaker feature being recognised, and the signal processing method.



**Keywords:** deep learning, neural networks, Mel, MFCC, audio features extraction, speaker features recognition

# Spis treści

Streszczenie ... 3
Abstract ... 3
1. Wstęp ... 5
2. Cel i zakres pracy ... 6
2.1. Cel pracy ... 6
2.2. Zakres pracy ... 6
2.3. Podział pracy ... 6
3. Przegląd dotychczasowych badań i rozpoznanie luki badawczej ... 8
3.1. Przegląd literatury ... 8
3.2. Identyfikacja luki badawczej ... 10
4. Podstawy teoretyczne ... 11
4.1. Reprezentacje sygnału audio ... 11
4.2. Sieci neuronowe stosowane do analizy mowy ... 13
5. Metoda badań ... 16
5.1. Środowisko badawcze ... 16
5.2. Wykorzystany zbiór danych ... 18
5.3. Przygotowanie zbioru danych ... 19
5.4. Ekstrakcja cech i przygotowanie danych wejściowych ... 22
5.5. Implementacja modeli ... 26
5.6. Metody oceny modeli ... 45
6. Przeprowadzone badania i wyniki ... 49
6.1. Organizacja badań i przeprowadzenie eksperymentów ... 49
6.2. Wyniki rozpoznawania płci mówcy ... 49
6.3. Wyniki rozpoznawania wieku mówcy ... 54
6.4. Wyniki rozpoznawania akcentu mówcy ... 60
6.5. Porównanie uzyskanych wyników ... 69
7. Wnioski ... 72
Wykaz literatury ... 74
Zasoby internetowe ... 76

# 1. Wstęp

W pierwszej połowie XXI wieku nastąpił dynamiczny rozwój badań i zastosowań związanych ze sztuczną inteligencją, a w szczególności z uczeniem maszynowym. Obecnie różne rodzaje i architektury sztucznych sieci neuronowych są szeroko wykorzystywane w wielu dziedzinach i zastosowaniach. Jednym z obszarów ich wykorzystania jest analiza mowy, obejmująca szeroki zakres zadań związanych z przetwarzaniem i interpretacją sygnału mowy. Należą do nich między innymi systemy bezpieczeństwa, klasyfikacja nagrań dźwiękowych, rozpoznawanie mówcy oraz identyfikacja osoby na podstawie jej głosu [16].

Jednym z wyzwań związanych z analizą nagrań mowy jest rozpoznawanie cech mówcy. Do takich cech można zaliczyć między innymi płeć, wiek, język, akcent oraz emocje przekazywane za pomocą głosu. W niniejszej pracy obszar ten określono jako analizę cech mówcy. Algorytmy uczenia głębokiego stanowią obiecujące podejście do realizacji zadań związanych z rozpoznawaniem tego rodzaju cech [16]. Surowy sygnał mowy nie zawsze jest bezpośrednio wykorzystywany jako dane wejściowe dla modeli. Przed rozpoczęciem klasyfikacji może zostać przekształcony do postaci reprezentacji cech akustycznych. Zmiana reprezentacji danych ma na celu skondensowanie informacji statystycznie istotnych z punktu widzenia konkretnego problemu klasyfikacji [4]. Wśród stosowanych reprezentacji znajdują się między innymi współczynniki cepstralne w skali mel (MFCC ang. Mel-frequency cepstral coefficients) [4] oraz spektrogramy w skali logarytmicznej Mel, zwane czasem Mel-spektrogramami [2]. Wybór sposobu reprezentacji może wpływać na ilość i rodzaj informacji dostępnych dla modelu, a tym samym na skuteczność klasyfikacji.

W literaturze, m.in. [4], [5] przedstawiono wiele badań dotyczących rozpoznawania poszczególnych cech mówcy z wykorzystaniem metod uczenia maszynowego i uczenia głębokiego. W pracach tych, np. w [6], stosowane są różne reprezentacje akustyczne oraz różne architektury modeli. Wyniki poszczególnych badań nie pozwalają jednak jednoznacznie określić, która reprezentacja zapewnia najlepszą skuteczność niezależnie od rodzaju zastosowanego modelu i rozpoznawanej cechy mówcy. Zasadne jest zatem przeprowadzenie eksperymentu, w którym różne reprezentacje akustyczne zostaną porównane z wykorzystaniem tych samych architektur modeli w kilku zadaniach klasyfikacyjnych.

# 2. Cel i zakres pracy

## 2.1. Cel pracy

Celem pracy jest opracowanie i ocena skuteczności modeli uczenia maszynowego służących do rozpoznawania wybranych cech mówcy na podstawie analizy sygnału mowy. W ramach badań przeprowadzono ekstrakcję cech z nagrań dźwiękowych oraz przygotowano różne reprezentacje sygnału wykorzystywane jako dane wejściowe dla modeli klasyfikacyjnych. Następnie porównano skuteczność różnych architektur sieci neuronowych w rozpoznawaniu wybranych cech mówcy. Badania przeprowadzono dla trzech zadań klasyfikacyjnych związanych z rozpoznawaniem płci, wieku oraz akcentu języka angielskiego. Ostatecznym celem jest określenie, w jakim stopniu wybór reprezentacji akustycznej i architektury modelu wpływa na skuteczność rozpoznawania poszczególnych cech mówcy.

## 2.2. Zakres pracy

Zakres pracy obejmował:

- analiza literatury przedmiotu,
- przygotowanie zbioru danych,
- ekstrakcja cech akustycznych,
- budowa i trening modeli klasyfikacyjnych,
- ewaluacja modeli i interpretacja wyników,
- wnioski i kierunki dalszych badań.

## 2.3. Podział pracy

Podział prac pomiędzy poszczególnych członków zespołu przedstawiono w tabeli 2.1.

Tabela 2.1. Podział prac pomiędzy członków zespołu

| Element pracy | Bednarski Piotr | Brzozowski Tomasz |
|---|---|---|
| Streszczenie/Abstract | | X |
| 1. Wstęp | X | |
| 2. Cel i zakres pracy | | X |

| | | |
|---|---|---|
| 3. Przegląd dotychczasowych badań | X | |
| 4. Podstawy teoretyczne | X | X |
| 4.1. Reprezentacje sygnału audio | X | |
| 4.2. Sieci neuronowe stosowane do analizy mowy | | X |
| 5. Metoda badań | X | X |
| 5.1. Środowisko badawcze | X | |
| 5.2. Wykorzystany zbiór danych | | X |
| 5.3. Przygotowanie zbioru danych | X | X |
| 5.4. Ekstrakcja cech i przygotowanie danych wejściowych | X | X |
| 5.5. Implementacja modeli | X | X |
| 5.6. Metody oceny modeli | X | X |
| 6. Przeprowadzone badania i wyniki | X | X |
| 7. Wnioski | X | X |
| Wykaz literatury | X | X |

# 3. Przegląd dotychczasowych badań i rozpoznanie luki badawczej

## 3.1. Przegląd literatury

W literaturze naukowej, m. in. [2], [3] i [4] poświęcono znaczącą uwagę problematyce profilowania mówców oraz powiązanym zagadnieniom analizy mowy. W ramach prowadzonych badań analizowane są różnorodne metody uczenia maszynowego i uczenia głębokiego, których celem jest automatyczne wydobywanie z danych akustycznych informacji charakteryzujących mówcę. Poniżej przedstawiono przegląd analizowanej literatury naukowej poświęconej nie tylko wydobywaniu cech mówcy, ale też ogólniej klasyfikacji nagrań dźwiękowych, metodom wstępnego przetwarzania danych akustycznych, zasadności stosowania tych metod oraz innym istotnym z punktu widzenia rozpoznawania cech mówcy lub dziedzin pokrewnych zagadnieniom.

Na podstawie pracy Angadi i in. [3] można przedstawić ogólne podejście do realizacji zadań związanych z analizą cech mówcy. W pierwszym etapie surowe dane dźwiękowe mogą zostać przekształcone do postaci reprezentacji, która pozwala zachować informacje istotne z punktu widzenia rozpatrywanego problemu. W pracy [3] wykorzystano w tym celu współczynniki MFCC, które następnie zastosowano jako cechy wejściowe dla modeli uczenia maszynowego. Następnie model uczenia maszynowego jest uczony z wykorzystaniem uzyskanej reprezentacji cech, a nie bezpośrednio surowego sygnału dźwiękowego.

Alnuaim i in. [2] przeprowadzili badania dotyczące rozpoznawania płci mówcy z wykorzystaniem metod uczenia maszynowego i uczenia głębokiego na zbiorze danych Mozilla Common Voice. W badaniu uwzględniono kilka reprezentacji akustycznych sygnału, w tym współczynniki MFCC oraz spektrogramy w skali Mel. Uzyskane wyniki wykazały skuteczność reprezentacji opartych na spektrogramach oraz metod uczenia głębokiego w zadaniu klasyfikacji płci, przy czym najlepsze rezultaty uzyskano z wykorzystaniem podejścia opartego na uczeniu transferowym. Podobne badania przeprowadzili Ghosh i in. [9], analizując jednocześnie klasyfikację płci oraz języka z wykorzystaniem cech akustycznych i metod uczenia głębokiego.

Jak wskazują Basak i in. [4], współczynniki MFCC należą do najczęściej stosowanych metod ekstrakcji cech w analizie i rozpoznawaniu mowy, a ich wykorzystanie jest często traktowane jako standardowe podejście w tego rodzaju zadaniach. Ich popularność wynika między innymi z uwzględnienia właściwości ludzkiego sposobu postrzegania dźwięku. Proces wyznaczania współczynników MFCC obejmuje zastosowanie dyskretnej

transformaty kosinusowej (DCT, ang. Discrete Cosine Transform), która służy do zmniejszenia korelacji pomiędzy współczynnikami banku filtrów i uzyskania bardziej zwartej reprezentacji danych.

Costantini, Cesarini i Brenna [5] porównali skuteczność splotowych sieci neuronowych (CNN, ang. convolutional neural network), uwzględniając zarówno modele zaprojektowane przez autorów, jak i modele wykorzystujące uczenie transferowe. W badaniu zastosowano dane poddane wstępnemu przetwarzaniu z wykorzystaniem dwóch różnych metod: spektrogramów uzyskanych na podstawie krótkoczasowej transformaty Fouriera (STFT, ang. Short-Time Fourier Transform) oraz reprezentacji MFCC przedstawionych w postaci graficznej. Interesującym wynikiem przedstawionym w pracy [5] była niższa skuteczność modeli wykorzystujących reprezentację MFCC w porównaniu z modelami wykorzystującymi reprezentację w postaci spektrogramów. Autorzy wskazują, że jednym z możliwych wyjaśnień tej różnicy może być większy stopień dyskretyzacji reprezentacji MFCC.

Faisal i in. [7] przeanalizowali możliwość klasyfikacji kaszlu związanego z COVID-19 z wykorzystaniem współczynników MFCC oraz kilku algorytmów uczenia maszynowego. Spośród ocenianych modeli najlepszy wynik uzyskał model SVM z jądrem RBF, jednak wartość AUC na poziomie 0,658 wskazuje na stosunkowo ograniczoną zdolność modelu do rozróżniania poszczególnych klas.

Ayranci i in. [1] przeprowadzili badania dotyczące rozpoznawania akcentu mówcy z wykorzystaniem współczynników MFCC oraz kilku algorytmów uczenia maszynowego, wykazując przydatność reprezentacji opartych na MFCC w zadaniu klasyfikacji akcentu. Podobne badania przeprowadzili Garg i in. [8], analizując skuteczność różnych cech akustycznych, w tym współczynników MFCC, cech widmowych oraz cech chroma, w klasyfikacji mowy z akcentem. Uzyskana przez autorów ogólna dokładność klasyfikacji wyniosła 86,67%.

Koli [12] przeprowadził badania dotyczące klasyfikacji wieku, płci oraz narodowości mówcy z wykorzystaniem wstępnie wytrenowanych modeli CNN oraz spektrogramów w skali Mel. W zadaniu klasyfikacji grup wiekowych uzyskano dokładność na poziomie 52%. Podobne badania przeprowadził Mavaddati [14], analizując klasyfikację wieku, płci oraz języka z wykorzystaniem modeli CNN, RNN i ResNet34, stosując reprezentacje spektroczasowe oraz uczenie transferowe.

### 3.2. Identyfikacja luki badawczej

Prace [2] i [9] nie przedstawiają bezpośredniego porównania reprezentacji MFCC i spektrogramów Mel przy zastosowaniu tych samych architektur sieci neuronowych. W niniejszej pracy przeprowadzono natomiast porównanie obu reprezentacji z wykorzystaniem autorskich modeli opartych na CNN, rekurencyjnych sieciach neuronowych z długą pamięcią krótkotrwałą (LSTM, ang. long short-term memory) oraz wielowarstwowych perceptronach (MLP, ang. multi-layer perceptron). Modele zostały wytrenowane od podstaw, bez wykorzystania uczenia transferowego.

Na podstawie [4] użycie DCT pozwala ograniczyć nadmiarowość informacji pomiędzy poszczególnymi współczynnikami. Pojawia się jednak pytanie, czy zachowanie bardziej zwartej reprezentacji jest zawsze korzystne dla danego zadania klasyfikacyjnego. Z tego względu zasadne jest zbadanie, czy reprezentacje zachowujące większą ilość informacji widmowej, mimo występującej w nich większej nadmiarowości, mogą zapewniać lepsze wyniki niż bardziej zwarta reprezentacja MFCC, w zależności od zastosowanej architektury sieci neuronowej oraz analizowanej cechy mówcy.

Obserwacja przedstawiona w pracy [5] polegająca na tym, że niższa skuteczność modeli wykorzystujących reprezentację MFCC w porównaniu z modelami wykorzystującymi reprezentację w postaci spektrogramów jest istotna z punktu widzenia dalszych badań i wskazuje na potrzebę przeprowadzenia szerszej analizy z wykorzystaniem różnych architektur sieci neuronowych, a nie wyłącznie sieci CNN. Należy również zaznaczyć, że badanie przedstawione w pracy [5] dotyczy rozpoznawania mówcy, a nie analizy jego cech. Oba zadania wykorzystują jednak informacje zawarte w sygnale mowy, choć informacje związane z mówcą istotne dla każdego z nich mogą być odmienne.

Wyniki pracy [7] sugerują, że samo zastosowanie współczynników MFCC nie gwarantuje skutecznego rozdzielenia klas, a ich przydatność może zależeć zarówno od charakterystyki analizowanych danych dźwiękowych, jak i od rodzaju realizowanego zadania klasyfikacyjnego, czy metody, jaką wykonywana jest predykcja.

W oparciu o [1], [2] i [12] można wysnuć tezę, iż reprezentacje cech akustycznych mogą dostarczać użytecznych informacji pozwalających na rozróżnianie poszczególnych akcentów.

# 4. Podstawy teoretyczne

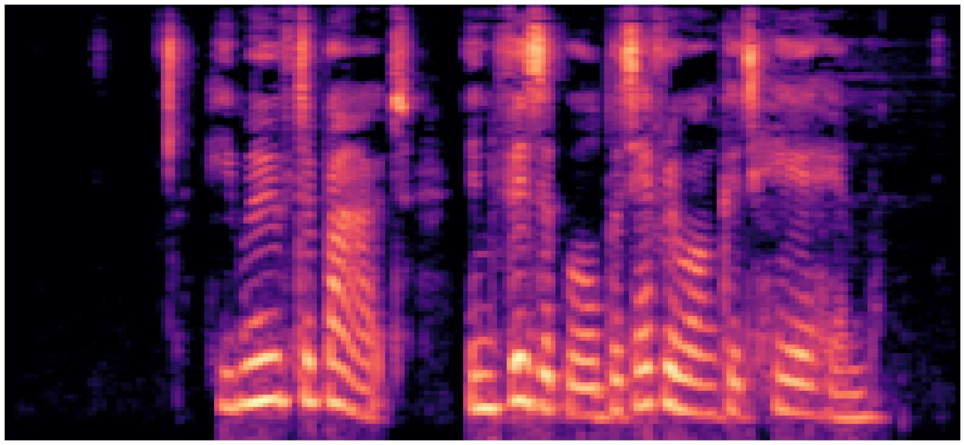
## 4.1. Reprezentacje sygnału audio

### Spektrogram Mel

Spektrogram Mel jest reprezentacją sygnału dźwiękowego, w której informacja o częstotliwości została przedstawiona z wykorzystaniem skali logarytmicznej Mel. Jej zastosowanie wynika z charakterystyki ludzkiego słuchu, dla którego odbiór zmian częstotliwości nie ma charakteru liniowego. W celu odwzorowania tej właściwości częstotliwości fizyczne wyrażone w hercach (Hz) przelicza się na wartości skali Mel. Zgodnie z [1] zależność pomiędzy częstotliwością $f_{Hz}$,a odpowiadającą jej wartością $f_{mel}$ można opisać równaniem:

$$f_{mel} = 2595 \cdot log\left(1 + \frac{f_{Hz}}{700}\right) \tag{4.1}$$

Do utworzenia spektrogramu Mel wykorzystywany jest wynik STFT. Sygnał jest analizowany w kolejnych, krótkich fragmentach, dla których wyznaczane jest widmo częstotliwościowe. Następnie uzyskane wartości są przepuszczane przez bank filtrów rozmieszczonych zgodnie ze skalą Mel. Filtry te mają zazwyczaj kształt trójkątny i obejmują określone zakresy częstotliwości. Wartość każdego pasma jest wyznaczana na podstawie ważonego udziału składowych widma znajdujących się w zakresie danego filtru. Powtarzanie tego procesu dla kolejnych fragmentów sygnału pozwala utworzyć dwuwymiarową reprezentację, w której jedna oś odpowiada czasowi, a druga pasmom częstotliwości w skali Mel. Wartości znajdujące się w poszczególnych punktach reprezentacji określają poziom energii sygnału dla danego momentu i zakresu częstotliwości. W efekcie spektrogram Mel umożliwia obserwację zmian charakterystyki częstotliwościowej sygnału w czasie [15]. Na rysunku 4.1 zaprezentowano przykładowy spektrogram w skali Mel.



Rysunek 4.1. Spektrogram Mel

Uwzględnienie właściwości ludzkiej percepcji słuchowej sprawia, że spektrogramy Mel są przydatne w analizie sygnałów mowy. Reprezentacja ta jest wykorzystywana między innymi w rozpoznawaniu mówcy, automatycznym rozpoznawaniu mowy oraz rozpoznawaniu emocji. Może również stanowić bezpośrednią reprezentację wejściową dla modeli uczenia maszynowego i głębokiego [15].

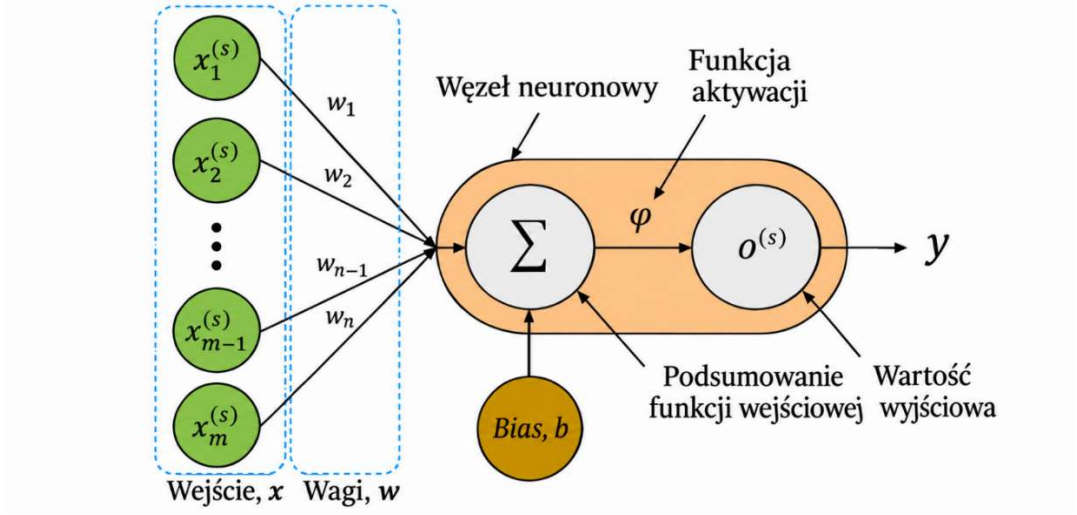
**Współczynniki cepstralne w skali Mel**

Opisany wcześniej spektrogram Mel przedstawia rozkład energii sygnału w czasie z uwzględnieniem skali częstotliwości odpowiadającej właściwościom ludzkiego słuchu. Reprezentacja ta może być jednak poddana dalszemu przetwarzaniu w celu uzyskania bardziej zwartego opisu charakterystyki widmowej sygnału. Jedna z metod wykorzystująca ten sposób reprezentacji to MFCC [17]. Na wartościach uzyskanych z banku filtrów wykonywana jest DCT. Jej zastosowanie pozwala przekształcić zależności pomiędzy poszczególnymi pasmami w zestaw współczynników cepstralnych oraz ograniczyć ilość informacji do cech istotnych dla dalszej analizy. Z tego względu współczynniki MFCC są często wykorzystywane jako dane wejściowe dla modeli uczenia maszynowego stosowanych do analizy i klasyfikacji sygnałów mowy [4].

## 4.2. Sieci neuronowe stosowane do analizy mowy

### Perceptron wielowarstwowy

Wielowarstwowy perceptron (MLP) należy do grupy jednokierunkowych sztucznych sieci neuronowych i jest jedną z podstawowych architektur wykorzystywanych w uczeniu głębokim. Model ten może być stosowany w zadaniach uczenia nadzorowanego, w tym między innymi do klasyfikacji oraz predykcji wartości. Jego budowa obejmuje warstwę wejściową, warstwy ukryte oraz warstwę wyjściową. W zależności od zastosowania modelu liczba warstw ukrytych może być różna. Charakterystyczną cechą MLP jest pełne połączenie neuronów pomiędzy sąsiednimi warstwami. Oznacza to, że każdy neuron jednej warstwy otrzymuje informacje od wszystkich neuronów warstwy poprzedniej i przekazuje wynik swojego działania do neuronów kolejnej warstwy. Dane wprowadzone do sieci są kolejno przetwarzane przez poszczególne warstwy ukryte, w których następuje przekształcanie reprezentacji wejściowej. Następnie uzyskana reprezentacja jest przekazywana do warstwy wyjściowej, odpowiedzialnej za wygenerowanie wyniku odpowiedniego dla realizowanego zadania. Podstawowym elementem każdej warstwy MLP jest neuron. Jego działanie można sprowadzić do obliczenia sumy ważonej wartości wejściowych, uwzględnienia obciążenia, a następnie zastosowania funkcji aktywacji. Takie przekształcenie pozwala kolejnym warstwom sieci stopniowo modyfikować reprezentację przekazywanych danych [18]. Schemat pojedynczego neuronu przedstawiono na rysunku 4.2.




Rysunek 4.2. Schemat pojedynczego neuronu w modelu MLP. Opracowano przy użyciu modeli generatywnych na podstawie [11].

Na rysunku 4.2 (x) oznacza wektor wartości wejściowych, (w) jest wektorem wag, (b) oznacza obciążenie neuronu, natomiast (y) jest wartością wyjściową. Funkcja $\varphi$ pełni rolę funkcji aktywacji i umożliwia wprowadzenie nieliniowości do działania sieci neuronowej [11].

**Splotowa sieć neuronowa**

Splotowe sieci neuronowe (CNN) są szeroko wykorzystywane w obszarze głębokiego uczenia do przetwarzania i analizy danych. Znalazły zastosowanie między innymi w rozpoznawaniu obrazów i mowy, klasyfikacji obrazów oraz wykrywaniu obiektów. Sieci CNN są sieciami jednokierunkowymi, w których jednym z podstawowych mechanizmów przetwarzania informacji jest operacja splotu. Umożliwia ona identyfikowanie charakterystycznych cech występujących w danych wejściowych. W przypadku sieci CNN proces wyznaczania cech może być realizowany bezpośrednio w trakcie uczenia modelu. Oznacza to, że w przeciwieństwie do metod wymagających wcześniejszego ręcznego przygotowania cech, sieć może samodzielnie nauczyć się reprezentacji odpowiednich dla danego zadania. Wyodrębnione w ten sposób cechy są następnie wykorzystywane przez kolejne elementy modelu do wykonania klasyfikacji. Takie podejście pozwala połączyć etap ekstrakcji cech z procesem klasyfikacji w ramach jednej architektury i ograniczyć zakres ręcznego przygotowania danych [18].

Jej podstawowymi elementami są warstwy splotowe (ang. convolutional layer), funkcje aktywacji (ang. activation function), warstwy próbkowania (ang. pooling layer) oraz warstwy w pełni połączone (ang. fully connected layer). Warstwy splotowe odpowiadają za wykrywanie istotnych cech w danych wejściowych poprzez zastosowanie filtrów wykonujących operację splotu. Na wynik ich działania, a także na wyniki innych warstw, może być następnie nakładana nieliniowa funkcja aktywacji, która pozwala sieci na odwzorowywanie bardziej złożonych zależności między danymi. Warstwy próbkowania służą do zmniejszania rozmiaru przetwarzanych reprezentacji, co ogranicza liczbę parametrów i obciążenie obliczeniowe kolejnych warstw. Uzyskane reprezentacje mogą być następnie przekazywane do warstw w pełni połączonych, które wykorzystuje się do dalszego przetwarzania cech i przeprowadzenia końcowej klasyfikacji [13].

**Dwukierunkowa rekurencyjna sieć neuronowa typu LSTM**

Sieci LSTM należą do rodziny rekurencyjnych sieci neuronowych (RNN, ang. recurrent neural networks), które są przeznaczone do pracy z danymi uporządkowanymi

sekwencyjnie, w tym z sygnałami zmieniającymi się w czasie. W odróżnieniu od klasycznych sieci neuronowych, w których poszczególne dane wejściowe są przetwarzane niezależnie, sieci rekurencyjne wykorzystują informacje pochodzące z wcześniejszych kroków przetwarzania. Pozwala to uwzględnić kontekst poprzednich elementów analizowanej sekwencji. Klasyczne RNN mają jednak ograniczoną zdolność do zachowywania informacji pochodzących z odległych fragmentów sekwencji. Z tego powodu opracowano architekturę LSTM, w której standardowy sposób przetwarzania informacji został zastąpiony specjalnym blokiem wyposażonym w mechanizm umożliwiający kontrolowanie przepływu informacji. Dzięki temu sieć może skuteczniej zachowywać istotne informacje przez dłuższy czas i uczyć się zależności występujących pomiędzy odległymi elementami sekwencji [10].

Dwukierunkowe sieci LSTM (Bi-LSTM, ang. Bidirectional Long Short-Term Memory) są rozszerzeniem klasycznej architektury LSTM przeznaczonym do analizy danych sekwencyjnych. Ich charakterystyczną cechą jest jednoczesne wykorzystanie informacji z dwóch kierunków przetwarzania. W standardowej sieci LSTM kolejne elementy sekwencji są analizowane zgodnie z ich naturalną kolejnością, przez co przy generowaniu wyniku model korzysta przede wszystkim z informacji dostępnych we wcześniejszych krokach. Bi-LSTM pozwala dodatkowo uwzględnić dane znajdujące się w dalszej części analizowanej sekwencji. Realizacja takiego przetwarzania wymaga zastosowania dwóch równoległych warstw LSTM. Jedna z nich analizuje sekwencję od pierwszego elementu do ostatniego, natomiast druga wykonuje obliczenia w kierunku przeciwnym. Informacje uzyskane przez oba kierunki są następnie wykorzystywane wspólnie do utworzenia reprezentacji sekwencji. Dzięki temu dla każdego analizowanego fragmentu dostępny jest kontekst pochodzący zarówno z wcześniejszych, jak i późniejszych elementów danych. Podczas uczenia każda z warstw LSTM niezależnie przetwarza otrzymaną sekwencję i aktualizuje swój stan wewnętrzny. Wyniki obu kierunków są następnie łączone i przekazywane do kolejnego etapu modelu. Takie rozwiązanie zwiększa ilość informacji dostępnych podczas analizy zależności pomiędzy poszczególnymi elementami sekwencji. Z tego względu architektura Bi-LSTM może być stosowana w zadaniach, w których znaczenie danego fragmentu danych zależy nie tylko od informacji występujących przed nim, ale również od tych znajdujących się po nim. Sieci tego typu są wykorzystywane między innymi w rozpoznawaniu mowy, przetwarzaniu języka naturalnego oraz innych zadaniach wymagających analizy zależności występujących w danych sekwencyjnych [18].

# 5. Metoda badań

Celem przeprowadzonych badań było opracowanie oraz ocena skuteczności modeli uczenia maszynowego przeznaczonych do rozpoznawania wybranych cech mówcy na podstawie analizy sygnału mowy. W ramach realizacji założonego celu przeprowadzono kolejne etapy postępowania badawczego, obejmujące przygotowanie materiału badawczego, wstępne przetwarzanie sygnałów mowy, ekstrakcję cech akustycznych, przygotowanie danych do procesu uczenia, budowę i trenowanie wybranych modeli uczenia maszynowego, a następnie ocenę ich skuteczności.

W badaniu zastosowano metodologię porównawczo-eksperymentalną. Przyjęta metoda badań pozwoliła na przeprowadzenie procesu analizy w sposób uporządkowany i umożliwiła porównanie uzyskanych wyników dla zastosowanych metod. Szczególną uwagę zwrócono na wpływ sposobu reprezentacji sygnału mowy oraz zastosowanych algorytmów uczenia maszynowego na jakość rozpoznawania analizowanych cech mówcy.

## 5.1. Środowisko badawcze

### Python

Realizacja badań została przeprowadzona z wykorzystaniem środowiska programistycznego opartego na języku programowania wysokiego poziomu Python w wersji 3.10.0. Język ten został wykorzystany jako podstawowe narzędzie do implementacji kolejnych etapów procesu badawczego, obejmujących przygotowanie danych, przetwarzanie sygnałów mowy, ekstrakcję cech oraz budowę i trenowanie modeli uczenia maszynowego.

### Librosa

Do analizy sygnałów audio oraz ekstrakcji cech akustycznych wykorzystano bibliotekę Librosa w wersji 0.11.0 [20], przeznaczoną do przetwarzania i analizy sygnałów dźwiękowych. Umożliwiła ona przygotowanie nagrań oraz wyznaczenie parametrów opisujących właściwości analizowanego sygnału mowy. Wyodrębnione cechy stanowiły następnie dane wejściowe wykorzystywane w procesie uczenia modeli.

### TensorFlow i Keras

Do realizacji procesu uczenia maszynowego wykorzystano bibliotekę TensorFlow, w wersji 2.21.0, wraz z udostępnianym przez nią interfejsem Keras, w wersji 3.12.2. Biblioteka TensorFlow odpowiadała za realizację obliczeń związanych z procesem uczenia modeli, natomiast Keras, jako wysokopoziomowy interfejs programistyczny, został wykorzystany do definiowania architektury modeli, konfigurowania procesu uczenia oraz ich trenowania. Zastosowanie obu rozwiązań pozwoliło na przeprowadzenie całego procesu modelowania w ramach jednego środowiska programistycznego.

### WSL

Istotnym elementem środowiska badawczego była również konfiguracja systemowa wykorzystywana podczas procesu trenowania modeli. Ze względu na konieczność wykorzystania akceleracji obliczeń z zastosowaniem procesora graficznego (GPU), proces trenowania został przeprowadzony w środowisku Linux. Wykorzystanie akceleracji GPU było istotne ze względu na dużą liczbę operacji obliczeniowych wykonywanych podczas trenowania modeli uczenia maszynowego. W celu zapewnienia możliwości korzystania ze środowiska Linux na komputerze pracującym pod kontrolą systemu Windows 10/11 wykorzystano Windows Subsystem for Linux (WSL). W ramach WSL uruchomiono dystrybucję Ubuntu, która stanowiła środowisko wykonawcze dla procesu trenowania modeli. Takie rozwiązanie pozwoliło na zachowanie podstawowego środowiska pracy opartego na systemie Windows, przy jednoczesnym wykorzystaniu środowiska Linux wymaganego do przeprowadzenia obliczeń z wykorzystaniem GPU i biblioteki TensorFlow.

### Scikit-learn

Do analizy wyników uzyskanych przez zaprojektowane i zaimplementowane modele wykorzystano bibliotekę scikit-learn w wersji 1.7.2 [21]. Za jej pomocą wyznaczono podstawowe miary klasyfikacyjne oraz wygenerowano raporty klasyfikacji dla poszczególnych modeli.

## 5.2. Wykorzystany zbiór danych

W badaniach wykorzystano angielskojęzyczny podzbiór zbioru danych Mozilla Common Voice w wersji 1.0 [22] zawierający 380 000 nagrań sygnału mowy, które stanowiły materiał wejściowy dla kolejnych etapów przeprowadzonego eksperymentu. Zbiór danych składa się z nagrań dźwiękowych pochodzących od różnych mówców w języku angielskim. Zbiór danych może zawierać wiele nagrań tego samego mówcy. Każde nagranie dźwiękowe zapisane jest w formacie MP3 jako sygnał jednokanałowy (mono), z częstotliwością próbkowania 48 kHz oraz opisane jest przez trzy cechy mówcy, od którego pochodzi dane nagranie. Analizowane cechy obejmowały cechy demograficzne mówców, takie jak płeć i wiek, oraz cechę językową związaną z występowaniem określonego akcentu języka angielskiego. Poszczególne klasy dla analizowanych cech przedstawiono w tabelach 5.1–5.3.

Tabela 5.1. Klasy płci mówców uwzględnione w zbiorze danych

| **Klasa płci** | **Nazwa klasy w języku angielskim** |
|---|---|
| kobieta | female |
| mężczyzna | male |

Tabela 5.2. Klasy wieku mówców uwzględnione w zbiorze danych

| **Klasa wieku** | **Nazwa klasy w języku angielskim** | **Przedział wieku (w latach)** |
|---|---|---|
| nastolatkowie | teens | < 19 |
| dwudziestolatkowie | twenties | 19 - 29 |
| trzydziestolatkowie | thirties | 30 - 39 |
| czterdziestolatkowie | fourties | 40 - 49 |
| pięćdziesięciolatkowie | fifties | 50 - 59 |
| sześćdziesięciolatkowie | sixties | 60 - 69 |
| siedemdziesięciolatkowie | seventies | 70 - 79 |
| osiemdziesięciolatkowie | eighties | 80 - 89 |

Tabela 5.3. Klasy akcentu języka angielskiego mówców uwzględnione w zbiorze danych

| Klasa akcentu języka angielskiego | Nazwa klasy w języku angielskim |
|---|---|
| amerykański | us |
| australijski | australia |
| angielski (Anglia) | england |
| kanadyjski | canada |
| filipiński | philippines |
| hongkoński | hongkong |
| indyjski | indian |
| irlandzki | ireland |
| malezyjski | malaysia |
| nowozelandzki | newzealand |
| szkocki | scotland |
| singapurski | singapore |
| południowy Atlantyk | southatlantic |
| afrykański | african |
| walijski | wales |
| bermudzki | bermuda |

## 5.3. Przygotowanie zbioru danych

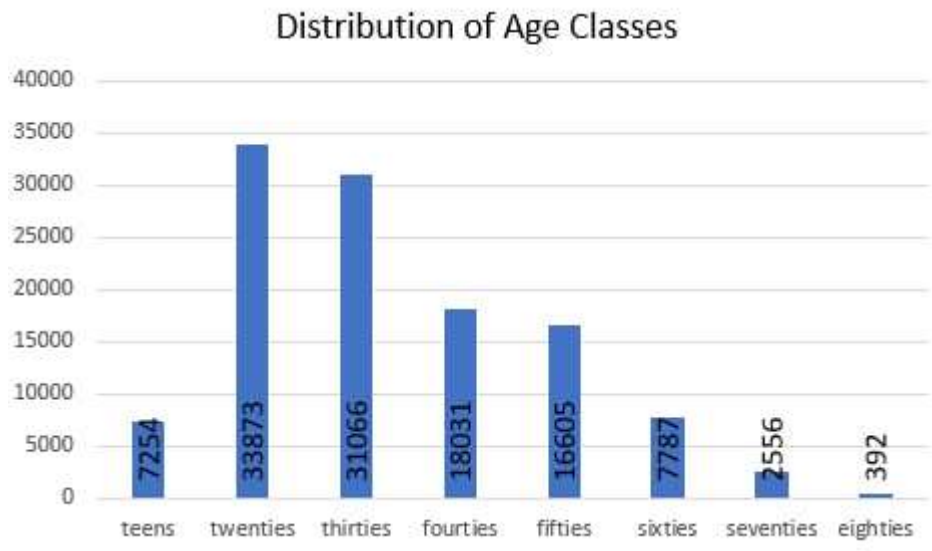
W pierwszym etapie przygotowania zbioru danych usunięto rekordy zawierające brakujące informacje. Ze zbioru wykluczono każde nagranie, dla którego brakowało wartości co najmniej jednej z analizowanych cech. Dodatkowo usunięto nagrania o czasie trwania przekraczającym 8 sekund. Nagrania o znacznie większej długości nie wnosiły proporcjonalnie większej ilości informacji istotnych z punktu widzenia przeprowadzanej analizy, dlatego ich wykluczenie pozwoliło ograniczyć obciążenie pamięciowe oraz ujednolicić długość analizowanych fragmentów sygnału. Ostatecznie oczyszczony zbiór danych zawierał 117 564 nagrania, z których każde zawierało informacje dotyczące trzech analizowanych cech mówcy.

Otrzymany po oczyszczeniu zbiór danych charakteryzował się nierównomiernym rozkładem liczby nagrań pomiędzy poszczególnymi klasami analizowanych cech. Niezbalansowanie to wynikało z pierwotnej struktury wykorzystanego zbioru danych i nie było efektem przeprowadzonego procesu przygotowania danych. Rozkład liczby nagrań

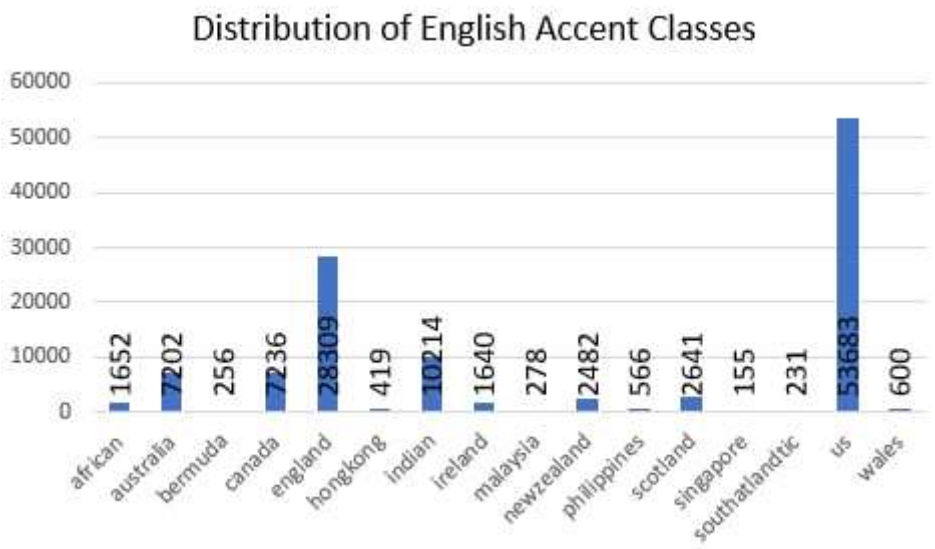
w poszczególnych klasach płci, akcentu oraz grup wiekowych przedstawiono na rysunkach 5.1-5.3. W ramach przeprowadzonych badań nie zastosowano metod służących do radzenia sobie z niezbalansowanymi zbiorami danych, takich jak techniki augmentacji lub SMOTE (ang. Synthetic Minority Oversampling Technique). Zachowanie pierwotnego rozkładu klas pozwoliło na ocenę działania badanych modeli w warunkach niezbalansowanego zbioru danych.




Rysunek 5.1. Rozkład liczebności klas płci w zbiorze danych




Rysunek 5.2. Rozkład liczebności klas wieku w zbiorze danych




Rysunek 5.3. Rozkład liczebności klas akcentu w zbiorze danych

W celu zapewnienia porównywalnego poziomu amplitudy analizowanych nagrań zastosowano normalizację amplitudy sygnału (listing 5.1) [23].

Listing 5.1. Funkcja normalizująca amplitudę sygnału mowy

```
3   def booster(audio):
4       max_amp = np.max(np.abs(audio))
5       if(max_amp==0):
6           return audio
7       gain = 1.0 / max_amp
8       if(gain > 1.0):
9           return audio * gain
10      else:
11          return audio
```

Dla każdego nagrania wyznaczono maksymalną wartość bezwzględną amplitudy, a następnie obliczano współczynnik wzmocnienia jako odwrotność tej wartości. Jeżeli maksymalna amplituda była mniejsza od 1, sygnał był mnożony przez wyznaczony współczynnik, tak aby jego maksymalna amplituda osiągnęła wartość 1. W przypadku nagrań, których maksymalna amplituda wynosiła 1 lub więcej, nie stosowano dodatkowego wzmocnienia.

## 5.4. Ekstrakcja cech i przygotowanie danych wejściowych

Mając przygotowany zbiór danych w sposób przedstawiony w rozdziale 5.3, kolejnym etapem badań była ekstrakcja cech, czyli proces wyznaczania z sygnału informacji opisujących jego charakterystykę, które mogą zostać wykorzystane jako dane wejściowe dla modeli uczenia maszynowego. Na podstawie przygotowanych nagrań wyznaczono reprezentacje sygnałów w skali Mel, a następnie zastosowano do nich dyskretną transformatę kosinusową. W wyniku tego procesu otrzymano współczynniki cepstralne w skali Mel, które wykorzystano w dalszej części badań.

Do realizacji ekstrakcji cech wykorzystano bibliotekę Librosa. Obliczenia przeprowadzono z uwzględnieniem częstotliwości próbkowania analizowanych nagrań wynoszącej 48 kHz (listing 5.2) [23].

Listing 5.2. Fragment funkcji realizującej ekstrakcję cech z nagrań

```
45      x , sr = librosa.load(path, sr=48000)
46      x = booster(x)
47
48      # MEL numeric:
49      mel = librosa.feature.melspectrogram(y=x, sr=sr, n_mels=N_MELS)
50      mel_db = librosa.power_to_db(mel, ref=np.max)
51      mel_num_path = Path(mel_num_output) / (Path(before+"_"+after).stem + ".npy")
52      np.save(mel_num_path, mel_db)
53
54      # MEL spectograms:
55      mel_spec_path = Path(mel_spec_output) / (Path(before+"_"+after).stem + ".png")
56
57      fig = plt.figure(figsize=mel_figsize, dpi=DPI)
58      ax = fig.add_axes([0, 0, 1, 1])
59      librosa.display.specshow(mel_db, sr=sr, x_axis='time', y_axis='m', cmap="gray")
60      ax.set_axis_off()
61      plt.savefig(mel_spec_path, pad_inches=0, dpi=DPI)
62      plt.close()
63
64      # MFCC numeric:
65      mfcc = librosa.feature.mfcc(y=x, sr=sr, n_mfcc=N_MFCC)
66      mfcc_num_path = Path(mfcc_num_output) / (Path(before+"_"+after).stem + ".npy")
67      np.save(mfcc_num_path, mfcc)
68
69      # MFCC spectograms:
70      mfcc_spec_path = Path(mfcc_spec_output) / (Path(before+"_"+after).stem + ".png")
71      fig = plt.figure(figsize=mfcc_figsize, dpi=DPI)
72      ax = fig.add_axes([0, 0, 1, 1])
73      librosa.display.specshow(mfcc, sr=sr, cmap="gray")
74      ax.set_axis_off()
75      plt.savefig(mfcc_spec_path, pad_inches=0, dpi=DPI)
76      plt.close()
```

Wszystkie obrazy, wykorzystywane później do nauki modeli sieci CNN, były generowane na podstawie całej długości danego nagrania. W przypadku danych numerycznych konieczne było natomiast zapewnienie jednakowej liczby analizowanych

okien czasowych dla wszystkich nagrań, co wynikało z wymagań modeli uczenia maszynowego, dla których dane wejściowe muszą mieć taki sam rozmiar. Przyjęto w tym celu długość równą 336 oknom. Wartość 336 została wyznaczona na podstawie mediany liczby okien występujących w nagraniach pozostałych w zbiorze po usunięciu nagrań o czasie trwania przekraczającym 8 sekund. Zastosowanie mediany pozwoliło ograniczyć wpływ nagrań o nietypowej długości oraz zapewnić względnie równomierny podział nagrań wymagających skrócenia i uzupełnienia.

W przypadku nagrań zawierających mniej niż 336 okien następowało ich uzupełnienie poprzez dołączenie na końcu odpowiedniej liczby początkowych okien danego nagrania. Jeżeli nagranie zawierało dokładnie 336 okien, nie było konieczne wykonywanie dodatkowych operacji. Natomiast w przypadku nagrań dłuższych niż 336 okien wybierano 336 okien znajdujących się w środkowej części nagrania, usuwając taką samą liczbę okien z początku i końca sygnału (listing 5.3) [23].

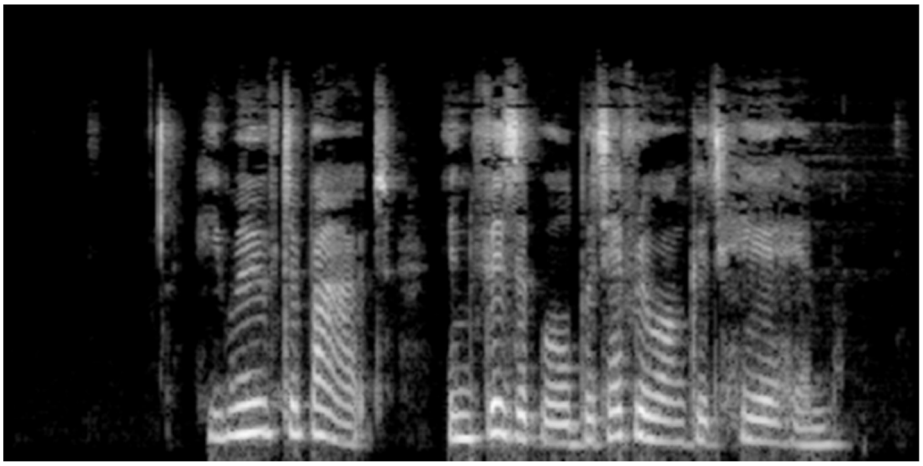
Listing 5.3. Funkcja dostosowująca długość danych numerycznych do zadanej liczby okien

```
59  def equalize_shape(path, new_path, median):
60      equalized_filepath = new_path + "\\" + path.rsplit("\\",1)[1].rsplit(".",1)[0] + "_eq.npy"
61      data = np.load(path)
62      d_size = data.shape[1]
63      new_data : np.ndarray
64      if(d_size == median):
65          new_data = data
66      elif(d_size > median):
67          excess = d_size - median
68          left = 0
69          right = 0
70          if(excess % 2):
71              left += 1
72          truncate = excess // 2
73          left += truncate
74          right += truncate
75          if right == 0:
76              new_data = data[:, left:]
77          else:
78              new_data = data[:, left:-right]
79      else:
80          missing = median - d_size
81          repeats = int(np.ceil(missing / d_size))
82          padding = np.tile(data, (1, repeats))
83          padding = padding[:, :missing]
84          new_data = np.concatenate([data, padding], axis=1)
85      np.save(equalized_filepath, new_data)
86      return equalized_filepath
```

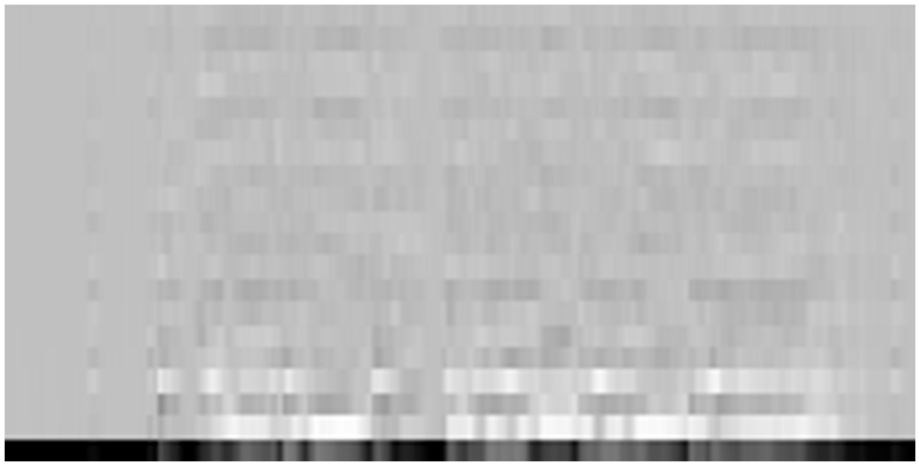
Podczas ekstrakcji cech określono parametry wpływające na wymiar uzyskiwanych reprezentacji. Dla danych w skali Mel przyjęto 256 pasm częstotliwości Mel, natomiast dla współczynników MFCC ustalono ich liczbę na 20. Po dostosowaniu liczby okien czasowych

do 336 dla każdego nagrania uzyskano reprezentacje o wymiarach 256×336 dla danych w skali Mel oraz 20×336 dla współczynników MFCC.

Po zakończeniu procesu ekstrakcji cech i przygotowania danych wejściowych utworzono końcowy zbiór zawierający informacje niezbędne do przeprowadzenia dalszych eksperymentów. W efekcie każdy rekord zbioru stanowił kompletny opis pojedynczej próbki danych i zawierał pierwotną nazwę nagrania, informacje dotyczące trzech analizowanych cech mówcy oraz ścieżki do plików zawierających poszczególne reprezentacje danego nagrania. Ścieżki do plików obejmowały reprezentacje obrazowe w skali szarości (rys. 5.4-5.5) oraz dane numeryczne w postaci wartości w skali Mel i współczynników cepstralnych w skali Mel (MFCC).



Rysunek 5.4. Spektrogram sygnału mowy w skali Mel



Rysunek 5.5. Reprezentacja obrazowa współczynników MFCC dla sygnału mowy

W celu przedstawienia struktury końcowego zbioru danych wejściowych dla modeli uczenia maszynowego poniżej w tabeli 5.4 zestawiono poszczególne kolumny wraz z opisem przechowywanych w nich informacji.

Tabela 5.4. Opis kolumn końcowego zbioru danych wejściowych

| Nazwa kolumny | Opis kolumny |
|---|---|
| filename | Nazwa oryginalnego nagrania w formacie MP3 |
| age | Klasa wieku mówcy |
| gender | Klasa płci mówcy |
| accent | Klasa akcentu mówcy |
| mel_spec_path | Ścieżka do pliku zawierającego spektrogram Mel w skali szarości |
| mfcc_spec_path | Ścieżka do pliku zawierającego wizualizację współczynników MFCC w skali szarości |
| mel_eq_path | Ścieżka do pliku zawierającego dane numeryczne w skali Mel |
| mfcc_eq_path | Ścieżka do pliku zawierającego współczynniki MFCC |

Na koniec zbiór danych wejściowych został podzielony na zbiór treningowy, walidacyjny i testowy (listing 5.4) [23]. Taki podział umożliwia kontrolę procesu uczenia oraz ocenę zdolności modeli do generalizacji, czyli poprawnego działania na danych, które nie były wcześniej wykorzystywane podczas ich uczenia. Liczebność poszczególnych zbiorów oraz ich udział procentowy w całym zbiorze danych przedstawiono w tabeli 5.5. Niniejszy podział może nie być niezależny od osoby, to znaczy w niniejszym podziale danych na zbiory nie jest wykluczona sytuacja, że nagrania tej samej osoby trafiły do więcej niż jednego zbioru.

Listing 5.4. Podział danych na zbiór treningowy, testowy i walidacyjny

```
118     X = data[:,0]
119     y = data[:,1].astype(np.int32)
120
121     X_train, X_temp, y_train, y_temp = train_test_split(
122         X,
123         y,
124         test_size=0.25,
125         random_state=RANDOM_STATE,
126         stratify=y
127     )
128
129     X_val, X_test, y_val, y_test = train_test_split(
130         X_temp,
131         y_temp,
132         test_size=0.60,
133         random_state=RANDOM_STATE,
134         stratify=y_temp
135     )
```

Tabela 5.5. Podział danych wejściowych na zbiór treningowy, walidacyjny i testowy

| Zbiór danych | Liczebność zbioru | Udział w całym zbiorze |
|---|---|---|
| Treningowy | 88173 | 75% |
| Walidacyjny | 11756 | 10% |
| Testowy | 17635 | 15% |

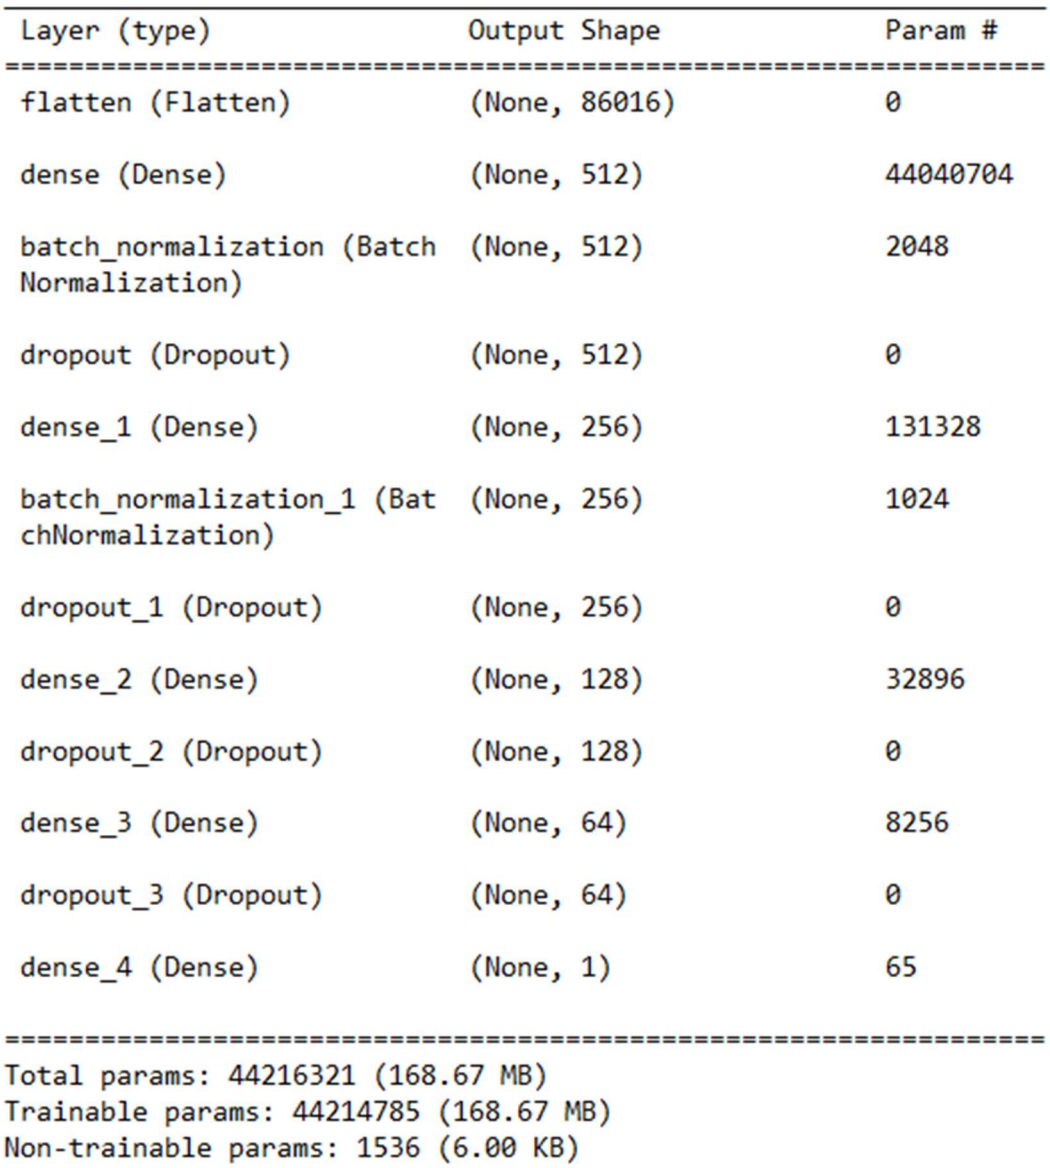
## 5.5. Implementacja modeli

W ramach przeprowadzonych badań zaimplementowano 18 modeli uczenia maszynowego przeznaczonych do rozpoznawania wybranych cech mówcy na podstawie przygotowanych danych wejściowych. Spośród 18 zaimplementowanych modeli 9 wykorzystywało jako dane wejściowe reprezentację sygnału w skali Mel, natomiast pozostałe 9 modeli oparto na współczynnikach MFCC. W ramach każdej z tych grup po trzy modele zostały przeznaczone do rozpoznawania płci, wieku oraz akcentu mówcy. W każdej grupie znalazły się również po trzy modele wykorzystujące obrazową reprezentację danych, po jednym dla każdej analizowanej cechy.

W badaniach wykorzystano następujące typy architektur sieci neuronowych:

- perceptron wielowarstwowy,
- splotowe sieci neuronowe,
- dwukierunkowe sieci neuronowe długiej pamięci krótkotrwałej.

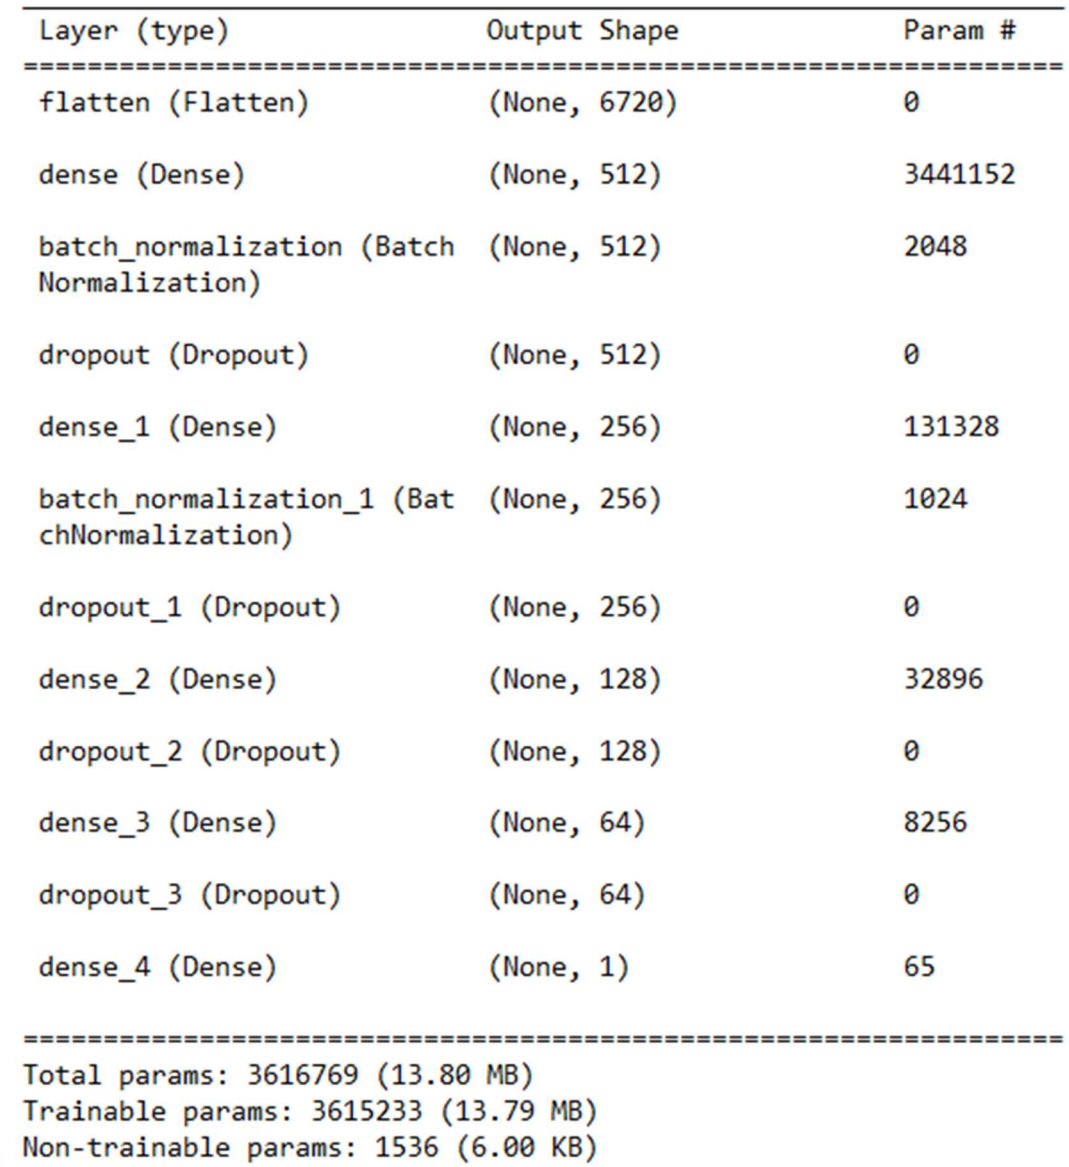
Poniżej na rysunkach 5.6-5.23 przedstawiono podsumowania architektur poszczególnych modeli, obejmujące zastosowane warstwy, wymiary ich wyjść oraz liczbę parametrów.



| Layer (type) | Output Shape | Param # |
|---|---|---|
| flatten (Flatten) | (None, 86016) | 0 |
| dense (Dense) | (None, 512) | 44040704 |
| batch_normalization (BatchNormalization) | (None, 512) | 2048 |
| dropout (Dropout) | (None, 512) | 0 |
| dense_1 (Dense) | (None, 256) | 131328 |
| batch_normalization_1 (BatchNormalization) | (None, 256) | 1024 |
| dropout_1 (Dropout) | (None, 256) | 0 |
| dense_2 (Dense) | (None, 128) | 32896 |
| dropout_2 (Dropout) | (None, 128) | 0 |
| dense_3 (Dense) | (None, 64) | 8256 |
| dropout_3 (Dropout) | (None, 64) | 0 |
| dense_4 (Dense) | (None, 1) | 65 |

Total params: 44216321 (168.67 MB)
Trainable params: 44214785 (168.67 MB)
Non-trainable params: 1536 (6.00 KB)

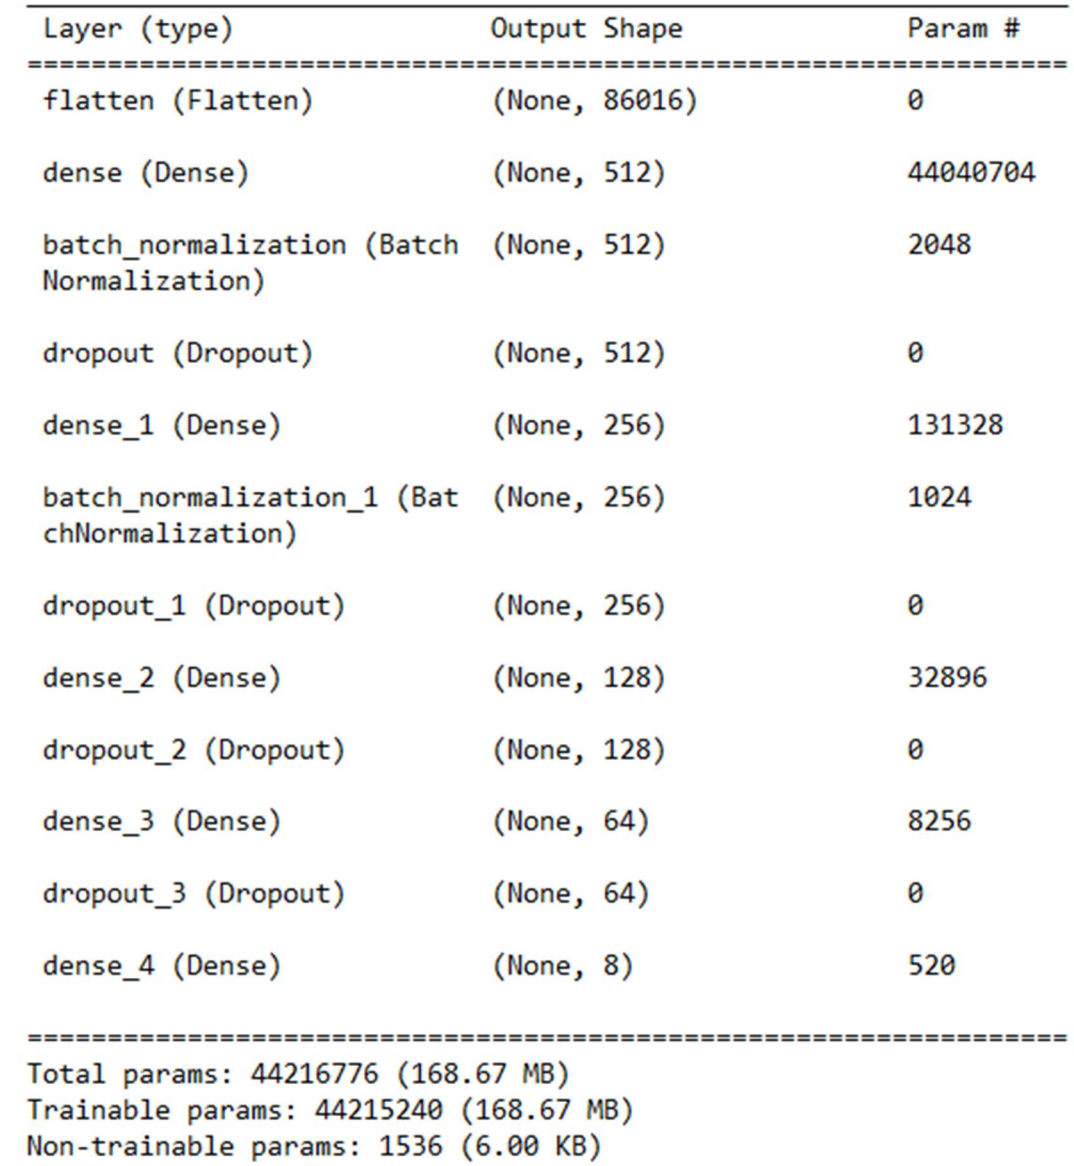
Rysunek 5.6. Architektura modelu sieci MLP wykorzystana do klasyfikacji płci mówcy na podstawie danych w skali Mel



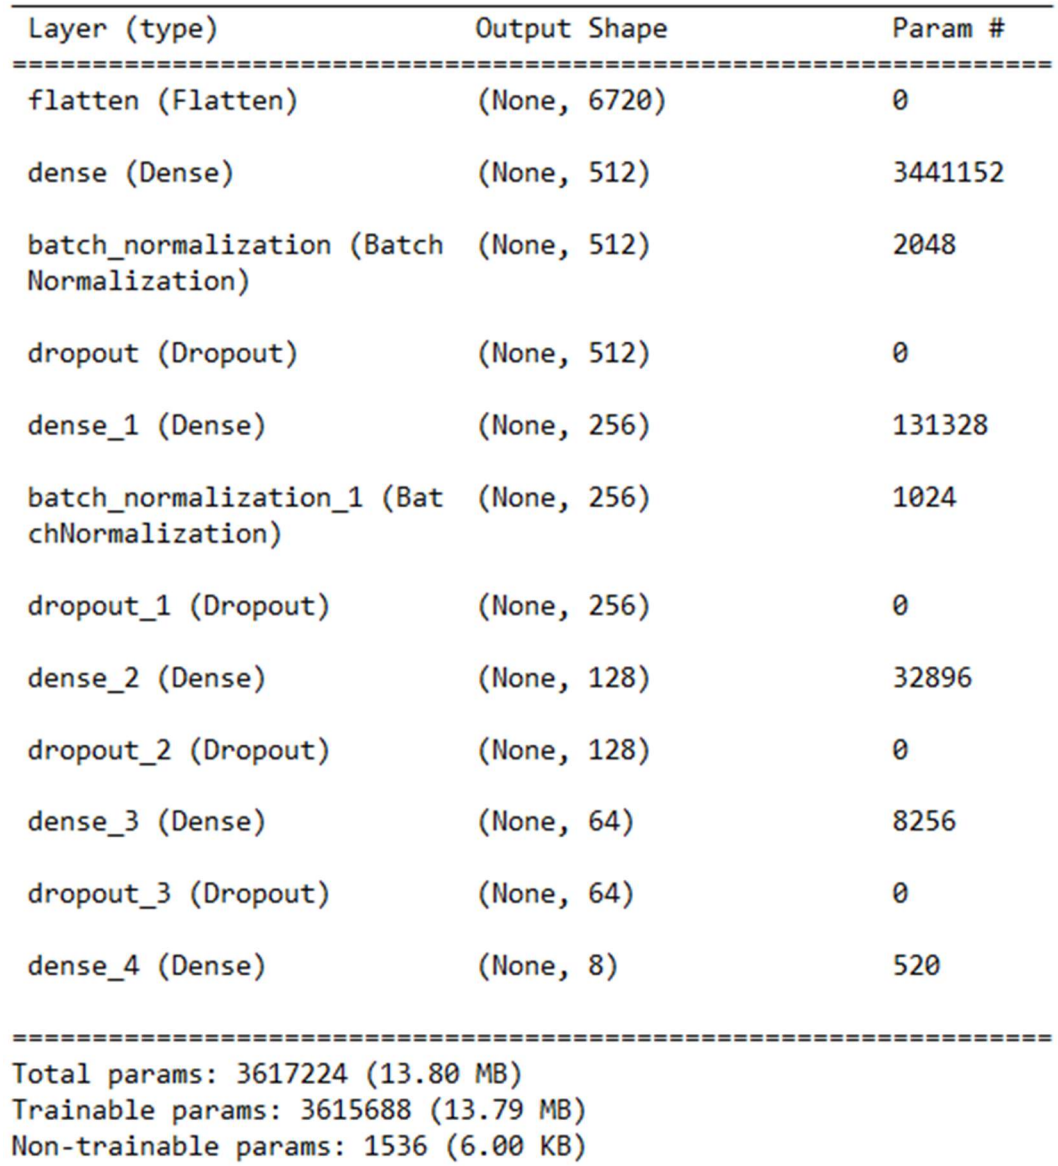
| Layer (type) | Output Shape | Param # |
|---|---|---|
| flatten (Flatten) | (None, 6720) | 0 |
| dense (Dense) | (None, 512) | 3441152 |
| batch_normalization (BatchNormalization) | (None, 512) | 2048 |
| dropout (Dropout) | (None, 512) | 0 |
| dense_1 (Dense) | (None, 256) | 131328 |
| batch_normalization_1 (BatchNormalization) | (None, 256) | 1024 |
| dropout_1 (Dropout) | (None, 256) | 0 |
| dense_2 (Dense) | (None, 128) | 32896 |
| dropout_2 (Dropout) | (None, 128) | 0 |
| dense_3 (Dense) | (None, 64) | 8256 |
| dropout_3 (Dropout) | (None, 64) | 0 |
| dense_4 (Dense) | (None, 1) | 65 |

Total params: 3616769 (13.80 MB)
Trainable params: 3615233 (13.79 MB)
Non-trainable params: 1536 (6.00 KB)

Rysunek 5.7. Architektura modelu sieci MLP wykorzystana do klasyfikacji płci mówcy na podstawie współczynników MFCC



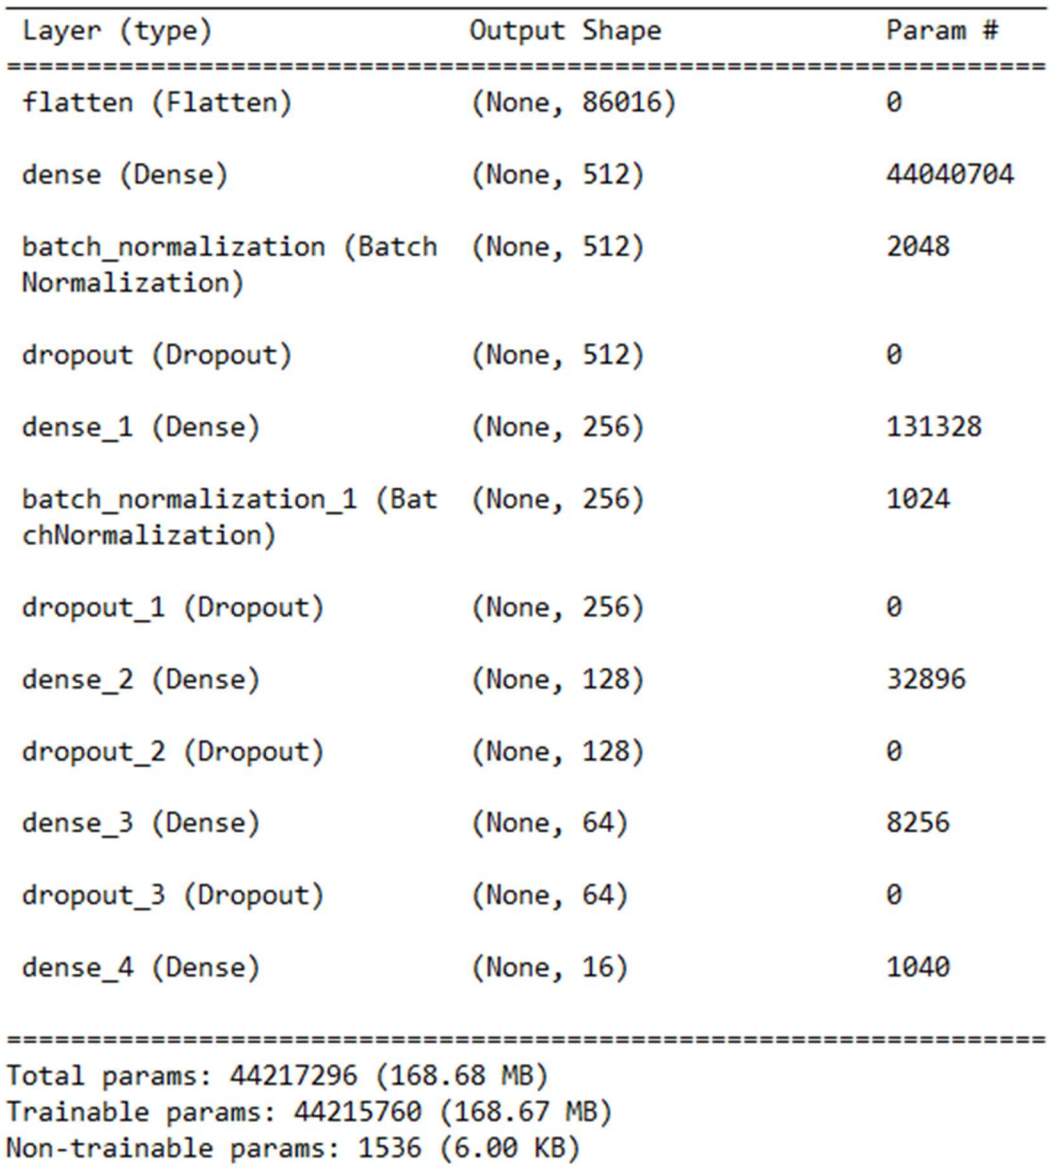

Rysunek 5.8. Architektura modelu sieci MLP wykorzystana do klasyfikacji grupy wiekowej mówcy na podstawie danych w skali Mel



| Layer (type) | Output Shape | Param # |
|---|---|---|
| flatten (Flatten) | (None, 6720) | 0 |
| dense (Dense) | (None, 512) | 3441152 |
| batch_normalization (BatchNormalization) | (None, 512) | 2048 |
| dropout (Dropout) | (None, 512) | 0 |
| dense_1 (Dense) | (None, 256) | 131328 |
| batch_normalization_1 (BatchNormalization) | (None, 256) | 1024 |
| dropout_1 (Dropout) | (None, 256) | 0 |
| dense_2 (Dense) | (None, 128) | 32896 |
| dropout_2 (Dropout) | (None, 128) | 0 |
| dense_3 (Dense) | (None, 64) | 8256 |
| dropout_3 (Dropout) | (None, 64) | 0 |
| dense_4 (Dense) | (None, 8) | 520 |

Total params: 3617224 (13.80 MB)
Trainable params: 3615688 (13.79 MB)
Non-trainable params: 1536 (6.00 KB)

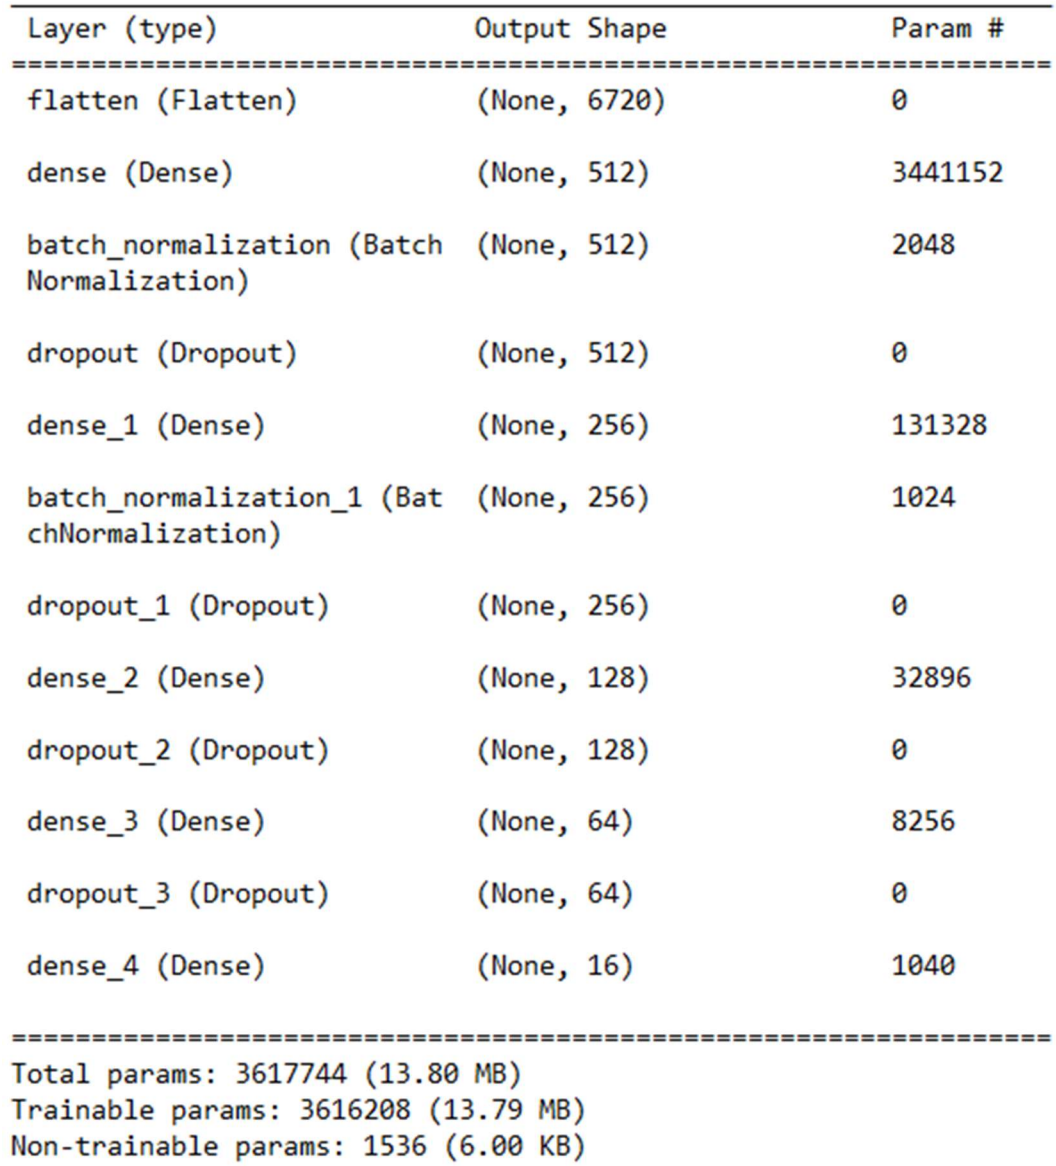
Rysunek 5.9. Architektura modelu sieci MLP wykorzystana do klasyfikacji grupy wiekowej mówcy na podstawie współczynników MFCC



| Layer (type) | Output Shape | Param # |
|---|---|---|
| flatten (Flatten) | (None, 86016) | 0 |
| dense (Dense) | (None, 512) | 44040704 |
| batch_normalization (BatchNormalization) | (None, 512) | 2048 |
| dropout (Dropout) | (None, 512) | 0 |
| dense_1 (Dense) | (None, 256) | 131328 |
| batch_normalization_1 (BatchNormalization) | (None, 256) | 1024 |
| dropout_1 (Dropout) | (None, 256) | 0 |
| dense_2 (Dense) | (None, 128) | 32896 |
| dropout_2 (Dropout) | (None, 128) | 0 |
| dense_3 (Dense) | (None, 64) | 8256 |
| dropout_3 (Dropout) | (None, 64) | 0 |
| dense_4 (Dense) | (None, 16) | 1040 |

Total params: 44217296 (168.68 MB)
Trainable params: 44215760 (168.67 MB)
Non-trainable params: 1536 (6.00 KB)

Rysunek 5.10. Architektura modelu sieci MLP wykorzystana do klasyfikacji akcentu języka angielskiego mówcy na podstawie danych w skali Mel



| Layer (type) | Output Shape | Param # |
|---|---|---|
| flatten (Flatten) | (None, 6720) | 0 |
| dense (Dense) | (None, 512) | 3441152 |
| batch_normalization (Batch Normalization) | (None, 512) | 2048 |
| dropout (Dropout) | (None, 512) | 0 |
| dense_1 (Dense) | (None, 256) | 131328 |
| batch_normalization_1 (BatchNormalization) | (None, 256) | 1024 |
| dropout_1 (Dropout) | (None, 256) | 0 |
| dense_2 (Dense) | (None, 128) | 32896 |
| dropout_2 (Dropout) | (None, 128) | 0 |
| dense_3 (Dense) | (None, 64) | 8256 |
| dropout_3 (Dropout) | (None, 64) | 0 |
| dense_4 (Dense) | (None, 16) | 1040 |

Total params: 3617744 (13.80 MB)
Trainable params: 3616208 (13.79 MB)
Non-trainable params: 1536 (6.00 KB)

Rysunek 5.11. Architektura modelu sieci MLP wykorzystana do klasyfikacji akcentu języka angielskiego mówcy na podstawie współczynników MFCC

```
Layer (type)                 Output Shape              Param #
=================================================================
conv2d (Conv2D)              (None, 128, 256, 32)      288

batch_normalization (Batch   (None, 128, 256, 32)      128
Normalization)

activation (Activation)      (None, 128, 256, 32)      0

max_pooling2d (MaxPooling2   (None, 64, 128, 32)       0
D)

conv2d_1 (Conv2D)            (None, 64, 128, 64)       18432

batch_normalization_1 (Bat   (None, 64, 128, 64)       256
chNormalization)

activation_1 (Activation)    (None, 64, 128, 64)       0

max_pooling2d_1 (MaxPoolin   (None, 32, 64, 64)        0
g2D)

conv2d_2 (Conv2D)            (None, 32, 64, 128)       73728

batch_normalization_2 (Bat   (None, 32, 64, 128)       512
chNormalization)

activation_2 (Activation)    (None, 32, 64, 128)       0

max_pooling2d_2 (MaxPoolin   (None, 16, 32, 128)       0
g2D)

conv2d_3 (Conv2D)            (None, 16, 32, 256)       294912

batch_normalization_3 (Bat   (None, 16, 32, 256)       1024
chNormalization)

activation_3 (Activation)    (None, 16, 32, 256)       0

global_average_pooling2d (   (None, 256)               0
GlobalAveragePooling2D)

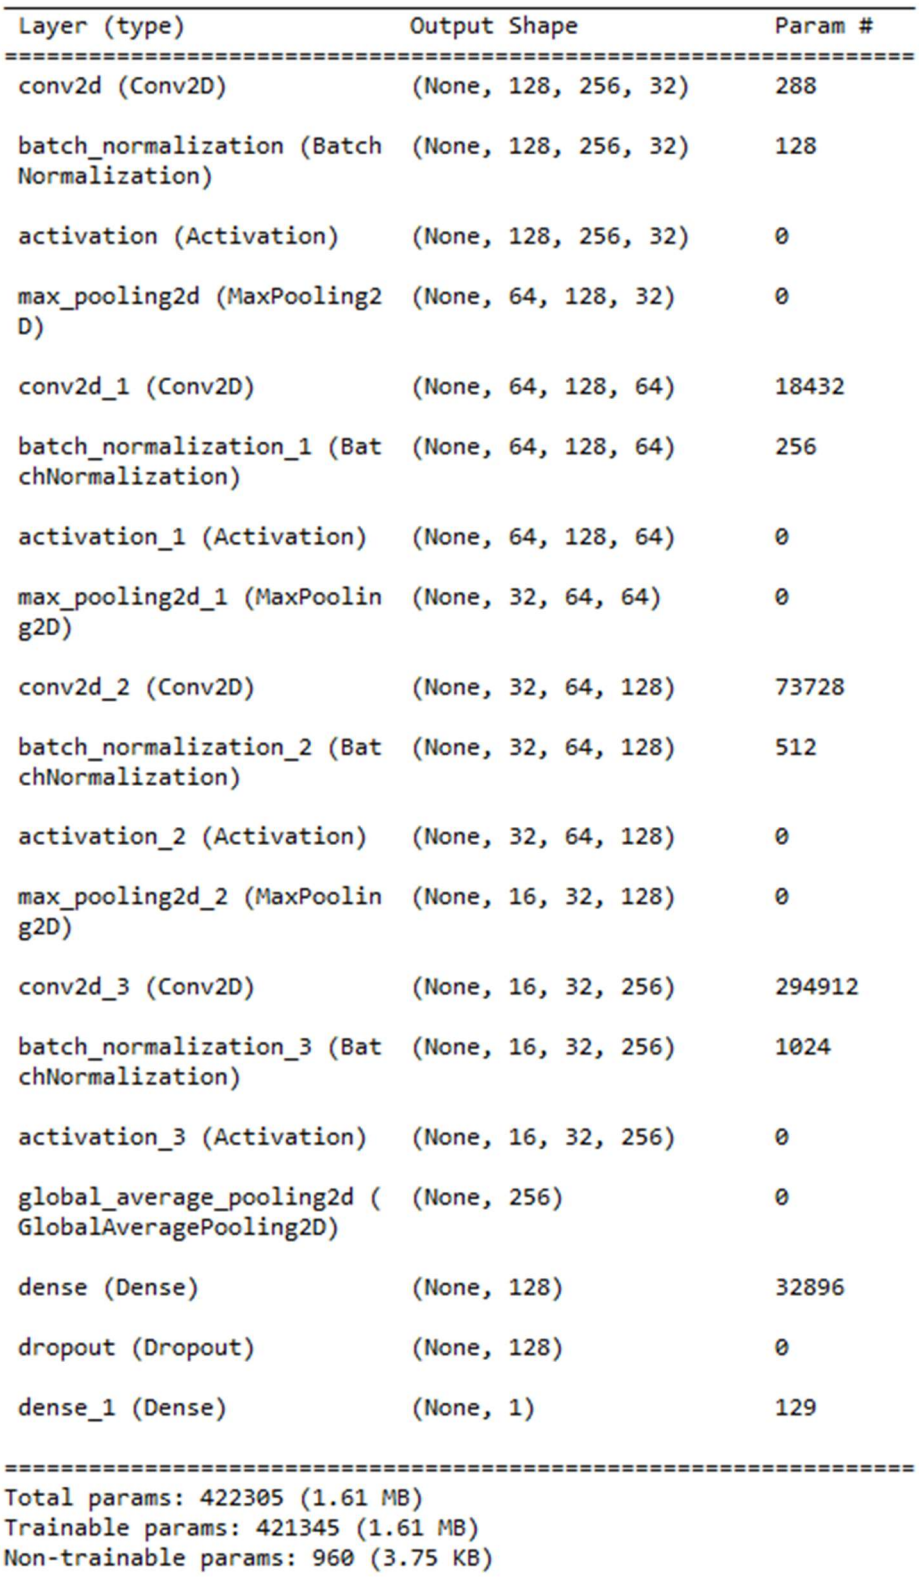
dense (Dense)                (None, 128)               32896

dropout (Dropout)            (None, 128)               0

dense_1 (Dense)              (None, 1)                 129

=================================================================
Total params: 422305 (1.61 MB)
Trainable params: 421345 (1.61 MB)
Non-trainable params: 960 (3.75 KB)
```

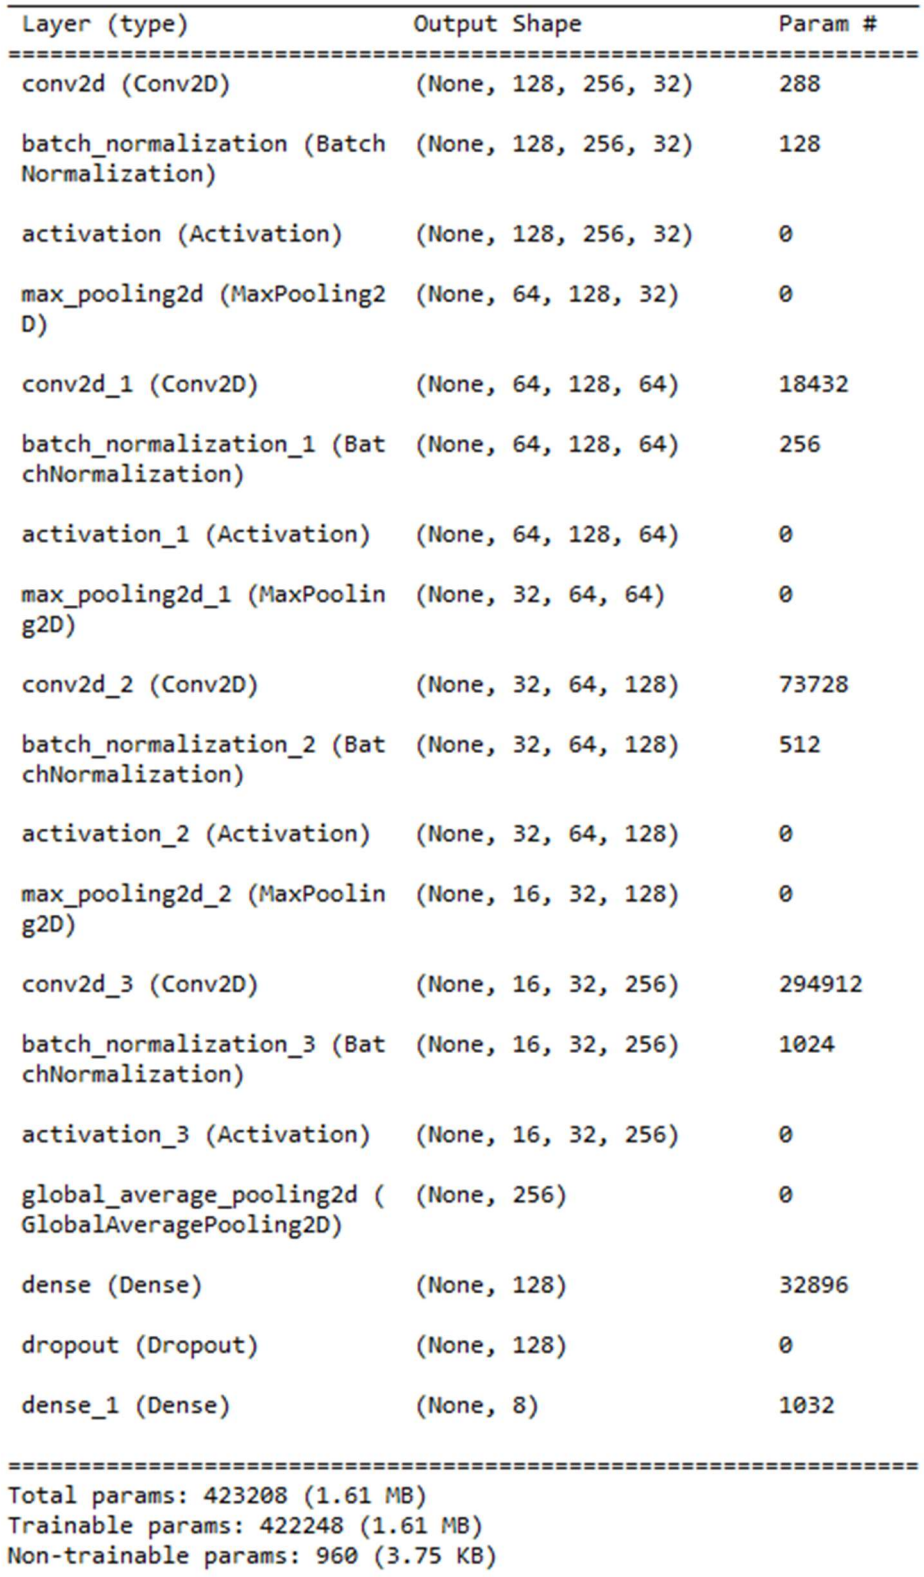
Rysunek 5.12. Architektura modelu sieci CNN wykorzystana do klasyfikacji płci mówcy na podstawie danych w skali Mel



| Layer (type) | Output Shape | Param # |
|---|---|---|
| conv2d (Conv2D) | (None, 128, 256, 32) | 288 |
| batch_normalization (BatchNormalization) | (None, 128, 256, 32) | 128 |
| activation (Activation) | (None, 128, 256, 32) | 0 |
| max_pooling2d (MaxPooling2D) | (None, 64, 128, 32) | 0 |
| conv2d_1 (Conv2D) | (None, 64, 128, 64) | 18432 |
| batch_normalization_1 (BatchNormalization) | (None, 64, 128, 64) | 256 |
| activation_1 (Activation) | (None, 64, 128, 64) | 0 |
| max_pooling2d_1 (MaxPooling2D) | (None, 32, 64, 64) | 0 |
| conv2d_2 (Conv2D) | (None, 32, 64, 128) | 73728 |
| batch_normalization_2 (BatchNormalization) | (None, 32, 64, 128) | 512 |
| activation_2 (Activation) | (None, 32, 64, 128) | 0 |
| max_pooling2d_2 (MaxPooling2D) | (None, 16, 32, 128) | 0 |
| conv2d_3 (Conv2D) | (None, 16, 32, 256) | 294912 |
| batch_normalization_3 (BatchNormalization) | (None, 16, 32, 256) | 1024 |
| activation_3 (Activation) | (None, 16, 32, 256) | 0 |
| global_average_pooling2d (GlobalAveragePooling2D) | (None, 256) | 0 |
| dense (Dense) | (None, 128) | 32896 |
| dropout (Dropout) | (None, 128) | 0 |
| dense_1 (Dense) | (None, 1) | 129 |

Total params: 422305 (1.61 MB)
Trainable params: 421345 (1.61 MB)
Non-trainable params: 960 (3.75 KB)

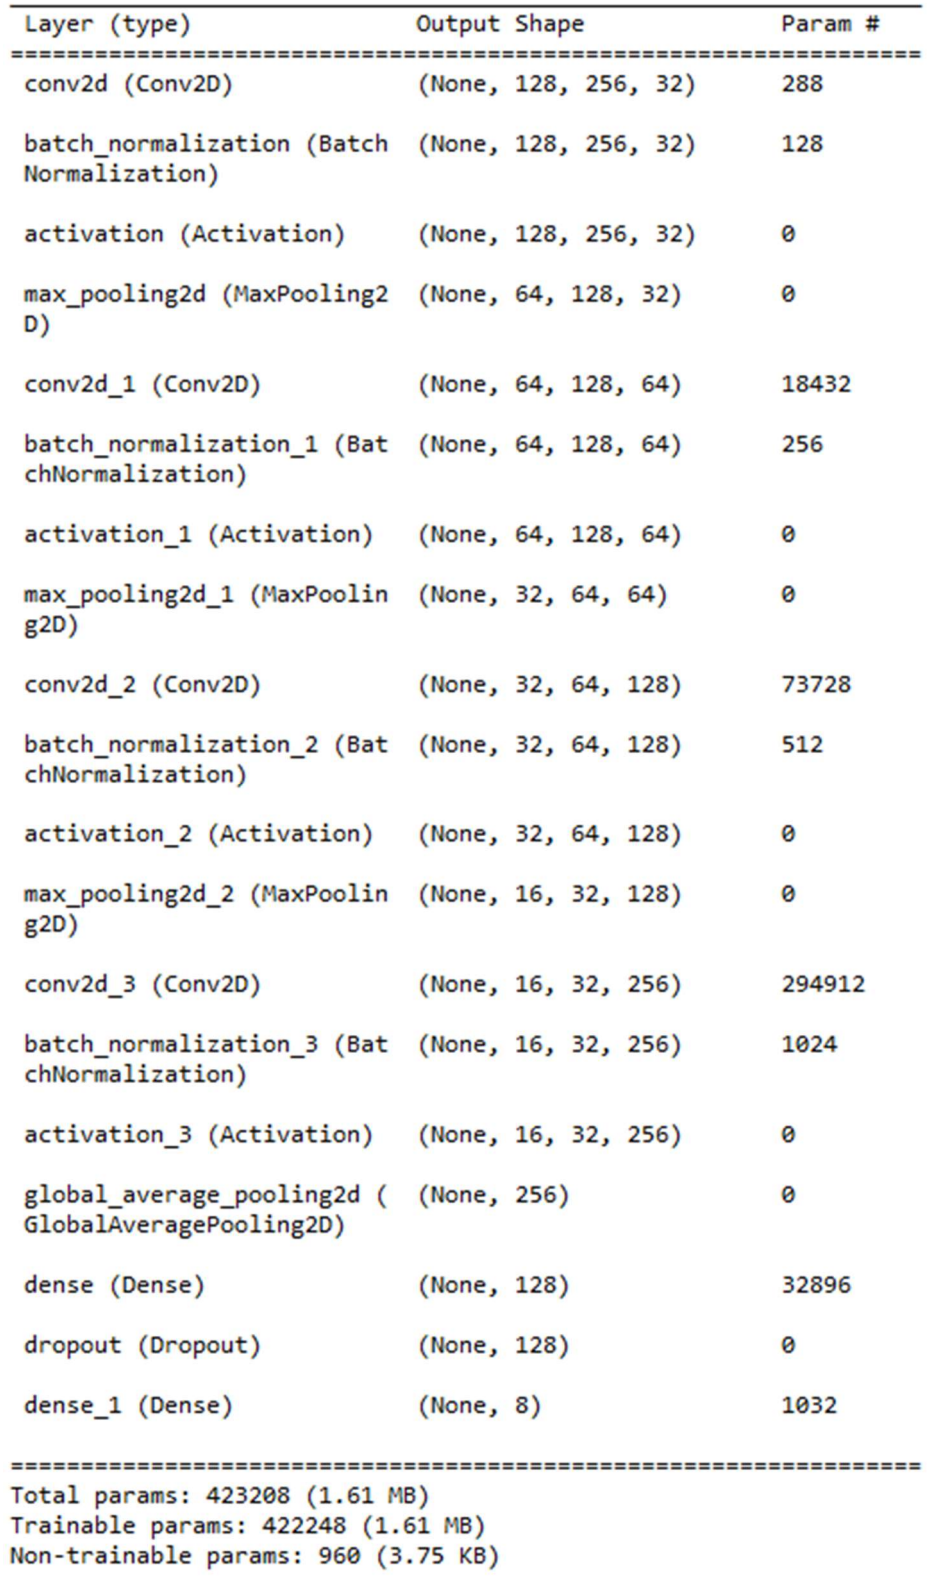
Rysunek 5.13. Architektura modelu sieci CNN wykorzystana do klasyfikacji płci mówcy na podstawie współczynników MFCC



| Layer (type) | Output Shape | Param # |
|---|---|---|
| conv2d (Conv2D) | (None, 128, 256, 32) | 288 |
| batch_normalization (BatchNormalization) | (None, 128, 256, 32) | 128 |
| activation (Activation) | (None, 128, 256, 32) | 0 |
| max_pooling2d (MaxPooling2D) | (None, 64, 128, 32) | 0 |
| conv2d_1 (Conv2D) | (None, 64, 128, 64) | 18432 |
| batch_normalization_1 (BatchNormalization) | (None, 64, 128, 64) | 256 |
| activation_1 (Activation) | (None, 64, 128, 64) | 0 |
| max_pooling2d_1 (MaxPooling2D) | (None, 32, 64, 64) | 0 |
| conv2d_2 (Conv2D) | (None, 32, 64, 128) | 73728 |
| batch_normalization_2 (BatchNormalization) | (None, 32, 64, 128) | 512 |
| activation_2 (Activation) | (None, 32, 64, 128) | 0 |
| max_pooling2d_2 (MaxPooling2D) | (None, 16, 32, 128) | 0 |
| conv2d_3 (Conv2D) | (None, 16, 32, 256) | 294912 |
| batch_normalization_3 (BatchNormalization) | (None, 16, 32, 256) | 1024 |
| activation_3 (Activation) | (None, 16, 32, 256) | 0 |
| global_average_pooling2d (GlobalAveragePooling2D) | (None, 256) | 0 |
| dense (Dense) | (None, 128) | 32896 |
| dropout (Dropout) | (None, 128) | 0 |
| dense_1 (Dense) | (None, 8) | 1032 |

Total params: 423208 (1.61 MB)
Trainable params: 422248 (1.61 MB)
Non-trainable params: 960 (3.75 KB)

Rysunek 5.14. Architektura modelu sieci CNN wykorzystana do klasyfikacji grupy wiekowej mówcy na podstawie danych w skali Mel



| Layer (type) | Output Shape | Param # |
|---|---|---|
| conv2d (Conv2D) | (None, 128, 256, 32) | 288 |
| batch_normalization (BatchNormalization) | (None, 128, 256, 32) | 128 |
| activation (Activation) | (None, 128, 256, 32) | 0 |
| max_pooling2d (MaxPooling2D) | (None, 64, 128, 32) | 0 |
| conv2d_1 (Conv2D) | (None, 64, 128, 64) | 18432 |
| batch_normalization_1 (BatchNormalization) | (None, 64, 128, 64) | 256 |
| activation_1 (Activation) | (None, 64, 128, 64) | 0 |
| max_pooling2d_1 (MaxPooling2D) | (None, 32, 64, 64) | 0 |
| conv2d_2 (Conv2D) | (None, 32, 64, 128) | 73728 |
| batch_normalization_2 (BatchNormalization) | (None, 32, 64, 128) | 512 |
| activation_2 (Activation) | (None, 32, 64, 128) | 0 |
| max_pooling2d_2 (MaxPooling2D) | (None, 16, 32, 128) | 0 |
| conv2d_3 (Conv2D) | (None, 16, 32, 256) | 294912 |
| batch_normalization_3 (BatchNormalization) | (None, 16, 32, 256) | 1024 |
| activation_3 (Activation) | (None, 16, 32, 256) | 0 |
| global_average_pooling2d (GlobalAveragePooling2D) | (None, 256) | 0 |
| dense (Dense) | (None, 128) | 32896 |
| dropout (Dropout) | (None, 128) | 0 |
| dense_1 (Dense) | (None, 8) | 1032 |

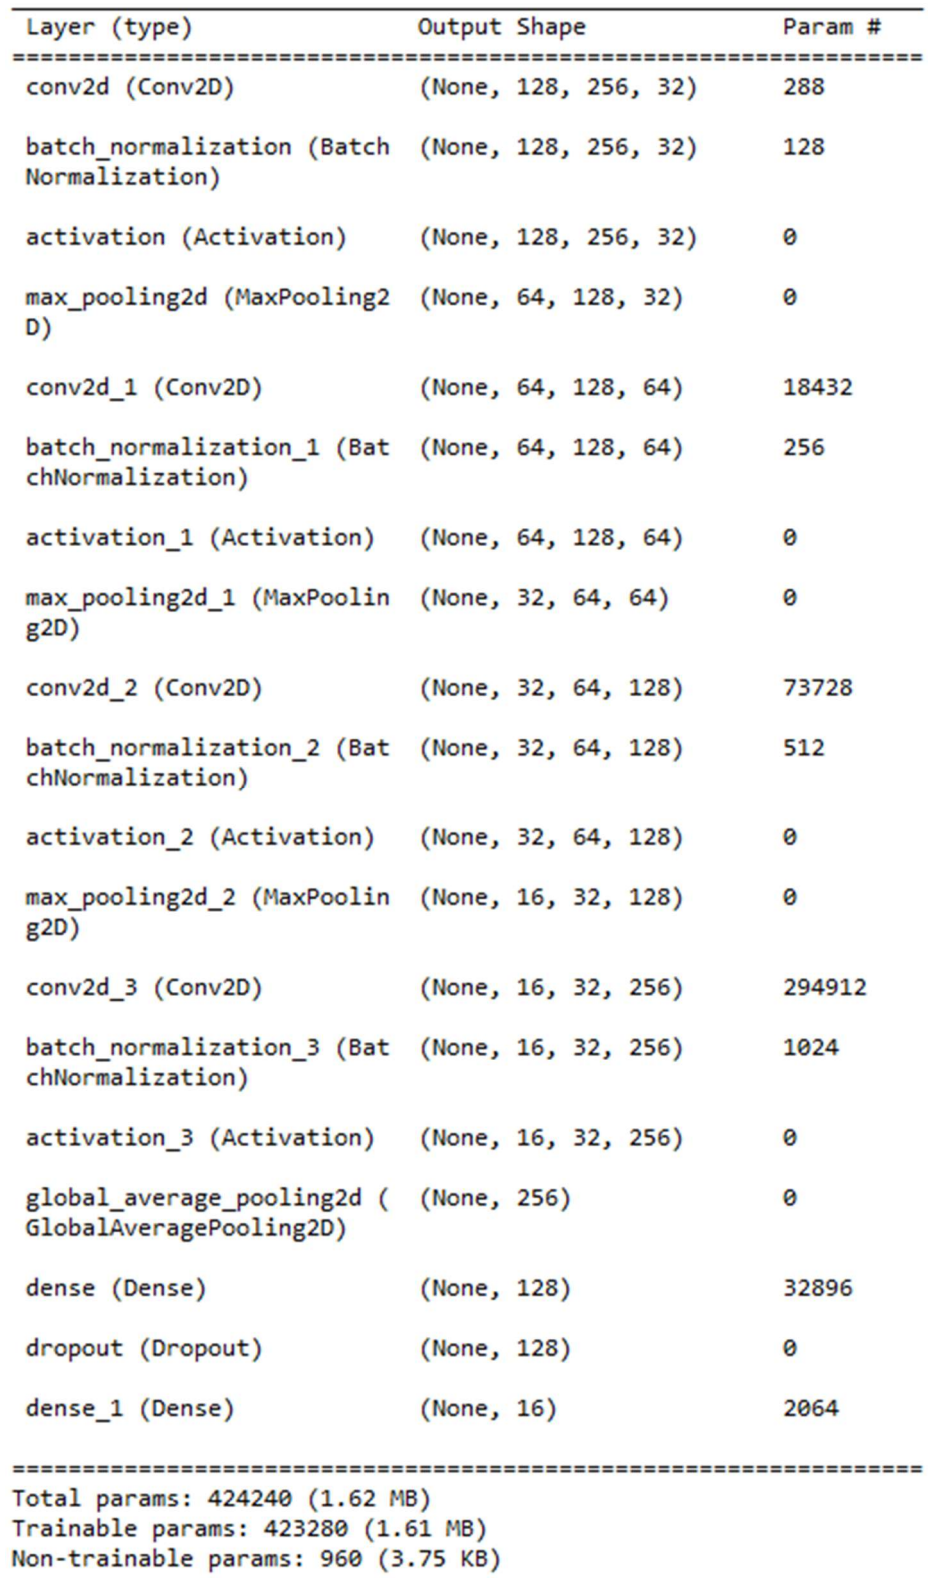
Total params: 423208 (1.61 MB)
Trainable params: 422248 (1.61 MB)
Non-trainable params: 960 (3.75 KB)

Rysunek 5.15. Architektura modelu sieci CNN wykorzystana do klasyfikacji grupy wiekowej mówcy na podstawie współczynników MFCC

| Layer (type) | Output Shape | Param # |
|---|---|---|
| conv2d (Conv2D) | (None, 128, 256, 32) | 288 |
| batch_normalization (BatchNormalization) | (None, 128, 256, 32) | 128 |
| activation (Activation) | (None, 128, 256, 32) | 0 |
| max_pooling2d (MaxPooling2D) | (None, 64, 128, 32) | 0 |
| conv2d_1 (Conv2D) | (None, 64, 128, 64) | 18432 |
| batch_normalization_1 (BatchNormalization) | (None, 64, 128, 64) | 256 |
| activation_1 (Activation) | (None, 64, 128, 64) | 0 |
| max_pooling2d_1 (MaxPooling2D) | (None, 32, 64, 64) | 0 |
| conv2d_2 (Conv2D) | (None, 32, 64, 128) | 73728 |
| batch_normalization_2 (BatchNormalization) | (None, 32, 64, 128) | 512 |
| activation_2 (Activation) | (None, 32, 64, 128) | 0 |
| max_pooling2d_2 (MaxPooling2D) | (None, 16, 32, 128) | 0 |
| conv2d_3 (Conv2D) | (None, 16, 32, 256) | 294912 |
| batch_normalization_3 (BatchNormalization) | (None, 16, 32, 256) | 1024 |
| activation_3 (Activation) | (None, 16, 32, 256) | 0 |
| global_average_pooling2d (GlobalAveragePooling2D) | (None, 256) | 0 |
| dense (Dense) | (None, 128) | 32896 |
| dropout (Dropout) | (None, 128) | 0 |
| dense_1 (Dense) | (None, 16) | 2064 |

Total params: 424240 (1.62 MB)
Trainable params: 423280 (1.61 MB)
Non-trainable params: 960 (3.75 KB)

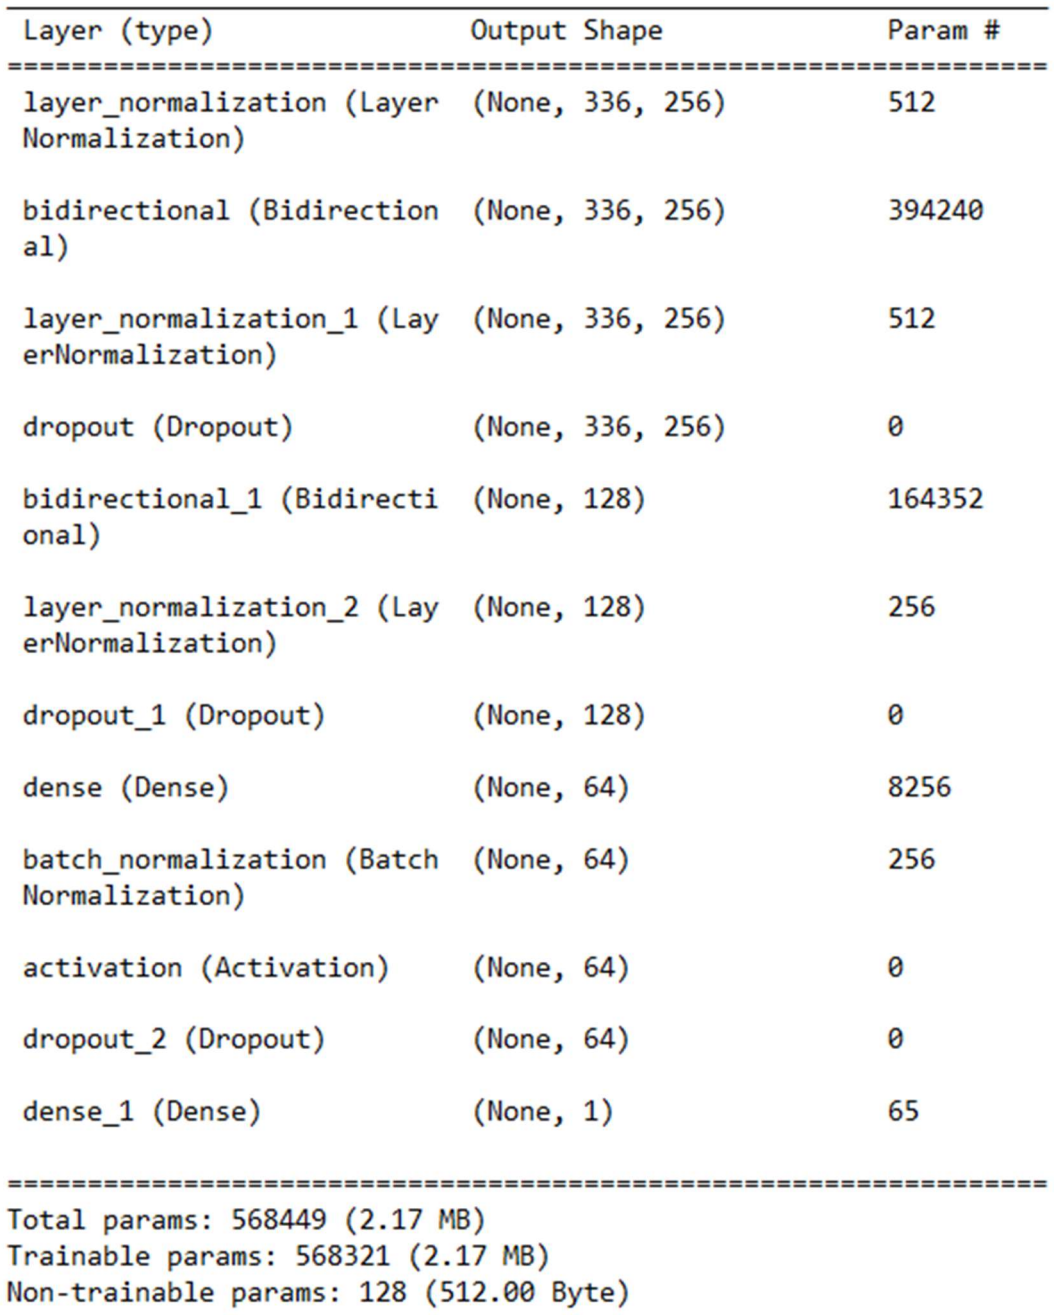
Rysunek 5.16. Architektura modelu sieci CNN wykorzystana do klasyfikacji akcentu języka angielskiego mówcy na podstawie danych w skali Mel



| Layer (type) | Output Shape | Param # |
|---|---|---|
| conv2d (Conv2D) | (None, 128, 256, 32) | 288 |
| batch_normalization (BatchNormalization) | (None, 128, 256, 32) | 128 |
| activation (Activation) | (None, 128, 256, 32) | 0 |
| max_pooling2d (MaxPooling2D) | (None, 64, 128, 32) | 0 |
| conv2d_1 (Conv2D) | (None, 64, 128, 64) | 18432 |
| batch_normalization_1 (BatchNormalization) | (None, 64, 128, 64) | 256 |
| activation_1 (Activation) | (None, 64, 128, 64) | 0 |
| max_pooling2d_1 (MaxPooling2D) | (None, 32, 64, 64) | 0 |
| conv2d_2 (Conv2D) | (None, 32, 64, 128) | 73728 |
| batch_normalization_2 (BatchNormalization) | (None, 32, 64, 128) | 512 |
| activation_2 (Activation) | (None, 32, 64, 128) | 0 |
| max_pooling2d_2 (MaxPooling2D) | (None, 16, 32, 128) | 0 |
| conv2d_3 (Conv2D) | (None, 16, 32, 256) | 294912 |
| batch_normalization_3 (BatchNormalization) | (None, 16, 32, 256) | 1024 |
| activation_3 (Activation) | (None, 16, 32, 256) | 0 |
| global_average_pooling2d (GlobalAveragePooling2D) | (None, 256) | 0 |
| dense (Dense) | (None, 128) | 32896 |
| dropout (Dropout) | (None, 128) | 0 |
| dense_1 (Dense) | (None, 16) | 2064 |

Total params: 424240 (1.62 MB)
Trainable params: 423280 (1.61 MB)
Non-trainable params: 960 (3.75 KB)

Rysunek 5.17. Architektura modelu sieci CNN wykorzystana do klasyfikacji akcentu języka angielskiego mówcy na podstawie współczynników MFCC



| Layer (type) | Output Shape | Param # |
|---|---|---|
| layer_normalization (LayerNormalization) | (None, 336, 256) | 512 |
| bidirectional (Bidirectional) | (None, 336, 256) | 394240 |
| layer_normalization_1 (LayerNormalization) | (None, 336, 256) | 512 |
| dropout (Dropout) | (None, 336, 256) | 0 |
| bidirectional_1 (Bidirectional) | (None, 128) | 164352 |
| layer_normalization_2 (LayerNormalization) | (None, 128) | 256 |
| dropout_1 (Dropout) | (None, 128) | 0 |
| dense (Dense) | (None, 64) | 8256 |
| batch_normalization (BatchNormalization) | (None, 64) | 256 |
| activation (Activation) | (None, 64) | 0 |
| dropout_2 (Dropout) | (None, 64) | 0 |
| dense_1 (Dense) | (None, 1) | 65 |

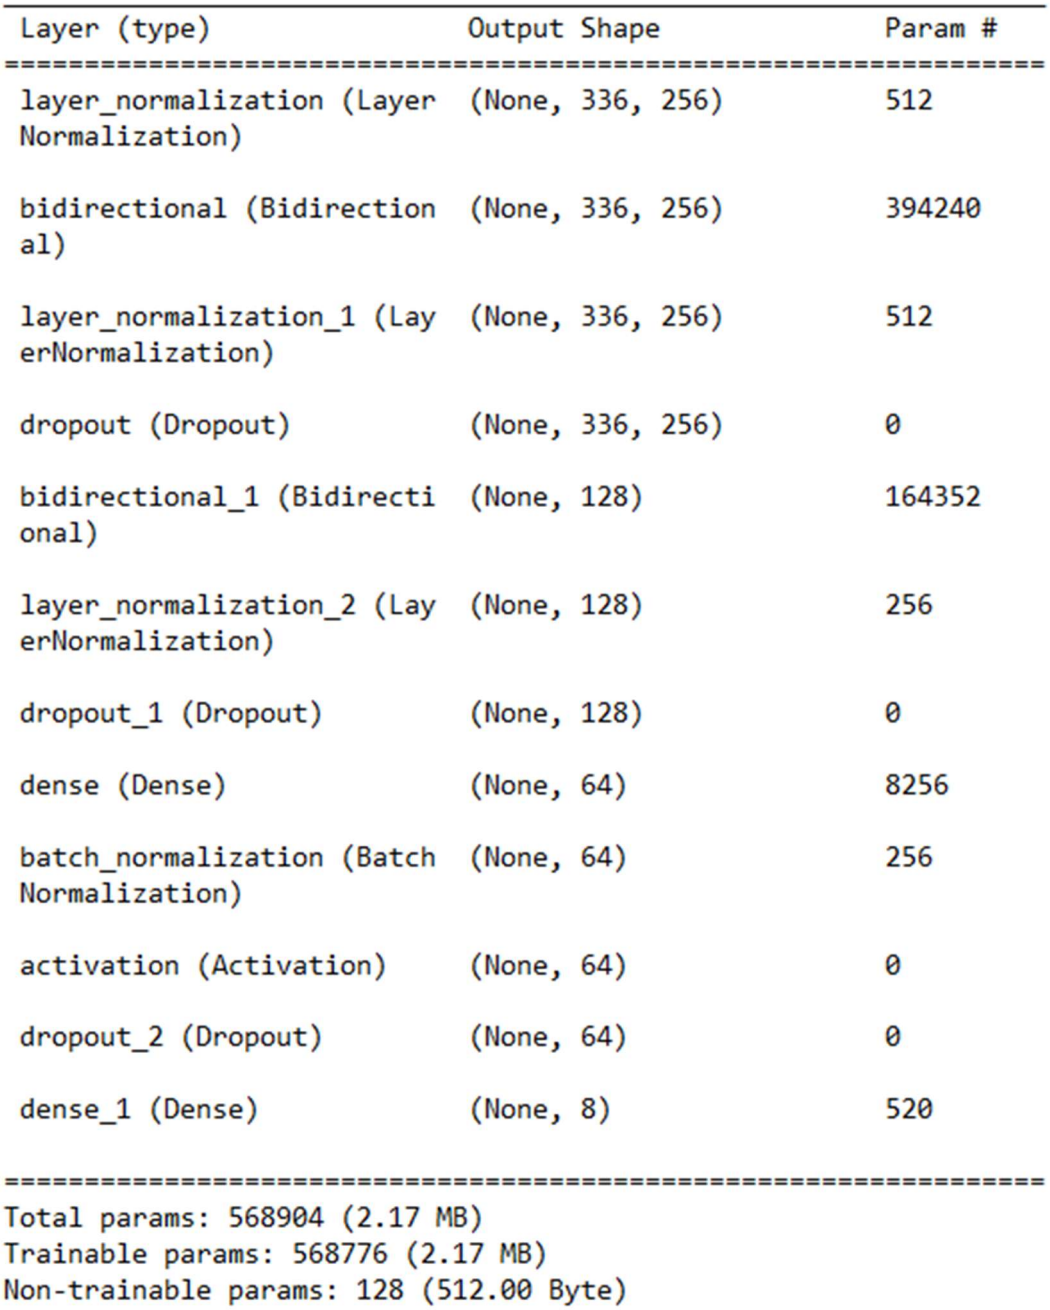
Total params: 568449 (2.17 MB)
Trainable params: 568321 (2.17 MB)
Non-trainable params: 128 (512.00 Byte)

Rysunek 5.18. Architektura modelu sieci Bi-LSTM wykorzystana do klasyfikacji płci mówcy na podstawie danych w skali Mel

| Layer (type) | Output Shape | Param # |
|---|---|---|
| layer_normalization (LayerNormalization) | (None, 336, 20) | 40 |
| bidirectional (Bidirectional) | (None, 336, 256) | 152576 |
| layer_normalization_1 (LayerNormalization) | (None, 336, 256) | 512 |
| dropout (Dropout) | (None, 336, 256) | 0 |
| bidirectional_1 (Bidirectional) | (None, 128) | 164352 |
| layer_normalization_2 (LayerNormalization) | (None, 128) | 256 |
| dropout_1 (Dropout) | (None, 128) | 0 |
| dense (Dense) | (None, 64) | 8256 |
| batch_normalization (BatchNormalization) | (None, 64) | 256 |
| activation (Activation) | (None, 64) | 0 |
| dropout_2 (Dropout) | (None, 64) | 0 |
| dense_1 (Dense) | (None, 1) | 65 |

Total params: 326313 (1.24 MB)
Trainable params: 326185 (1.24 MB)
Non-trainable params: 128 (512.00 Byte)

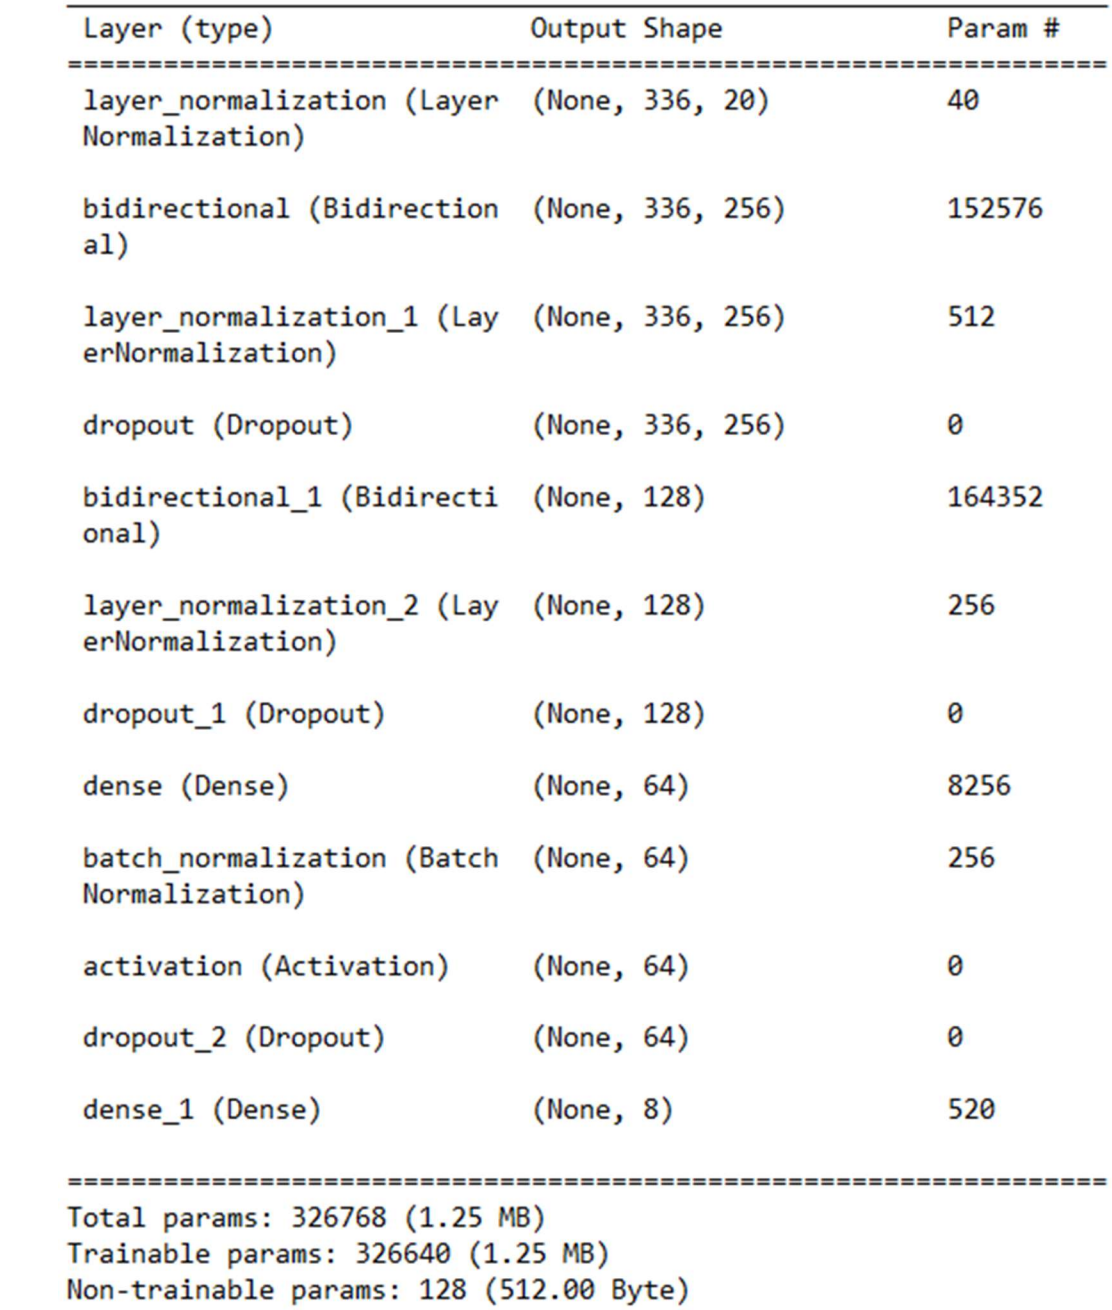
Rysunek 5.19. Architektura modelu sieci Bi-LSTM wykorzystana do klasyfikacji płci mówcy na podstawie współczynników MFCC



| Layer (type) | Output Shape | Param # |
|---|---|---|
| layer_normalization (LayerNormalization) | (None, 336, 256) | 512 |
| bidirectional (Bidirectional) | (None, 336, 256) | 394240 |
| layer_normalization_1 (LayerNormalization) | (None, 336, 256) | 512 |
| dropout (Dropout) | (None, 336, 256) | 0 |
| bidirectional_1 (Bidirectional) | (None, 128) | 164352 |
| layer_normalization_2 (LayerNormalization) | (None, 128) | 256 |
| dropout_1 (Dropout) | (None, 128) | 0 |
| dense (Dense) | (None, 64) | 8256 |
| batch_normalization (BatchNormalization) | (None, 64) | 256 |
| activation (Activation) | (None, 64) | 0 |
| dropout_2 (Dropout) | (None, 64) | 0 |
| dense_1 (Dense) | (None, 8) | 520 |

Total params: 568904 (2.17 MB)
Trainable params: 568776 (2.17 MB)
Non-trainable params: 128 (512.00 Byte)

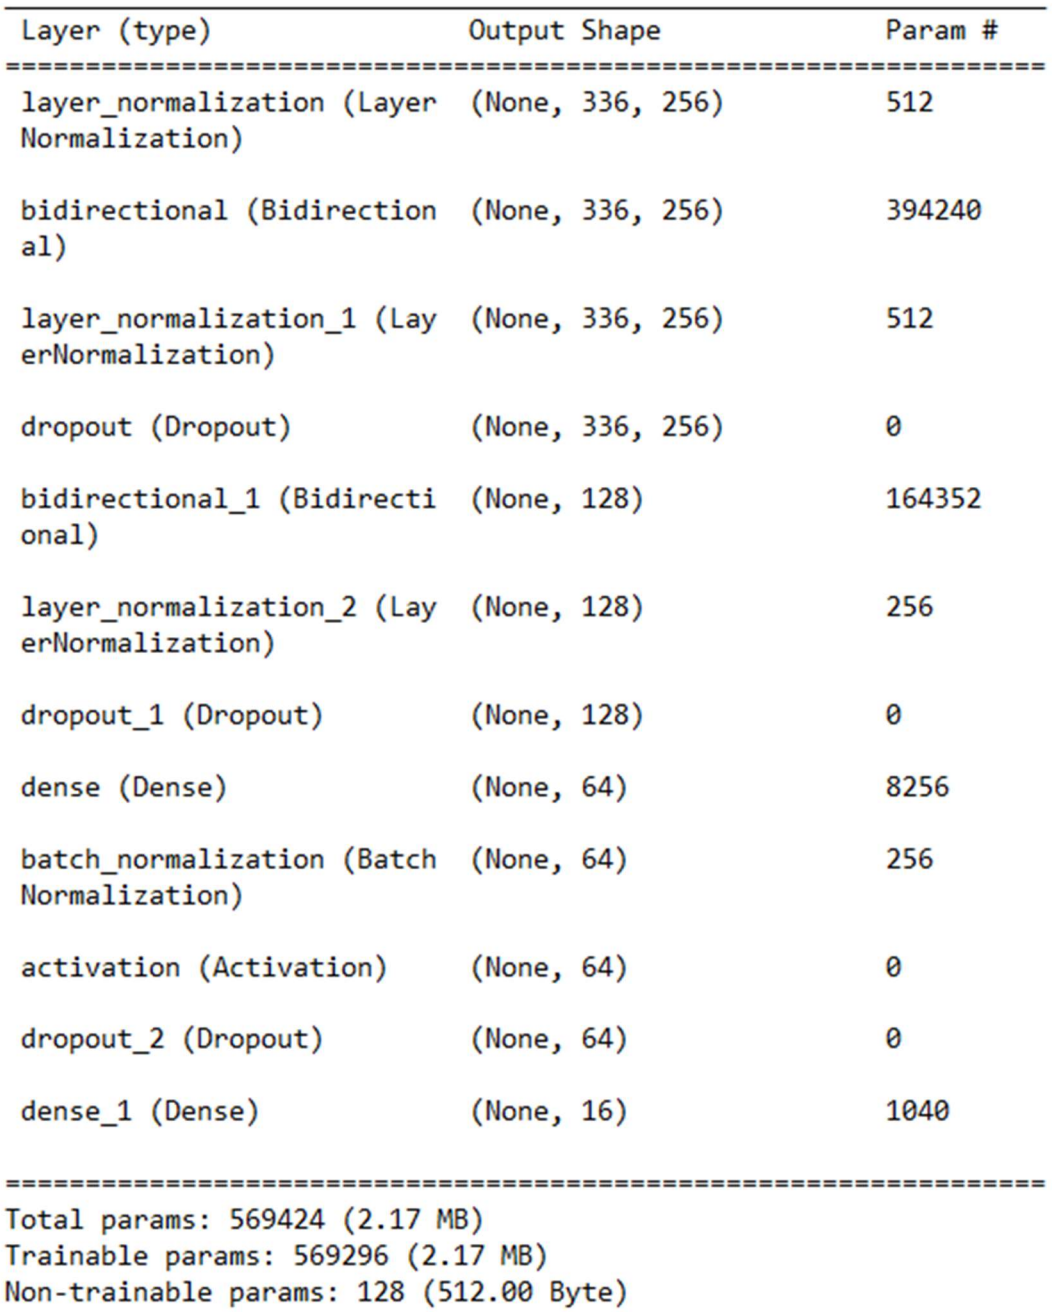
Rysunek 5.20. Architektura modelu sieci Bi-LSTM wykorzystana do klasyfikacji grupy wiekowej mówcy na podstawie danych w skali Mel



| Layer (type) | Output Shape | Param # |
|---|---|---|
| layer_normalization (LayerNormalization) | (None, 336, 20) | 40 |
| bidirectional (Bidirectional) | (None, 336, 256) | 152576 |
| layer_normalization_1 (LayerNormalization) | (None, 336, 256) | 512 |
| dropout (Dropout) | (None, 336, 256) | 0 |
| bidirectional_1 (Bidirectional) | (None, 128) | 164352 |
| layer_normalization_2 (LayerNormalization) | (None, 128) | 256 |
| dropout_1 (Dropout) | (None, 128) | 0 |
| dense (Dense) | (None, 64) | 8256 |
| batch_normalization (BatchNormalization) | (None, 64) | 256 |
| activation (Activation) | (None, 64) | 0 |
| dropout_2 (Dropout) | (None, 64) | 0 |
| dense_1 (Dense) | (None, 8) | 520 |

Total params: 326768 (1.25 MB)
Trainable params: 326640 (1.25 MB)
Non-trainable params: 128 (512.00 Byte)

Rysunek 5.21. Architektura modelu sieci Bi-LSTM wykorzystana do klasyfikacji grupy wiekowej mówcy na podstawie współczynników MFCC



| Layer (type) | Output Shape | Param # |
|---|---|---|
| layer_normalization (LayerNormalization) | (None, 336, 256) | 512 |
| bidirectional (Bidirectional) | (None, 336, 256) | 394240 |
| layer_normalization_1 (LayerNormalization) | (None, 336, 256) | 512 |
| dropout (Dropout) | (None, 336, 256) | 0 |
| bidirectional_1 (Bidirectional) | (None, 128) | 164352 |
| layer_normalization_2 (LayerNormalization) | (None, 128) | 256 |
| dropout_1 (Dropout) | (None, 128) | 0 |
| dense (Dense) | (None, 64) | 8256 |
| batch_normalization (BatchNormalization) | (None, 64) | 256 |
| activation (Activation) | (None, 64) | 0 |
| dropout_2 (Dropout) | (None, 64) | 0 |
| dense_1 (Dense) | (None, 16) | 1040 |

Total params: 569424 (2.17 MB)
Trainable params: 569296 (2.17 MB)
Non-trainable params: 128 (512.00 Byte)

Rysunek 5.22. Architektura modelu sieci Bi-LSTM wykorzystana do klasyfikacji akcentu języka angielskiego mówcy na podstawie danych w skali Mel

```
Layer (type)                 Output Shape              Param #
=================================================================
layer_normalization (Layer   (None, 336, 20)           40
Normalization)

bidirectional (Bidirection   (None, 336, 256)          152576
al)

layer_normalization_1 (Lay   (None, 336, 256)          512
erNormalization)

dropout (Dropout)            (None, 336, 256)          0

bidirectional_1 (Bidirecti   (None, 128)               164352
onal)

layer_normalization_2 (Lay   (None, 128)               256
erNormalization)

dropout_1 (Dropout)          (None, 128)               0

dense (Dense)                (None, 64)                8256

batch_normalization (Batch   (None, 64)                256
Normalization)

activation (Activation)      (None, 64)                0

dropout_2 (Dropout)          (None, 64)                0

dense_1 (Dense)              (None, 16)                1040

=================================================================
Total params: 327288 (1.25 MB)
Trainable params: 327160 (1.25 MB)
Non-trainable params: 128 (512.00 Byte)
```

Rysunek 5.23. Architektura modelu sieci Bi-LSTM wykorzystana do klasyfikacji akcentu języka angielskiego mówcy na podstawie współczynników MFCC

Podczas procesu uczenia modeli zastosowano mechanizm wczesnego zatrzymania (ang. Early Stopping), którego zadaniem było ograniczenie ryzyka przeuczenia modeli oraz skrócenie czasu obliczeń. Jako monitorowaną wartość przyjęto funkcję straty obliczoną na zbiorze walidacyjnym, a proces uczenia był zatrzymywany, jeżeli przez 10 kolejnych epok nie następowała poprawa tej wartości. Dodatkowo zastosowano mechanizm zapisu najlepszego modelu (ang. Model Checkpoint), który zapisywał model uzyskujący najlepszą wartość funkcji straty na zbiorze walidacyjnym. Dzięki temu do dalszej oceny można było

wykorzystać model charakteryzujący się najlepszym wynikiem walidacyjnym, a nie tylko model uzyskany w ostatniej epoce procesu uczenia.

Na tak zaimplementowanych modelach sieci neuronowych przeprowadzono proces ich uczenia z wykorzystaniem środowiska WSL (Windows Subsystem for Linux) z systemem Ubuntu oraz akceleracją obliczeń przy użyciu GPU. Wszystkie opracowane modele zostały wytrenowane w tych samych warunkach środowiskowych, co pozwoliło na zachowanie porównywalnych warunków przeprowadzania eksperymentów.

### 5.6. Metody oceny modeli

W celu porównania skuteczności opracowanych architektur, wyniki modeli poddano analizie wykorzystując metryki oceny klasyfikacji. Dla wszystkich 18 modeli wyznaczono podstawowe miary przedstawiane w raporcie klasyfikacji oraz wygenerowano macierze pomyłek. Uzyskane wyniki posłużyły do oceny jakości klasyfikacji poszczególnych cech mówcy oraz porównania skuteczności badanych modeli.

Źródłem wzorów na metryki jakości klasyfikacji jest praca [19], a te wykorzystane w procesie badawczym wypisane są poniżej:

- dokładność (ang. accuracy) - określa, jaka część wszystkich przypadków została poprawnie sklasyfikowana przez model. Wyrażana jest przez wzór:

$$dokładność = \frac{TP + TN}{TP + TN + FP + FN} \tag{5.1}$$

- precyzja (ang. precision) - określa, jaka część przypadków przypisanych przez model do danej klasy rzeczywiście do niej należy. Wyrażana jest przez wzór:

$$precyzja = \frac{TP}{TP + FP} \tag{5.2}$$

- czułość (ang. recall lub sensitivity) - określa, jaka część wszystkich rzeczywistych przypadków należących do klasy pozytywnej została poprawnie rozpoznana przez model. Wyrażana jest przez wzór:

$$czułość = \frac{TP}{TP + FN} \tag{5.3}$$

- specyficzność (ang. specificity) – określa, jaka część wszystkich rzeczywistych przypadków należących do klasy negatywnej została poprawnie rozpoznana przez model. Jest to w zasadzie czułość dla klasy negatywnej. Wyrażona jest przez wzór:

$$specyficzność = \frac{TN}{TN + FP} \tag{5.4}$$

- wskaźnik F1 (ang. F1 score) - stanowi średnią harmoniczną precyzji i czułości, łącząc obie te miary w jeden wskaźnik. Wyrażana jest przez wzór:

$$F1 = 2 \cdot \frac{precyzja \cdot czułość}{precyzja + czułość} \tag{5.5}$$

gdzie:

- TP (ang. True Positive) - liczba przypadków, które model poprawnie zaklasyfikował jako należące do klasy pozytywnej,
- TN (ang. True Negative) - liczba przypadków, które model poprawnie zaklasyfikował jako należące do klasy negatywnej,
- FP (ang. False Positive) - liczba przypadków należących do klasy negatywnej, które model błędnie zaklasyfikował jako należące do klasy pozytywnej,
- FN (ang. False Negative) - liczba przypadków należących do klasy pozytywnej, które model błędnie zaklasyfikował jako należące do klasy negatywnej.

Przedstawione powyżej cztery podstawowe wyniki klasyfikacji TP, TN, FP i FN można zwizualizować za pomocą macierzy pomyłek. Macierz ta (tabela 5.6) przedstawia w formie tabeli zależność pomiędzy klasami rzeczywistymi, a klasami przewidzianymi przez model.

Tabela 5.6. Macierz pomyłek dla klasyfikacji binarnej

| | | **Przewidziane klasy** | |
|---|---|---|---|
| | | **Pozytywne** | **Negatywne** |
| **Rzeczywiste klasy** | **Pozytywne** | Prawdziwie pozytywne (TP) | Fałszywie negatywne (FN) |
| | **Negatywne** | Fałszywie pozytywne (FP) | Prawdziwie negatywne (TN) |

Przedstawiona macierz pomyłek obrazuje przykład klasyfikacji binarnej, w której występują dwie klasy. W przypadku klasyfikacji wieloklasowej macierz pomyłek zawiera większą liczbę wierszy i kolumn, odpowiadającą liczbie rozpoznawanych klas. Wartości na przekątnej macierzy oznaczają poprawne klasyfikacje, natomiast wartości poza przekątną wskazują przypadki błędnie zaklasyfikowane do innych klas. Na podstawie takiej macierzy dla każdej klasy można wyznaczyć wartości TP, TN, FP i FN, traktując analizowaną klasę jako klasę pozytywną, a wszystkie pozostałe klasy jako negatywne.

W przeprowadzonych badaniach macierze pomyłek przedstawiono z zastosowaniem normalizacji wierszowej (ang. Row Normalization). W takim przypadku wartości w macierzy wyrażane są w postaci procentowej, a nie jako bezwzględna liczba obserwacji. Normalizacja wykonywana jest niezależnie dla każdego wiersza, który odpowiada jednej z rzeczywistych klas, dzięki czemu suma wartości w każdym wierszu wynosi 100%. Oznacza to, że poszczególne wartości przedstawiają udział procentowy przypadków należących do danej rzeczywistej klasy, które zostały przypisane przez model do poszczególnych klas. Zastosowanie normalizacji wierszowej ułatwia porównanie skuteczności klasyfikacji pomiędzy poszczególnymi klasami, szczególnie w przypadku niezbalansowanego zbioru danych. Przedstawienie wyników w postaci wartości

procentowych ogranicza wpływ różnic w liczebności klas i pozwala ocenić, jaka część przypadków z każdej klasy została poprawnie rozpoznana przez model.

W przypadku klasyfikacji wieloklasowej raport klasyfikacji zawiera również wartości uśrednione dla wszystkich klas. Uśrednianie makroskopowe polega na obliczeniu średniej arytmetycznej wartości danej miary dla wszystkich klas, dzięki czemu każda z nich ma taki sam wpływ na wynik końcowy, niezależnie od swojej liczebności. Makroskopowa średnia ważona uwzględnia natomiast liczebność poszczególnych klas, przez co klasy zawierające większą liczbę przypadków mają większy wpływ na uzyskaną wartość. Zastosowanie obu sposobów uśredniania jest szczególnie istotne w przypadku niezbalansowanego zbioru danych, ponieważ pozwala z jednej strony ocenić skuteczność modelu przy jednakowym traktowaniu wszystkich klas, a z drugiej uwzględnić rzeczywisty rozkład liczby przypadków pomiędzy klasami. Uśrednione miary jakości zawarte są w raporcie klasyfikacji dla metryk precyzji, czułości oraz wskaźnika F1.

# 6. Przeprowadzone badania i wyniki

## 6.1. Organizacja badań i przeprowadzenie eksperymentów

W ramach przeprowadzonych badań wykonano eksperymenty z wykorzystaniem 18 opracowanych modeli uczenia maszynowego. Eksperymenty przeprowadzono zgodnie z metodą badań przedstawioną we wcześniejszym rozdziale. Poszczególne modele różniły się zastosowaną reprezentacją danych wejściowych oraz wykorzystaną architekturą sieci neuronowej. Wykonano po jednym eksperymencie dla każdej sieci neuronowej przy użyciu jednego podziału danych na treningowe, testowe i walidacyjne, opisanego w metodologii.

Badania obejmowały trzy zadania klasyfikacyjne związane z rozpoznawaniem płci, wieku oraz akcentu języka angielskiego mówcy. Dla każdego z tych zadań wykorzystano modele, dla których jako dane wejściowe zastosowano reprezentację sygnału w skali Mel oraz współczynniki cepstralne w skali Mel (MFCC).

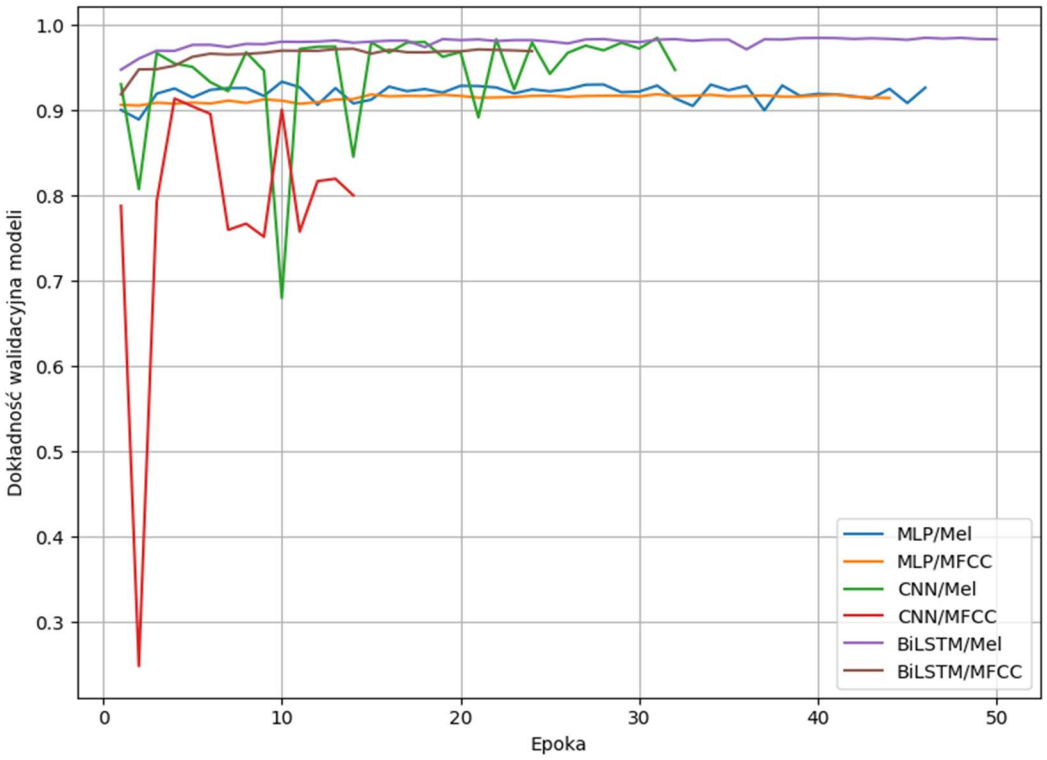
W ramach obu grup wykorzystano trzy typy architektur sieci neuronowych:

- wielowarstwowe perceptrony (MLP),
- splotowe sieci neuronowe (CNN),
- dwukierunkowe rekurencyjne sieci neuronowe typu LSTM (Bi-LSTM).

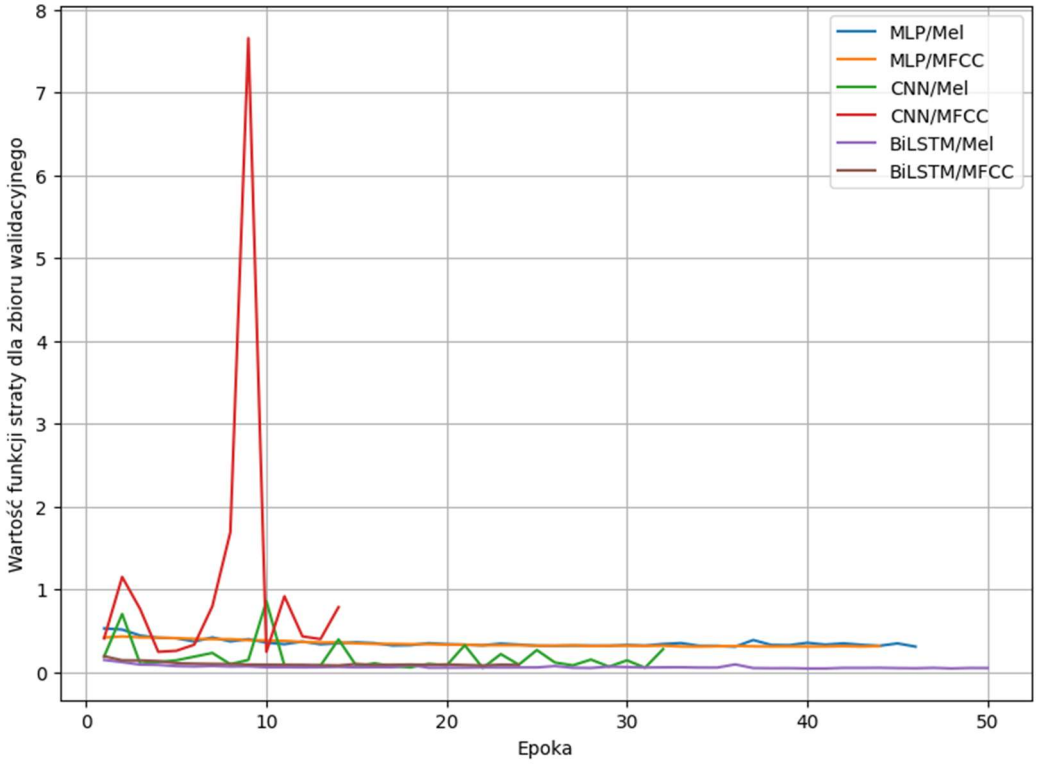
Dla każdego modelu przeprowadzono proces uczenia, a następnie wyznaczono wyniki klasyfikacji na zbiorze testowym. Uzyskane rezultaty przedstawiono za pomocą podstawowych miar klasyfikacyjnych oraz macierzy pomyłek. W dalszej części rozdziału przedstawiono wyniki uzyskane dla poszczególnych zadań klasyfikacyjnych.

## 6.2. Wyniki rozpoznawania płci mówcy

W pierwszej kolejności analizie została poddana cecha płci mówcy. Proces uczenia modeli przedstawiono na rysunkach 6.1-6.2, na których pokazano odpowiednio dokładność klasyfikacji oraz wartość funkcji straty uzyskiwane na zbiorze walidacyjnym w kolejnych epokach.




Rysunek 6.1. Przebieg dokładności klasyfikacji na zbiorze walidacyjnym dla modeli rozpoznających płeć mówcy



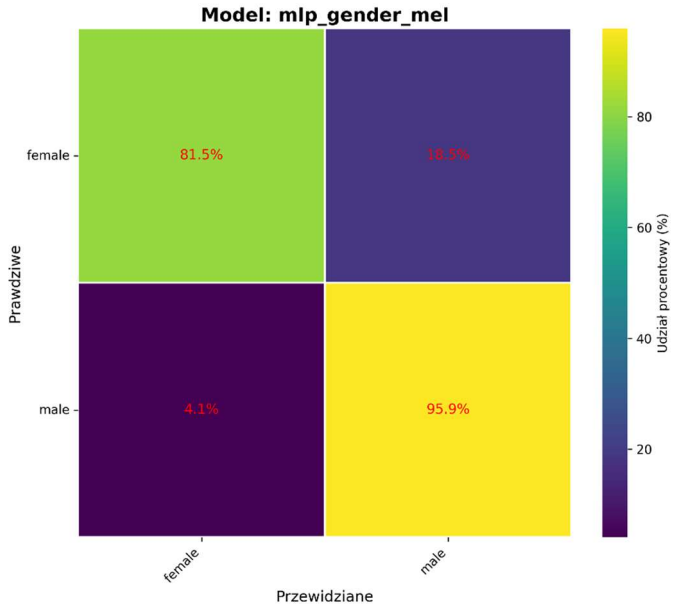

Rysunek 6.2. Przebieg wartości funkcji straty na zbiorze walidacyjnym dla modeli rozpoznających płeć mówcy

Porównując przebieg procesu uczenia poszczególnych modeli, można zauważyć, że architektury MLP i Bi-LSTM charakteryzowały się stabilnym przebiegiem procesu uczenia, podczas gdy w przypadku modeli CNN występowały wyraźne wahania wyników walidacyjnych. W celu szczegółowej oceny skuteczności poszczególnych modeli przeanalizowano wyniki klasyfikacji uzyskane na zbiorze testowym. Zestawienie wartości uzyskanych miar przedstawiono w tabeli 6.1.

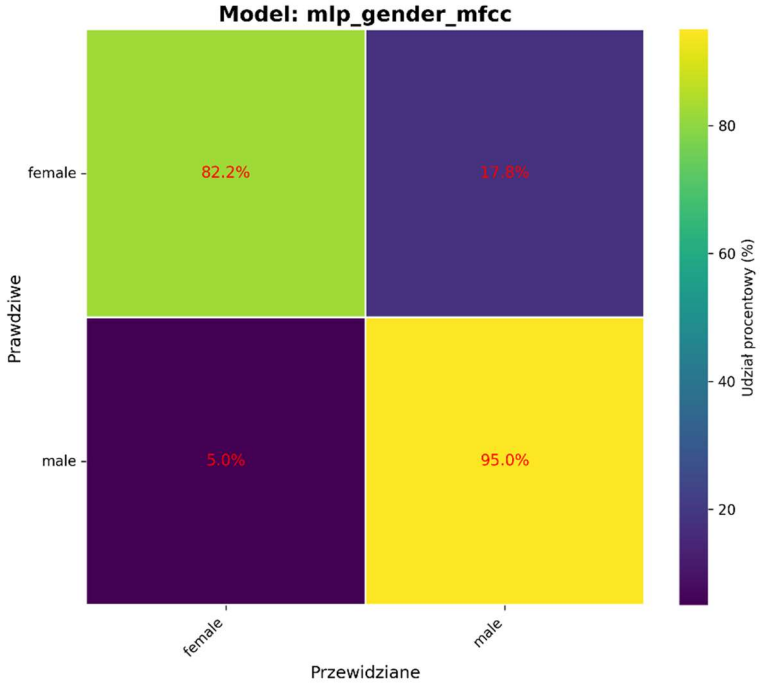
Tabela 6.1. Miary jakości klasyfikacji płci mówców dla badanych modeli

| | **Poszczególne modele** | | | | | |
|---|---|---|---|---|---|---|
| **Metryki** | **MLP Mel** | **MLP MFCC** | **CNN Mel** | **CNN MFCC** | **Bi-LSTM Mel** | **Bi-LSTM MFCC** |
| Dokładność | 0.923 | 0.918 | 0.983 | 0.913 | 0.983 | 0.968 |
| Precyzja | 0.940 | 0.941 | 0.990 | 0.940 | 0.988 | 0.981 |
| Czułość | 0.958 | 0.950 | 0.987 | 0.945 | 0.989 | 0.976 |
| Specyficzność | 0.815 | 0.822 | 0.971 | 0.819 | 0.964 | 0.945 |
| Wskaźnik F1 | 0.949 | 0.945 | 0.988 | 0.942 | 0.988 | 0.978 |

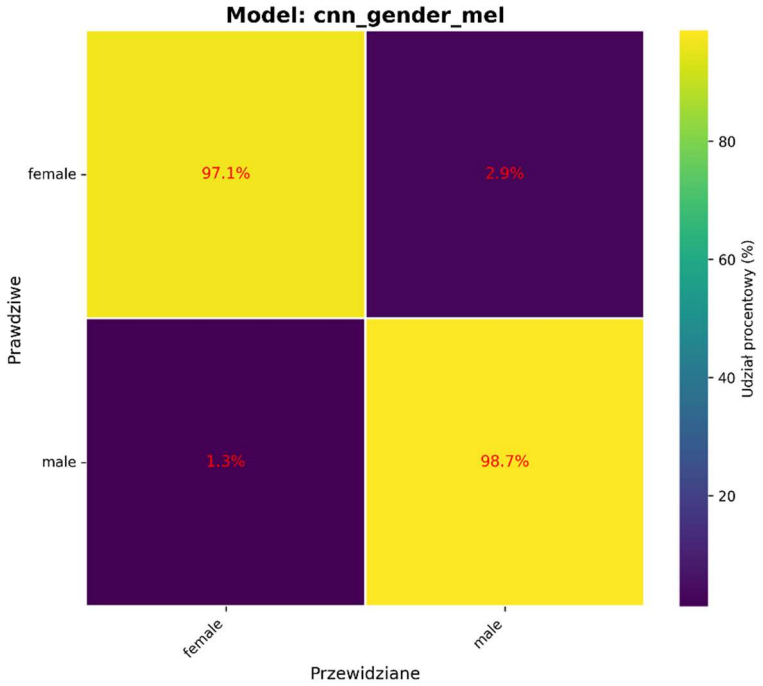
Przedstawione wartości pozwalają na ogólną ocenę skuteczności poszczególnych modeli, jednak nie pokazują, dla których klas występowały błędy klasyfikacji. W celu dokładniejszej analizy uzyskanych wyników sporządzono znormalizowane macierze pomyłek przedstawione na rysunkach 6.3-6.8.



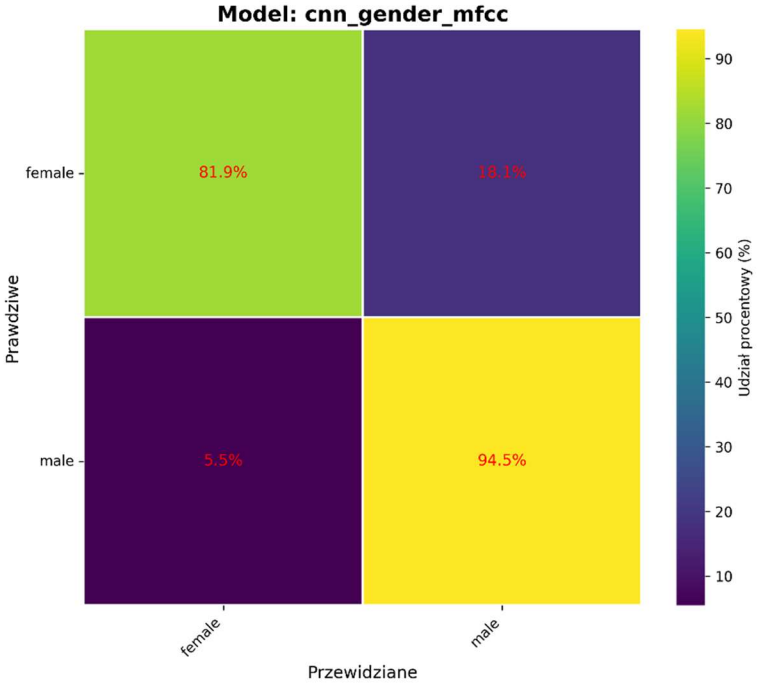

Rysunek 6.3. Znormalizowana macierz pomyłek dla modelu MLP/Mel rozpoznającego płeć mówcy



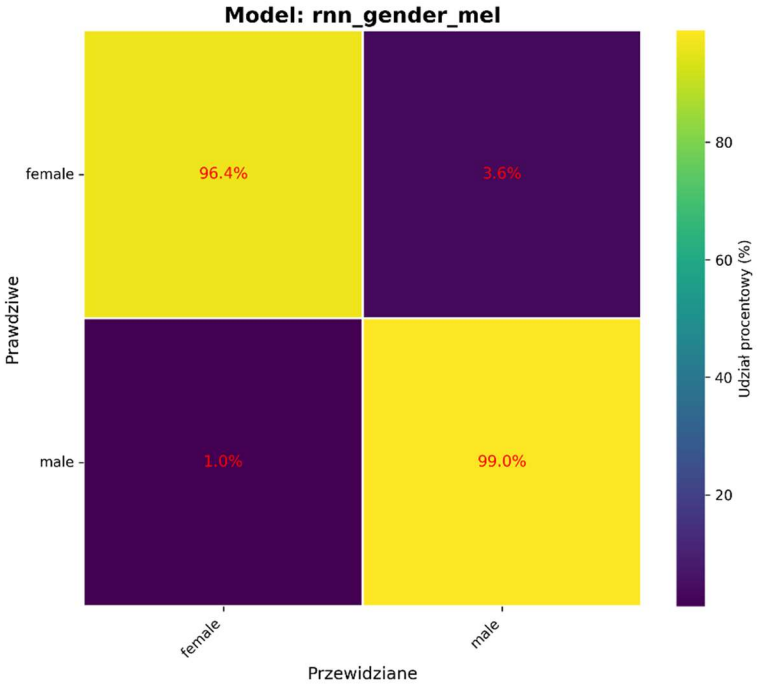

Rysunek 6.4. Znormalizowana macierz pomyłek dla modelu MLP/MFCC rozpoznającego płeć mówcy



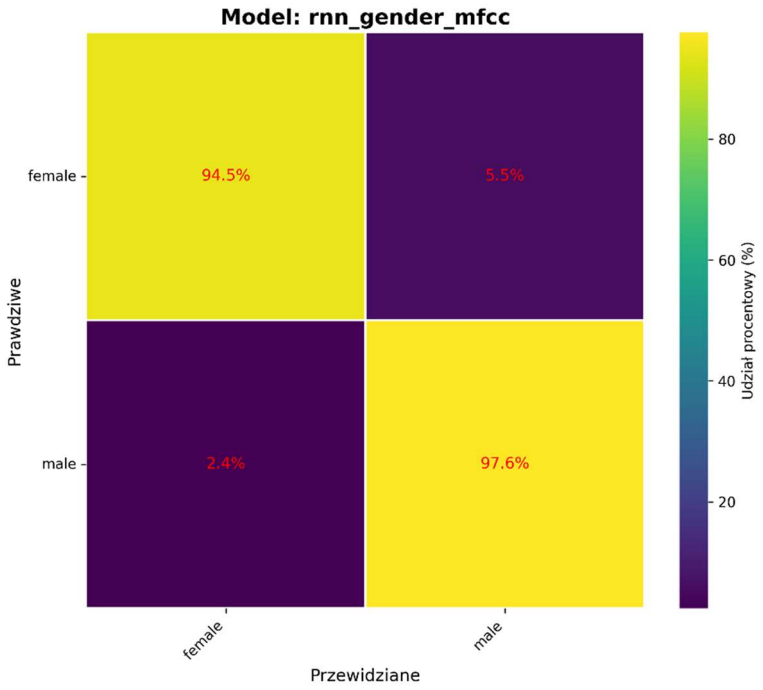

Rysunek 6.5. Znormalizowana macierz pomyłek dla modelu CNN/Mel rozpoznającego płeć mówcy




Rysunek 6.6. Znormalizowana macierz pomyłek dla modelu CNN/MFCC rozpoznającego płeć mówcy




Rysunek 6.7. Znormalizowana macierz pomyłek dla modelu Bi-LSTM/Mel rozpoznającego płeć mówcy

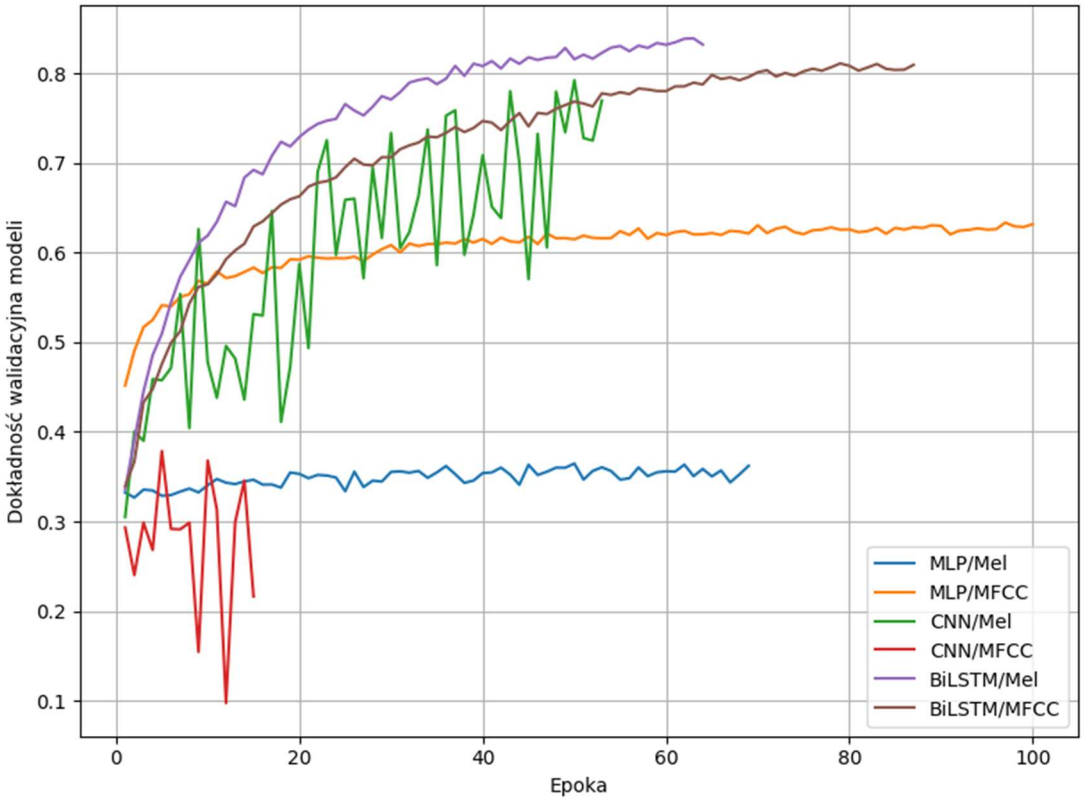



Rysunek 6.8. Znormalizowana macierz pomyłek dla modelu Bi-LSTM/MFCC rozpoznającego płeć mówcy

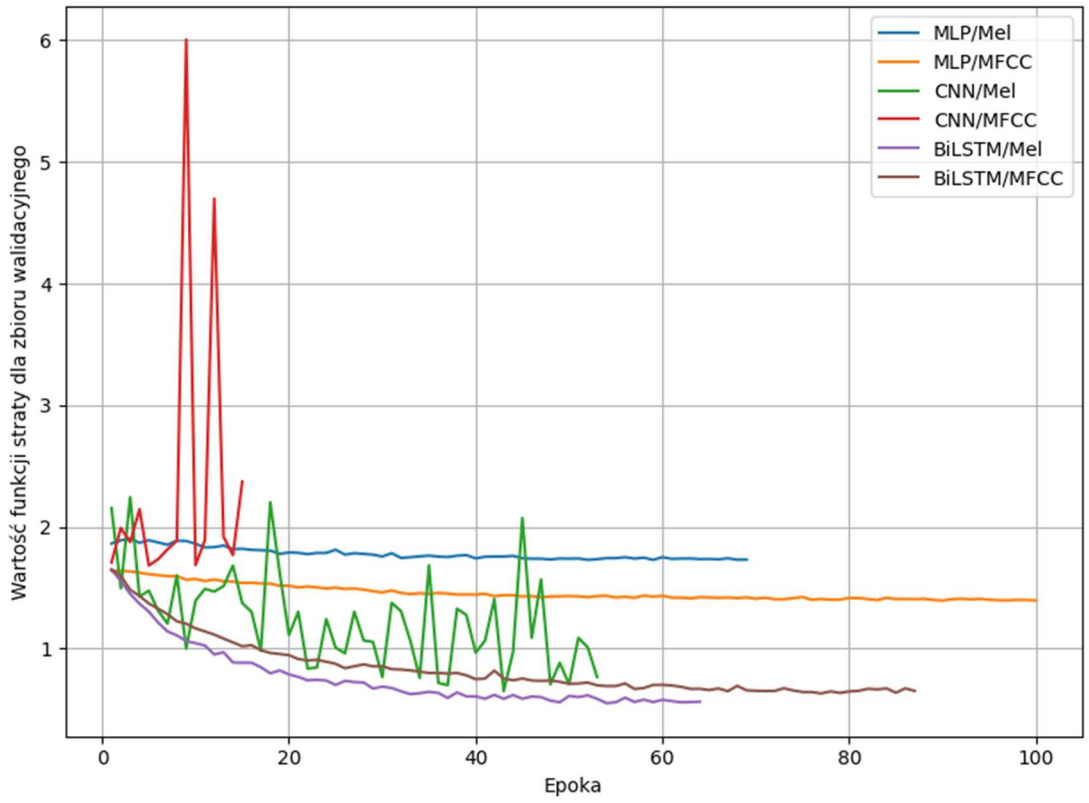
Analiza macierzy pomyłek zwraca uwagę na wysoką skuteczność obu modeli Bi-LSTM oraz jednego z modeli CNN bazującego na reprezentacji Mel, które poprawnie rozpoznawały około 95–97% przypadków należących do klasy kobiet oraz około 97–99% przypadków należących do klasy mężczyzn. W przypadku drugiego modelu sieci CNN oraz modeli MLP częściej występowały błędne klasyfikacje. W przypadku każdego z tych modeli około 18% głosów kobiet zostało błędnie zaklasyfikowanych jako głosy mężczyzn.

## 6.3. Wyniki rozpoznawania wieku mówcy

W dalszej części przeanalizowano wyniki uzyskane dla poszczególnych modeli w ramach rozpoznawania analizowanej cechy mówcy. Rysunki 6.9-6.10 przedstawiają przebieg przeprowadzonych procesów uczenia dla poszczególnych modeli.




Rysunek 6.9. Przebieg dokładności klasyfikacji na zbiorze walidacyjnym dla modeli rozpoznających wiek mówcy




Rysunek 6.10. Przebieg wartości funkcji straty na zbiorze walidacyjnym dla modeli rozpoznających wiek mówcy

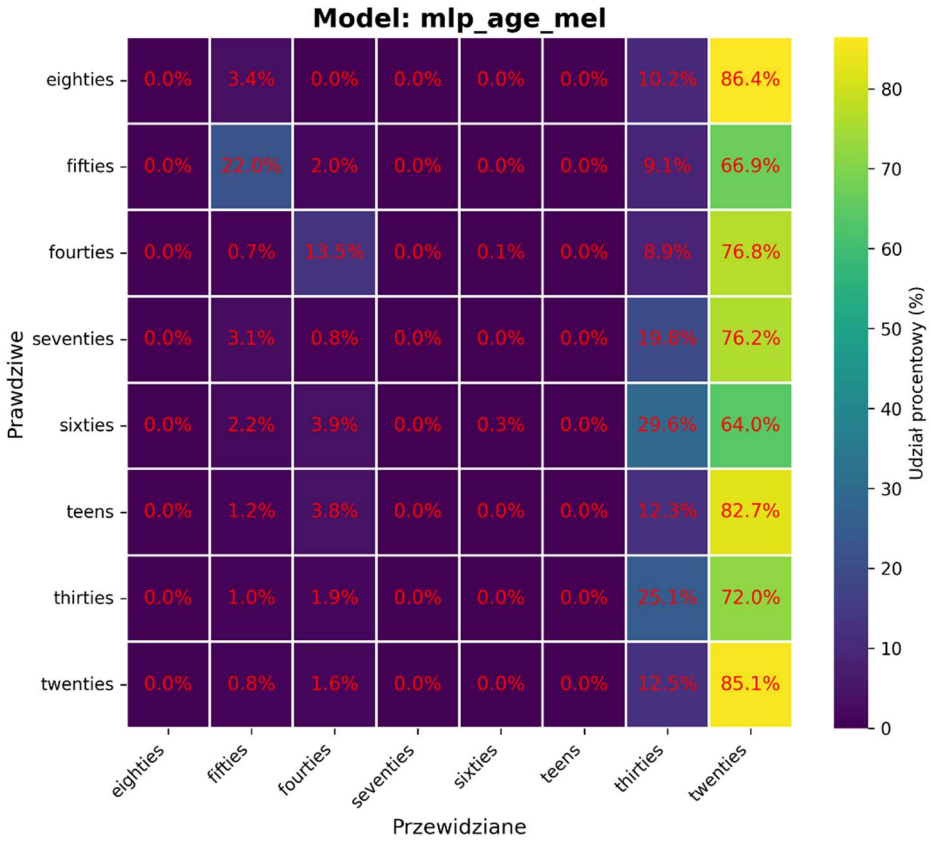
Analizując przebieg procesu uczenia, można zauważyć, że modele Bi-LSTM charakteryzowały się stabilnymi wartościami dokładności oraz funkcji straty na zbiorze walidacyjnym. Dokładność walidacyjna dla tych modeli utrzymywała się na poziomie około 0,80–0,85. Proces uczenia modeli MLP również przebiegał w sposób stabilny, jednak uzyskiwały one wyraźnie niższą dokładność oraz większe wartości funkcji straty. Największą niestabilność przebiegu procesu uczenia zaobserwowano w przypadku modeli CNN, dla których wartości uzyskiwane na zbiorze walidacyjnym wyraźnie zmieniały się pomiędzy kolejnymi epokami.

Dla każdego z badanych modeli wyznaczono wartości poszczególnych miar klasyfikacyjnych. Z uwagi na to, że eksperyment obejmował klasyfikację wieloklasową, dla miar precyzji, czułości oraz wskaźnika F1 zastosowano uśrednienie makroskopowe oraz makroskopową średnią ważoną tych metryk. Uzyskane wyniki przedstawiono w tabeli 6.2.

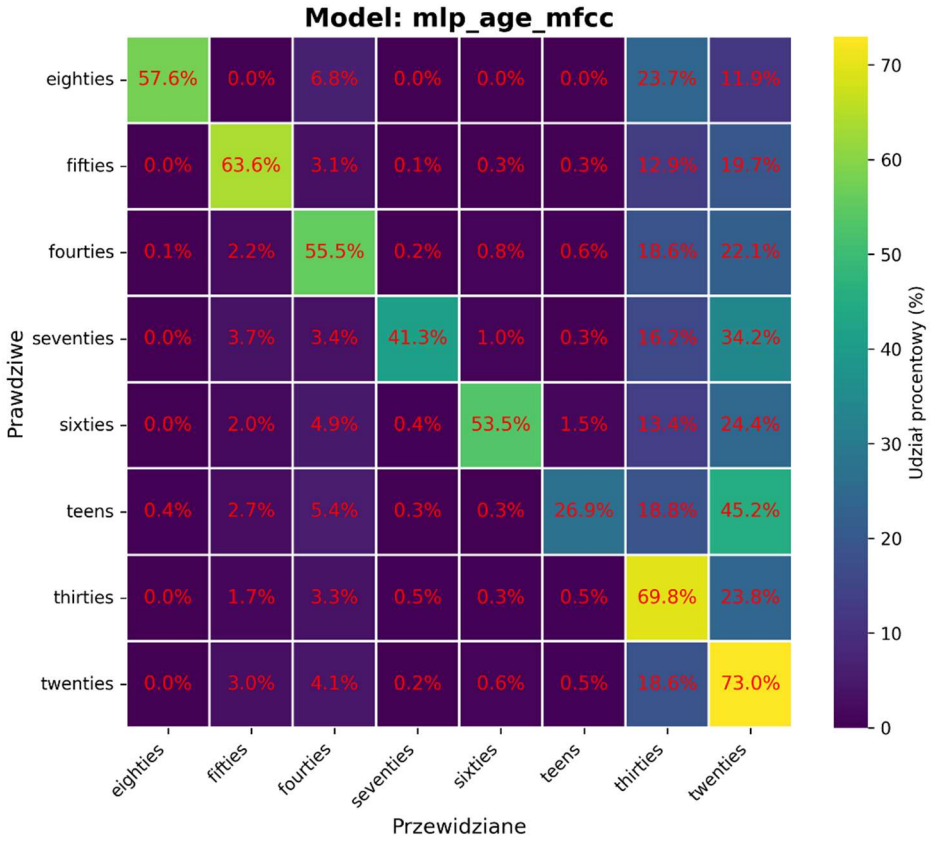
Tabela 6.2. Miary jakości klasyfikacji wieku mówców dla badanych modeli

| | **Poszczególne modele** | | | | | |
|---|---|---|---|---|---|---|
| **Metryki** | **MLP Mel** | **MLP MFCC** | **CNN Mel** | **CNN MFCC** | **Bi-LSTM Mel** | **Bi-LSTM MFCC** |
| Dokładność | 0.36 | 0.63 | 0.78 | 0.38 | 0.84 | 0.80 |
| Precyzja (średnia makro) | 0.31 | 0.74 | 0.78 | 0.28 | 0.82 | 0.77 |
| Precyzja (średnia ważona) | 0.42 | 0.67 | 0.79 | 0.44 | 0.84 | 0.81 |
| Czułość (średnia makro) | 0.18 | 0.55 | 0.74 | 0.20 | 0.83 | 0.80 |
| Czułość (średnia ważona) | 0.36 | 0.63 | 0.78 | 0.38 | 0.84 | 0.80 |
| Wskaźnik F1 (średnia makro) | 0.17 | 0.61 | 0.74 | 0.18 | 0.82 | 0.78 |
| Wskaźnik F1 (średnia ważona) | 0.30 | 0.63 | 0.78 | 0.31 | 0.84 | 0.80 |

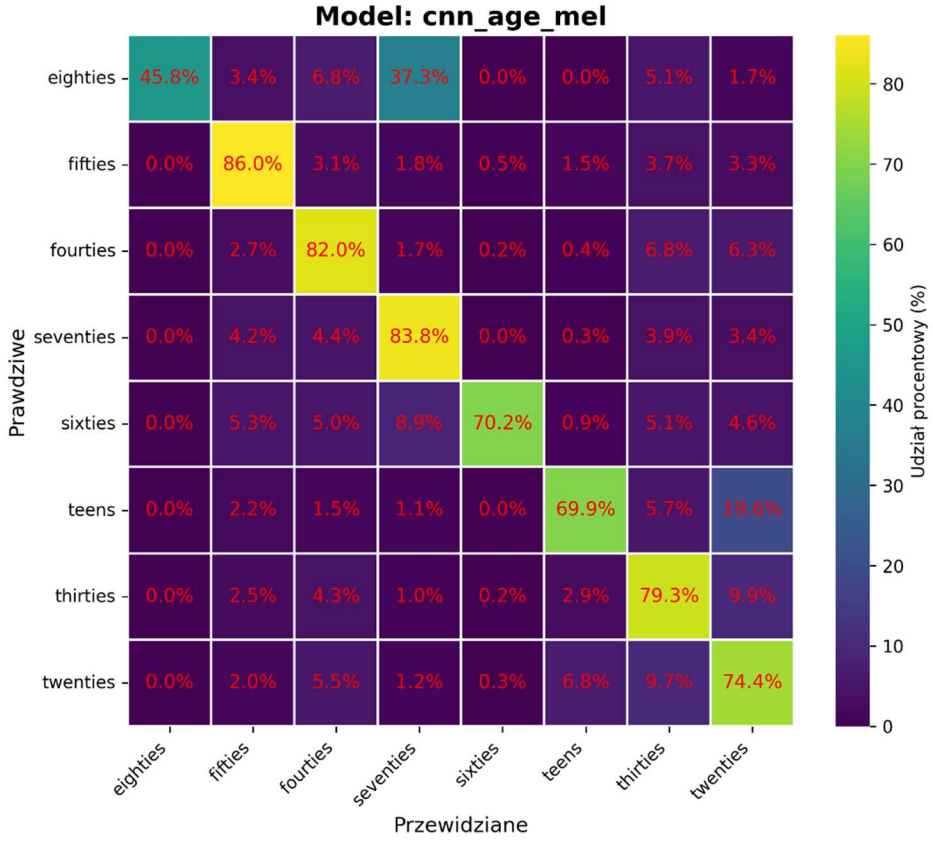
Analizę wyników dla poszczególnych grup wiekowych uzupełniono o znormalizowane macierze pomyłek (rys. 6.11-6.16). Przedstawiają one rozkład poprawnych i błędnych klasyfikacji uzyskanych przez poszczególne modele.



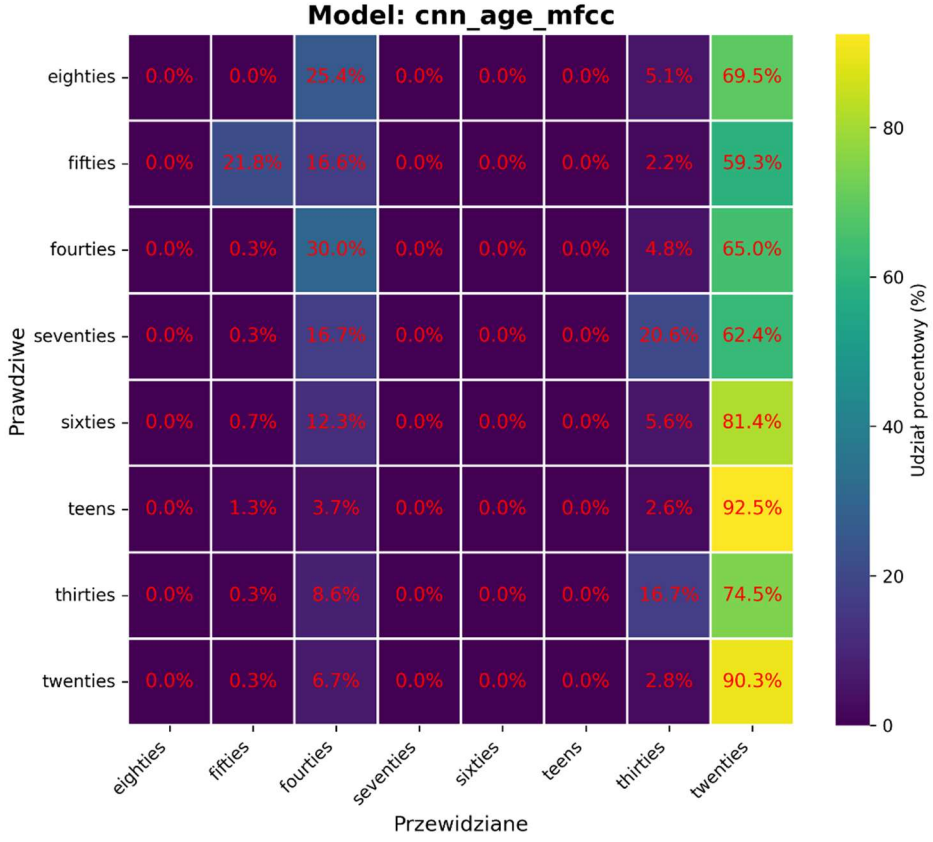

Rysunek 6.11. Znormalizowana macierz pomyłek dla modelu MLP/Mel rozpoznającego wiek mówcy



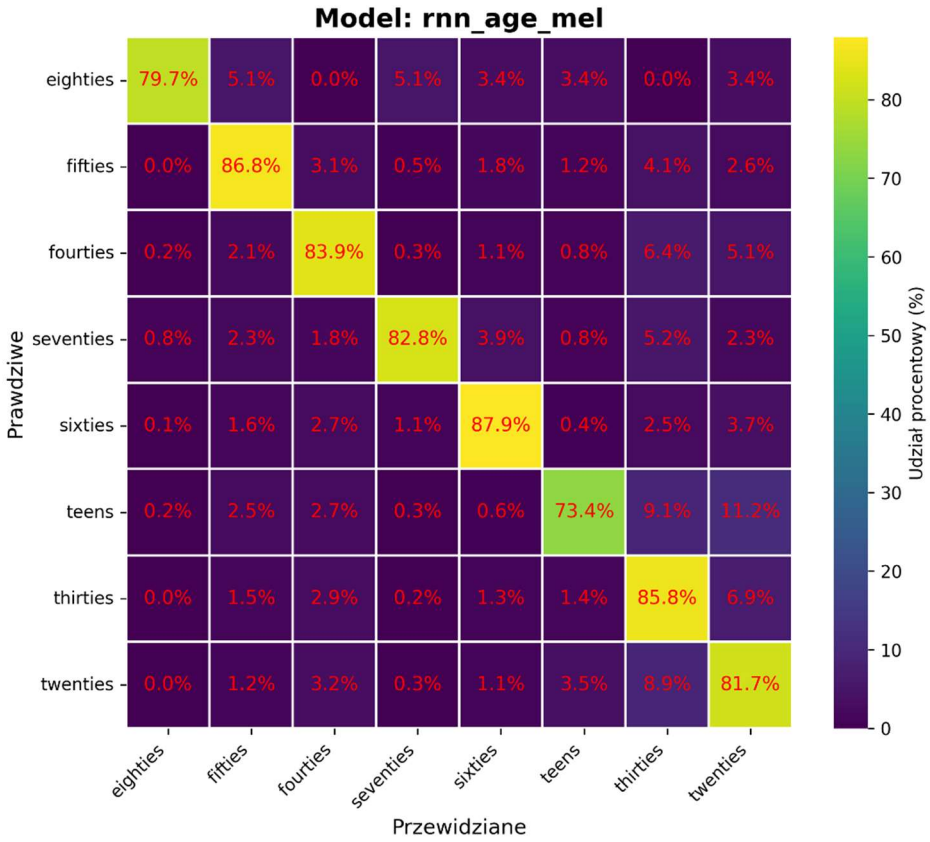

Rysunek 6.12. Znormalizowana macierz pomyłek dla modelu MLP/MFCC rozpoznającego wiek mówcy



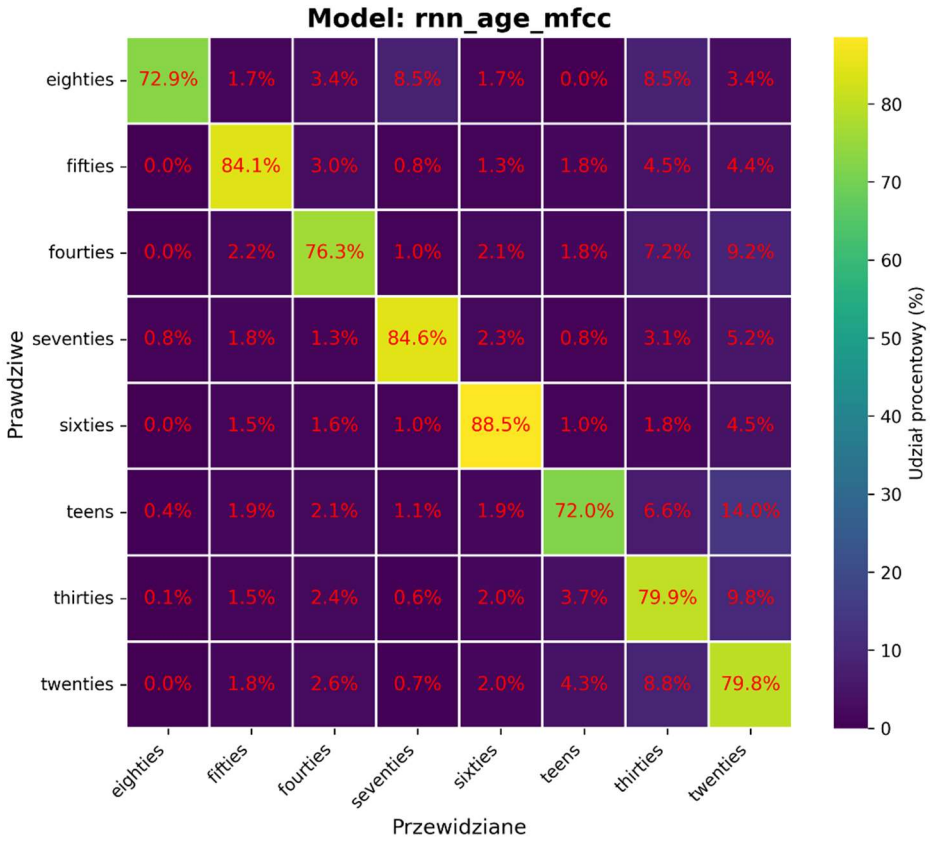

Rysunek 6.13. Znormalizowana macierz pomyłek dla modelu CNN/Mel rozpoznającego wiek mówcy




Rysunek 6.14. Znormalizowana macierz pomyłek dla modelu CNN/MFCC rozpoznającego wiek mówcy




Rysunek 6.15. Znormalizowana macierz pomyłek dla modelu Bi-LSTM/Mel rozpoznającego wiek mówcy

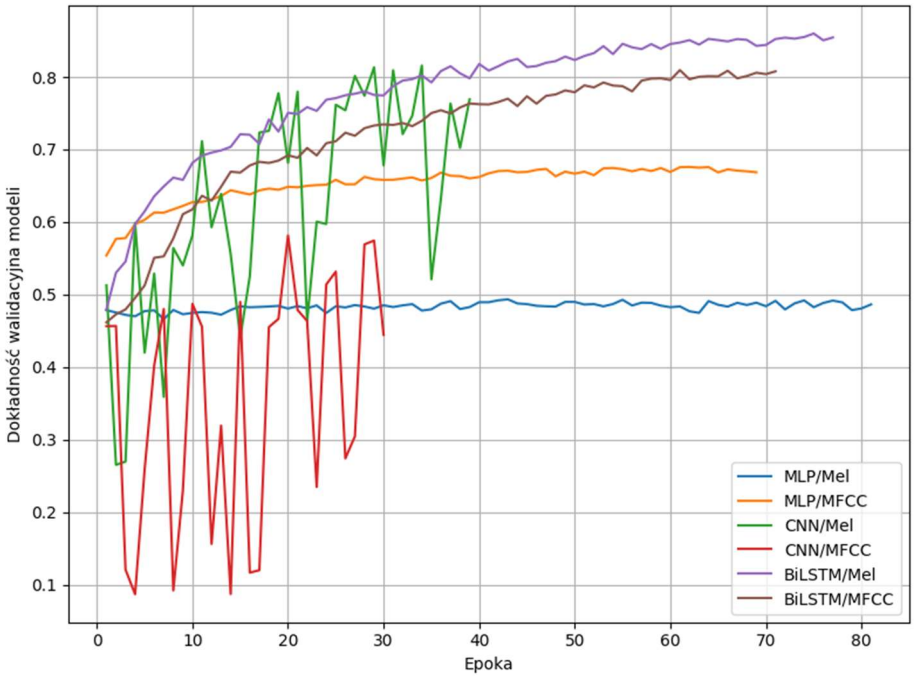



Rysunek 6.16. Znormalizowana macierz pomyłek dla modelu Bi-LSTM/MFCC rozpoznającego wiek mówcy

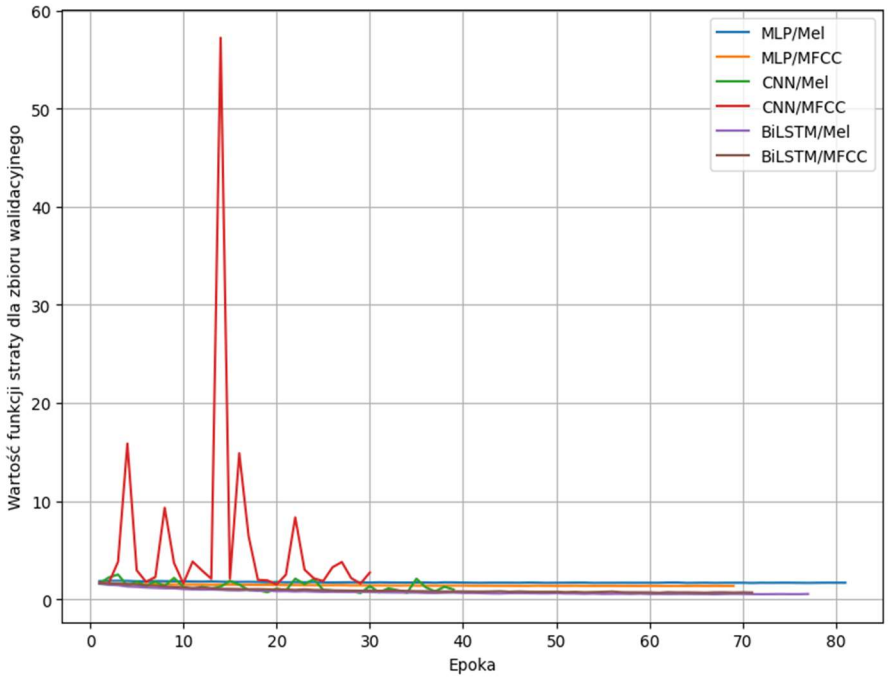
Analiza macierzy pomyłek dla modelu MLP bazującego na reprezentacji Mel oraz modelu CNN wykorzystującego współczynniki MFCC pokazuje, że w obu przypadkach większość obserwacji została przypisana do klasy większościowej twenties (dwudziestolatków). W przypadku pozostałych modeli widoczna jest wyraźna przekątna macierzy, wskazująca na poprawne klasyfikacje. Dla drugiego modelu MLP można zaobserwować poprawne przypisania, jednak występuje w nim znaczna liczba błędów związanych z przypisywaniem obserwacji do klas dwudziestolatków i trzydziestolatków. Drugi model CNN charakteryzował się mniejszą liczbą błędnych klasyfikacji, najczęstszym błędem było przypisywanie obserwacji należących do grupy wiekowej 80-89 lat do klasy 70-79 latków. Najlepsze wyniki uzyskano dla modeli Bi-LSTM, dla których odsetek poprawnie sklasyfikowanych obserwacji w poszczególnych klasach wynosił między 72–88%.

### 6.4. Wyniki rozpoznawania akcentu mówcy

Ostatnim analizowanym zadaniem było rozpoznawanie akcentu mówcy. Przebieg procesu uczenia badanych modeli przedstawiono na rysunkach 6.17-6.18, na których zaprezentowano zmiany wartości dokładność klasyfikacji oraz wartość funkcji straty uzyskiwanych przez modele na zbiorze walidacyjnym podczas kolejnych epok.




Rysunek 6.17. Przebieg dokładności klasyfikacji na zbiorze walidacyjnym dla modeli rozpoznających akcent mówcy




Rysunek 6.18. Przebieg wartości funkcji straty na zbiorze walidacyjnym dla modeli rozpoznających akcent mówcy

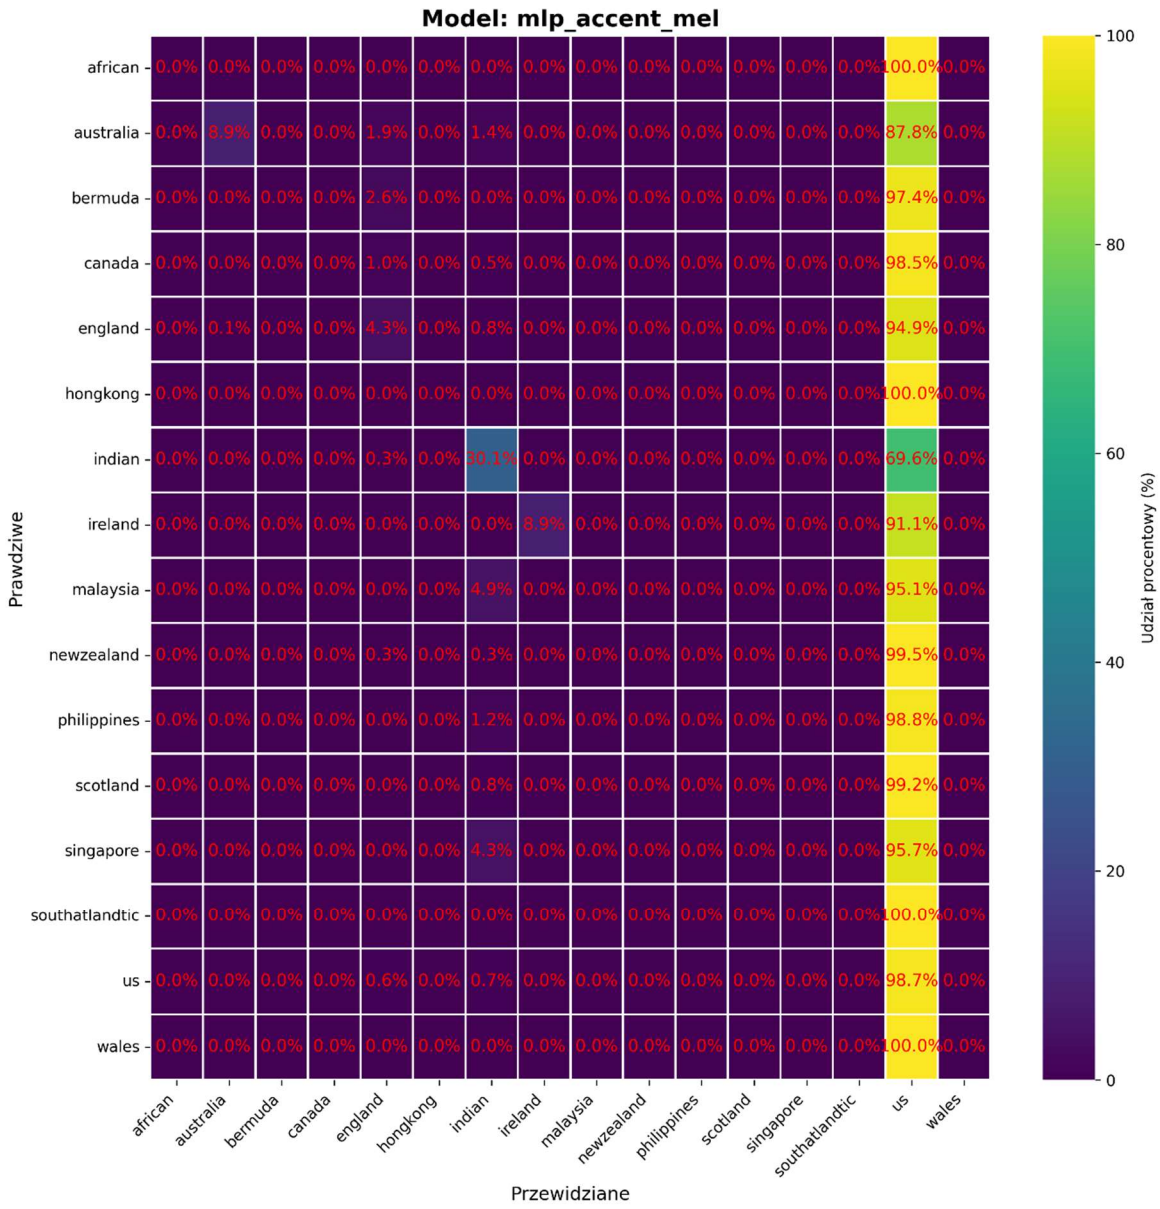
Analizując przebieg procesu uczenia, można zauważyć, że modele MLP oraz Bi-LSTM charakteryzowały się stabilnym przebiegiem zarówno dokładności walidacyjnej, jak i wartości funkcji straty. W przypadku modeli CNN, podobnie jak w poprzednich eksperymentach, zaobserwowano większe wahania wartości uzyskiwanych na zbiorze walidacyjnym w kolejnych epokach. Szczególnie widoczne było to dla modelu bazującym na współczynnikach MFCC, dla którego dokładność walidacyjna zmieniała się w szerokim zakresie, od około 0,1 do 0,6.

Dla każdego z badanych modeli wyznaczono wartości miar klasyfikacyjnych na podstawie wyników uzyskanych na zbiorze testowym. Podobnie jak w przypadku klasyfikacji wieku mówcy, w celu dokładniejszej oceny wyników zastosowano uśrednienie makro oraz średnią ważoną dla poszczególnych metryk. Zestawienie uzyskanych wartości przedstawiono w tabeli 6.3, co pozwala na bezpośrednie porównanie modeli wykorzystujących różne reprezentacje danych wejściowych.

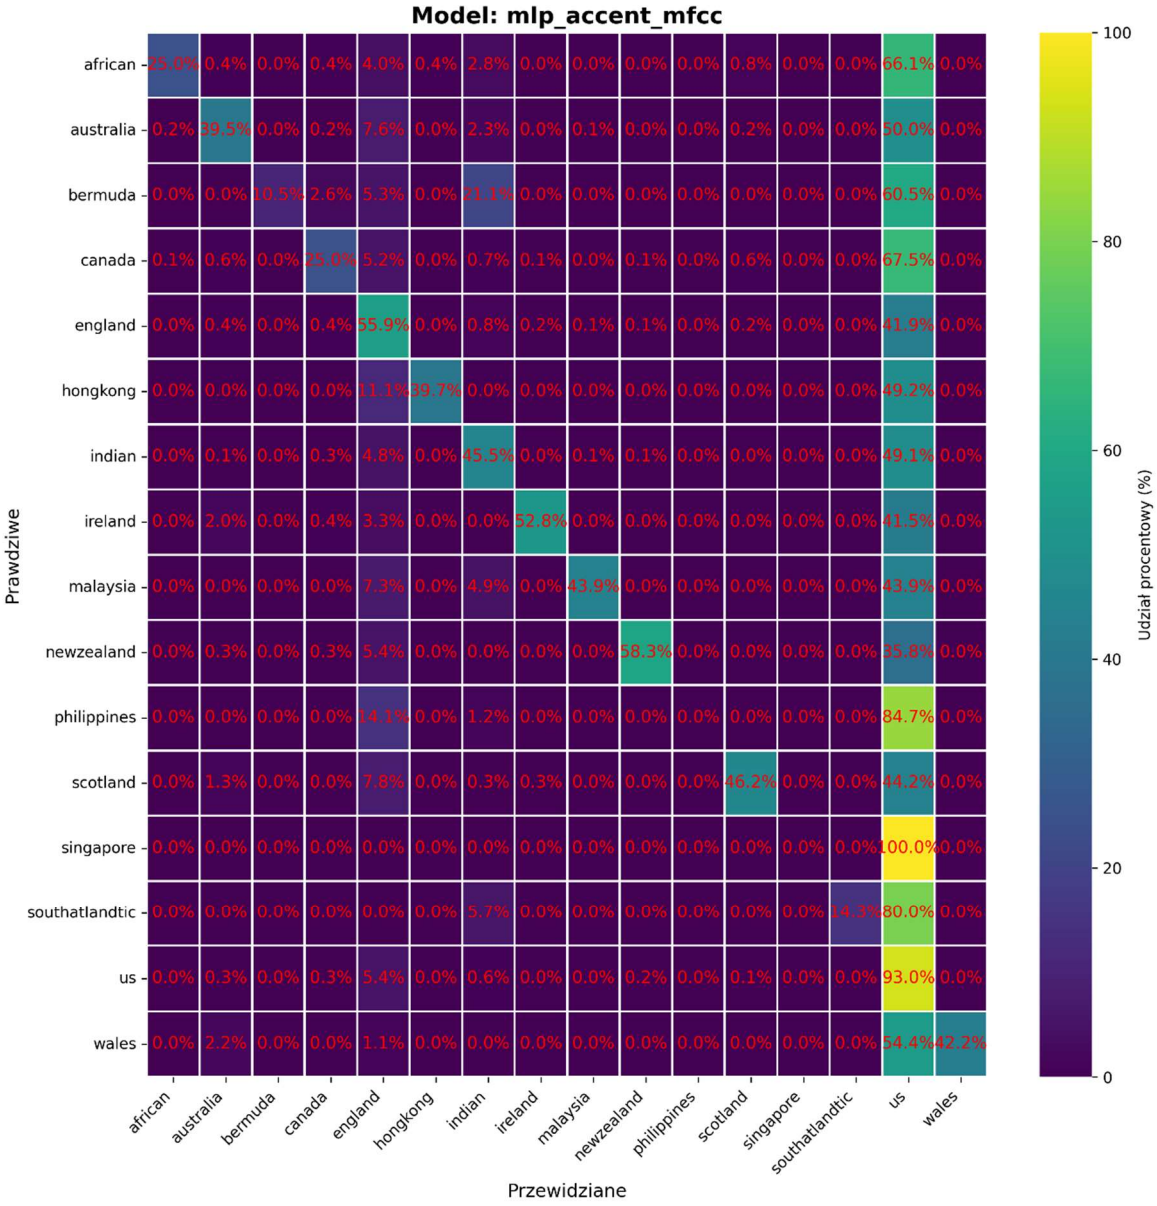
Tabela 6.3. Miary jakości klasyfikacji akcentu mówców dla badanych modeli

| | **Poszczególne modele** | | | | | |
|---|---|---|---|---|---|---|
| **Metryki** | **MLP Mel** | **MLP MFCC** | **CNN Mel** | **CNN MFCC** | **Bi-LSTM Mel** | **Bi-LSTM MFCC** |
| Dokładność | 0.49 | 0.68 | 0.81 | 0.58 | 0.85 | 0.81 |
| Precyzja (średnia makro) | 0.24 | 0.76 | 0.79 | 0.26 | 0.77 | 0.72 |
| Precyzja (średnia ważona) | 0.52 | 0.72 | 0.83 | 0.54 | 0.86 | 0.81 |
| Czułość (średnia makro) | 0.09 | 0.37 | 0.51 | 0.14 | 0.70 | 0.56 |
| Czułość (średnia ważona) | 0.49 | 0.68 | 0.81 | 0.58 | 0.85 | 0.81 |
| Wskaźnik F1 (średnia makro) | 0.09 | 0.46 | 0.58 | 0.13 | 0.71 | 0.62 |
| Wskaźnik F1 (średnia ważona) | 0.36 | 0.65 | 0.80 | 0.51 | 0.85 | 0.80 |

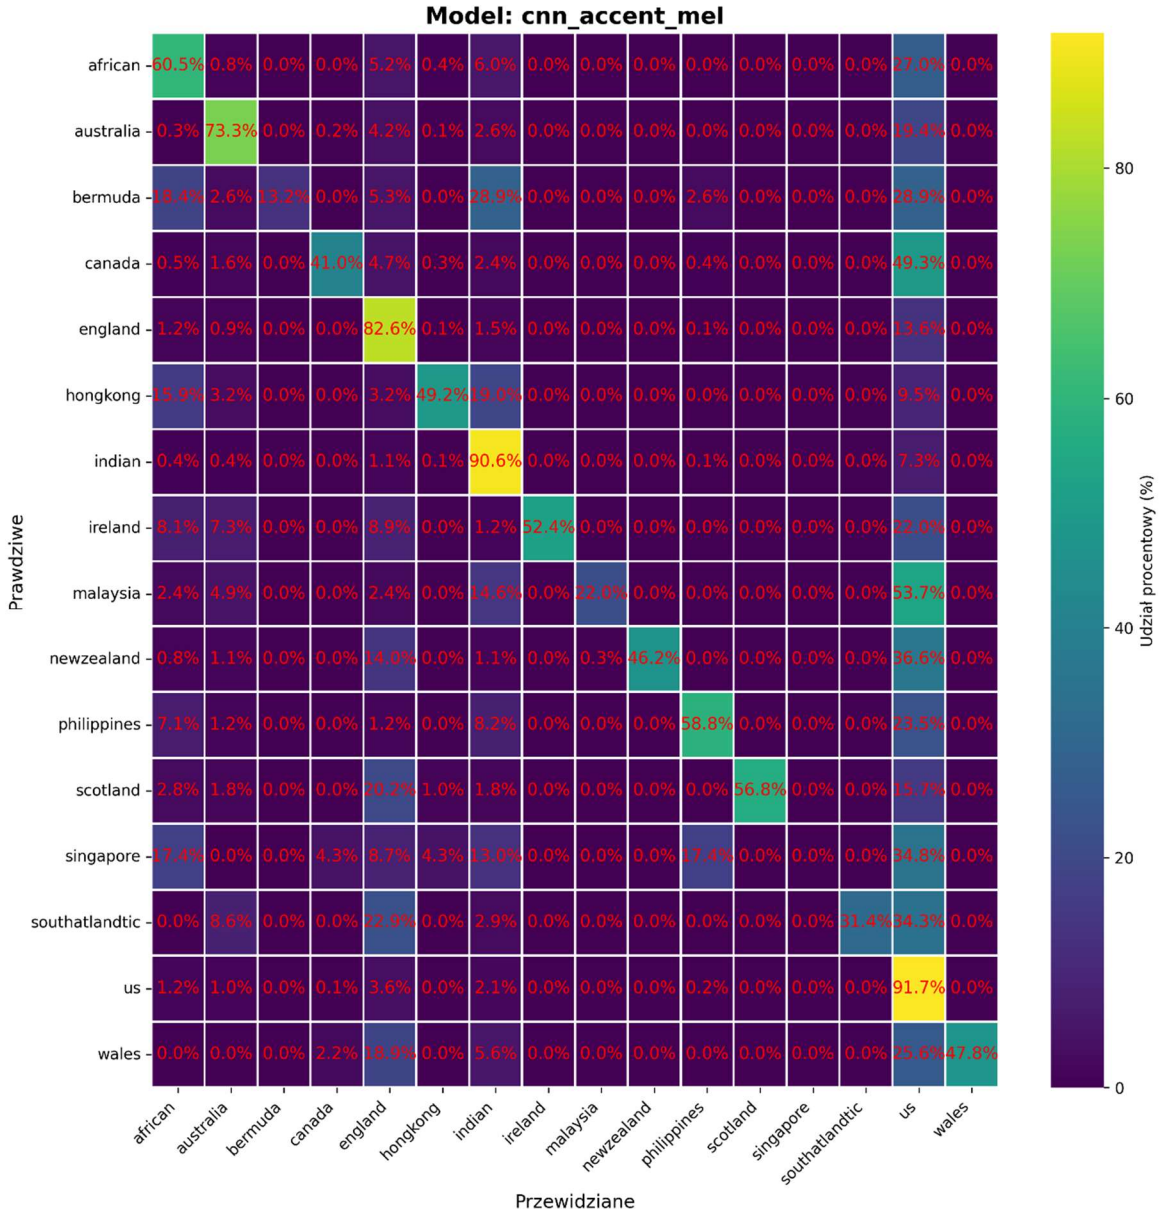
Dodatkowo wyniki klasyfikacji uzupełniono o macierze pomyłek (rys. 6.19-6.24), przedstawiające rozkład poprawnych i błędnych klasyfikacji pomiędzy poszczególnymi klasami akcentu. Ich analiza pozwala określić, które akcenty były rozpoznawane przez modele najskuteczniej oraz pomiędzy którymi klasami występowały najczęstsze pomyłki.



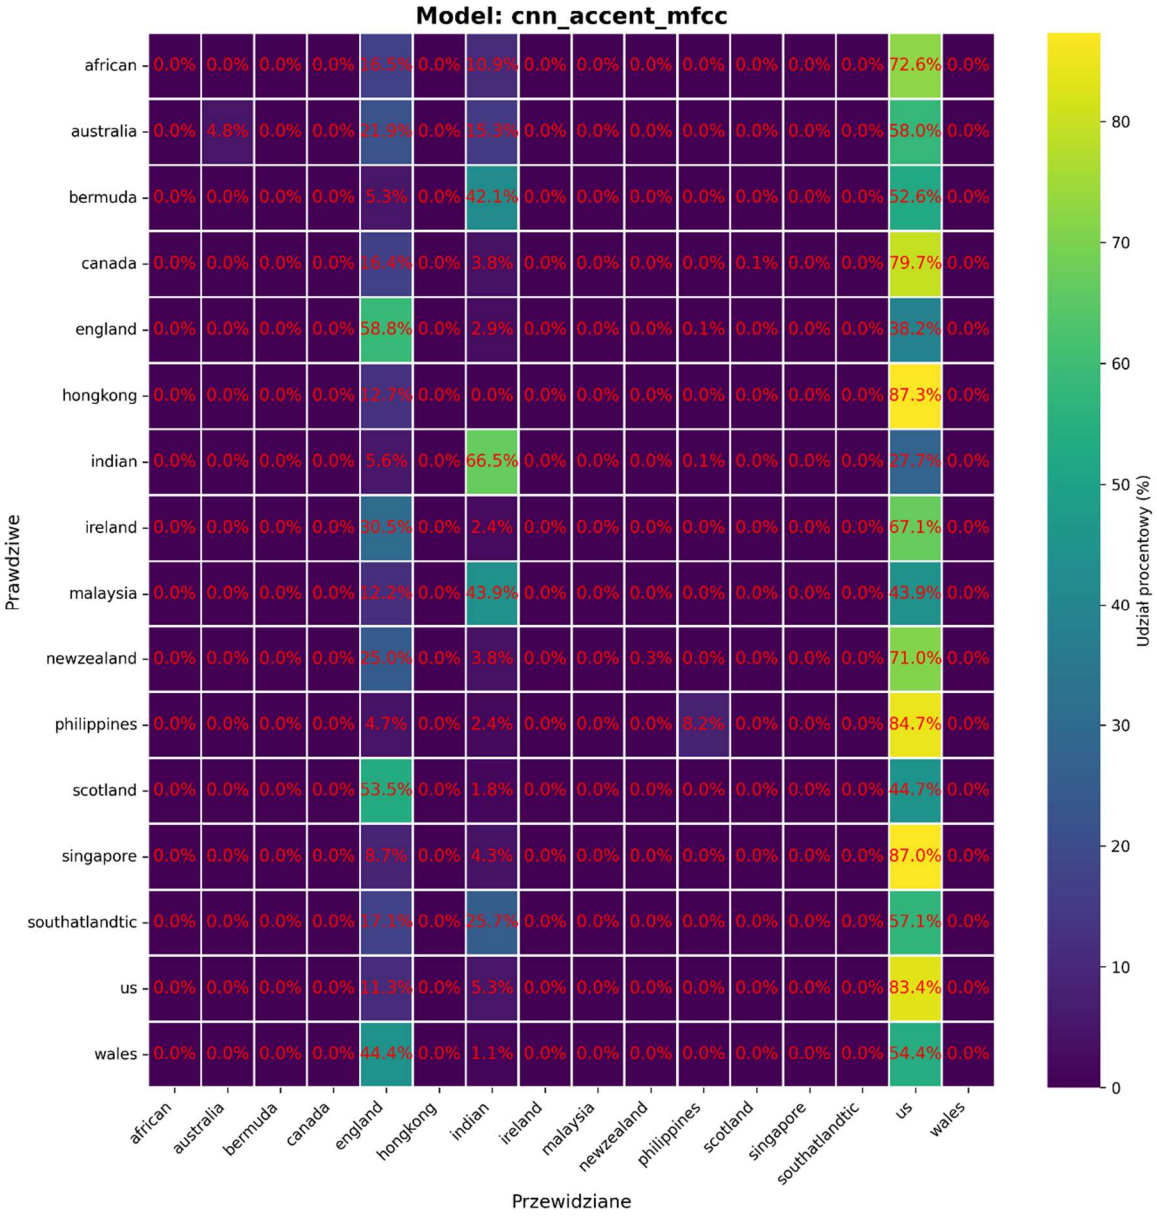

Rysunek 6.19. Znormalizowana macierz pomyłek dla modelu MLP/Mel rozpoznającego akcent mówcy



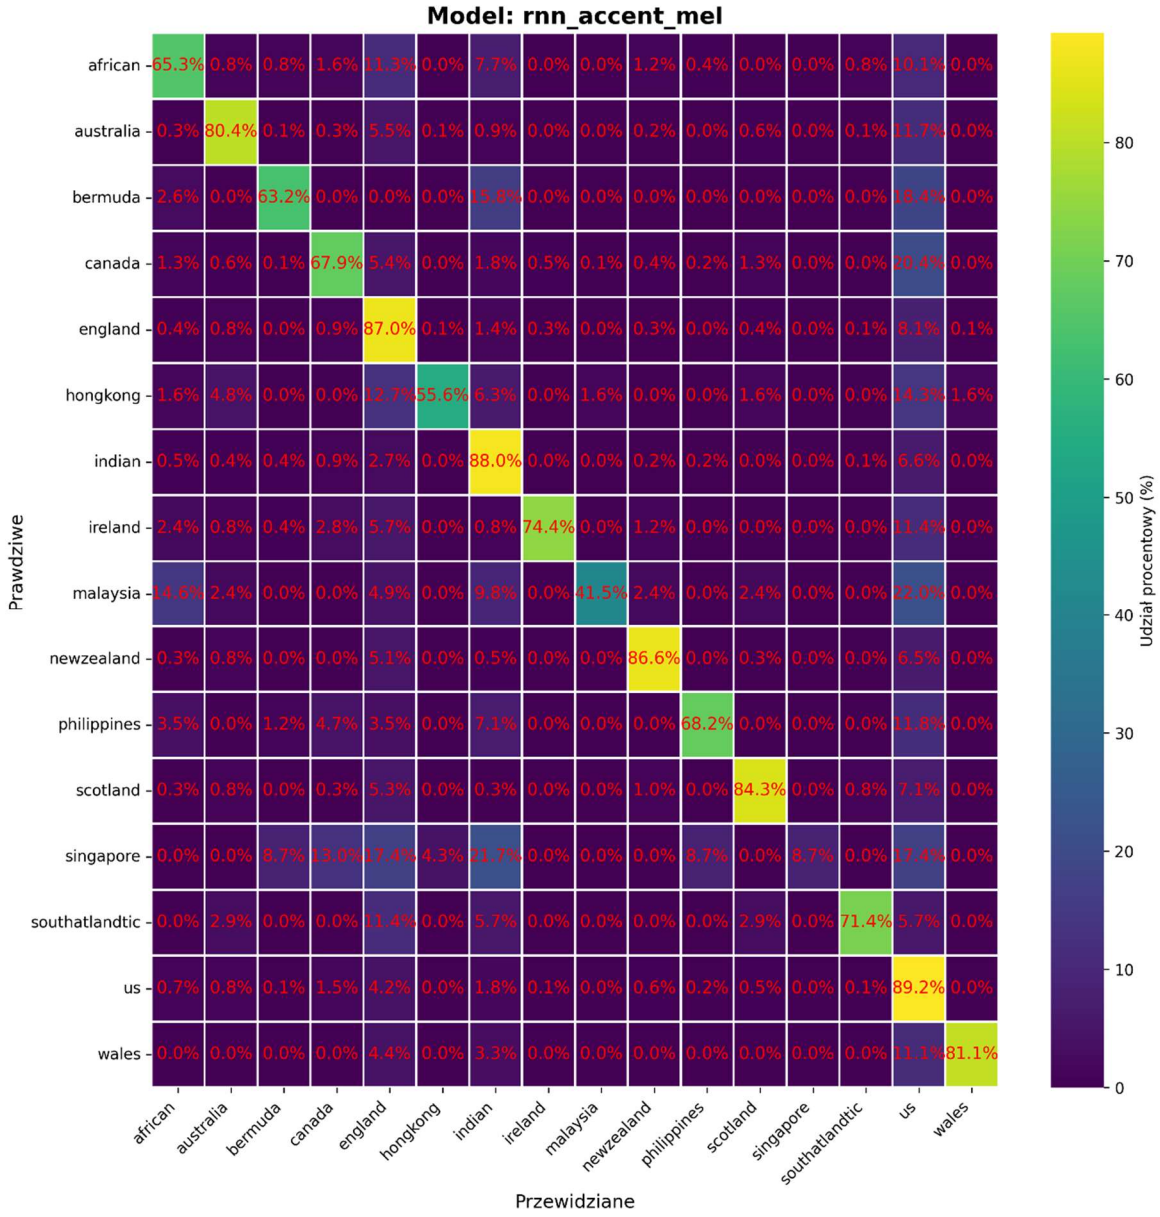

Rysunek 6.20. Znormalizowana macierz pomyłek dla modelu MLP/MFCC rozpoznającego akcent mówcy



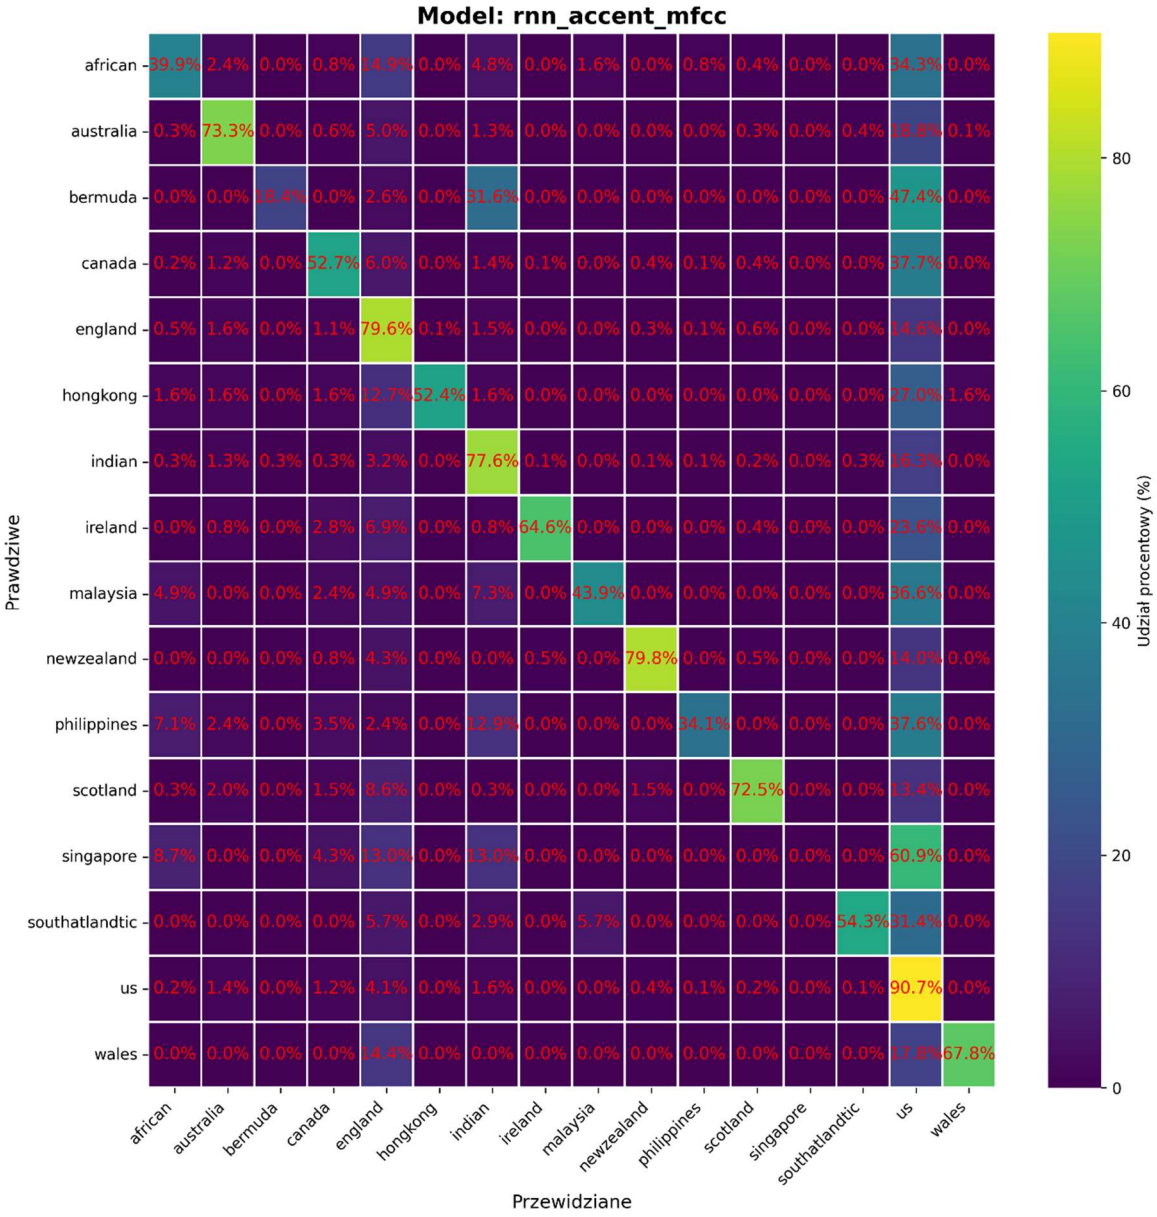

Rysunek 6.21. Znormalizowana macierz pomyłek dla modelu CNN/Mel rozpoznającego akcent mówcy




Rysunek 6.22. Znormalizowana macierz pomyłek dla modelu CNN/MFCC rozpoznającego akcent mówcy




Rysunek 6.23. Znormalizowana macierz pomyłek dla modelu Bi-LSTM/Mel rozpoznającego akcent mówcy




Rysunek 6.24. Znormalizowana macierz pomyłek dla modelu Bi-LSTM/MFCC rozpoznającego akcent mówcy

Analiza macierzy pomyłek modeli MLP pokazuje, że większość obserwacji była przypisywana do klasy większościowej, odpowiadającej akcentowi amerykańskiemu. Jedynie dla modelu MLP opartym na reprezentacji MFCC uzyskano nieco lepsze wyniki, szczególnie dla akcentu brytyjskiego, irlandzkiego oraz nowozelandzkiego, dla których odsetek poprawnie sklasyfikowanych obserwacji przekroczył 50%. W przypadku modeli CNN również widoczna była tendencja do przypisywania znacznej części obserwacji do klas odpowiadających akcentowi amerykańskiemu i brytyjskiemu. Model CNN bazujący na danych w skali Mel, wykazał jednak zdolność do rozpoznawania wzorców charakterystycznych również dla niektórych pozostałych akcentów, co przełożyło się na

bardziej zróżnicowany rozkład poprawnych klasyfikacji pomiędzy klasami. Najlepsze rezultaty pod względem rozpoznawania poszczególnych akcentów uzyskano dla modelu Bi-LSTM z reprezentacją Mel. Macierz pomyłek wskazuje, że model ten był w stanie rozpoznawać wzorce związane z większością analizowanych akcentów, a poprawne klasyfikacje występowały dla znacznej części klas. Drugi model Bi-LSTM uzyskał słabsze wyniki, a w jego przypadku również widoczna była tendencja do przypisywania części obserwacji do klas o większej liczebności.

### 6.5. Porównanie uzyskanych wyników

Ze względu na znaczne niezrównoważenie klas w analizowanym zbiorze danych, jako główną miarę porównawczą dla reprezentacji akustycznych Mel i MFCC w zadaniach klasyfikacji wieloklasowej przyjęto uśrednienie makroskopowe metryki czułości. Wartość ta jest obliczana jako średnia czułość uzyskana dla wszystkich klas, przy czym każda z nich ma taki sam udział w wyniku końcowym. Pozwala to na zrównoważoną ocenę zdolności modeli do prawidłowego rozpoznawania próbek należących do poszczególnych klas, niezależnie od ich liczebności. W przypadku klasyfikacji binarnej nie stosowano makro uśrednienia, ponieważ rozpatrywane są jedynie dwie klasy, a wyniki przedstawiono bezpośrednio za pomocą wartości czułości.

Porównanie wartości miar opartych na czułości dla reprezentacji Mel i MFCC przedstawiono w tabeli 6.4. Uzyskane wyniki wskazują na występowanie różnic pomiędzy obiema reprezentacjami, których wielkość zależy od zastosowanej architektury sieci neuronowej i od rozpoznawanej cechy mówcy.

Tabela 6.4. Porównanie makro uśrednionej wartości miary czułości dla reprezentacji Mel i MFCC

| Model | Mel | MFCC | Δ (różnica) |
|---|---|---|---|
| MLP/Gender | 0.959 | 0.950 | +0.009 |
| CNN/Gender | 0.987 | 0.945 | +0.042 |
| Bi-LSTM/Gender | 0.990 | 0.976 | +0.014 |
| MLP/Age | 0.18 | 0.55 | -0.37 |
| CNN/Age | 0.74 | 0.20 | +0.54 |
| Bi-LSTM/Age | 0.83 | 0.80 | +0.03 |
| MLP/Accent | 0.09 | 0.37 | -0.28 |
| CNN/Accent | 0.51 | 0.14 | +0.37 |
| Bi-LSTM/Accent | 0.70 | 0.56 | +0.14 |

Uzyskane wyniki wskazują, że skuteczność zastosowanej reprezentacji akustycznej jest w dużym stopniu zależna zarówno od architektury sieci neuronowej, jak i od rodzaju rozpoznawanej cechy mówcy. Nie zaobserwowano jednej reprezentacji, która zapewniłaby

najlepsze wyniki klasyfikacji we wszystkich analizowanych warunkach eksperymentalnych. Szczególnie wyraźne różnice można zauważyć w zachowaniu modeli MLP i CNN, podczas gdy modele Bi-LSTM charakteryzowały się bardziej stabilnymi wynikami przy zastosowaniu obu analizowanych reprezentacji.

W zadaniu rozpoznawania płci zarówno reprezentacja Mel, jak i współczynniki MFCC zapewniły stosunkowo wysoką skuteczność modeli CNN i Bi-LSTM. Najlepsze wyniki uzyskano dla modelu Bi-LSTM wykorzystującego reprezentację Mel, dla którego dokładność wyniosła 0,983, a czułość 0,990. Model CNN z wykorzystaniem tej samej reprezentacji osiągnął porównywalną dokładność na poziomie 0,983 oraz czułość wynoszącą 0,987. W przypadku modeli MLP uzyskano niższe wyniki, przy czym dokładność wyniosła odpowiednio 0,923 dla reprezentacji Mel oraz 0,918 dla współczynników MFCC. Stosunkowo niewielkie różnice pomiędzy wynikami uzyskanymi dla obu reprezentacji mogą wynikać z faktu, że rozpoznawanie płci na podstawie informacji akustycznych jest zadaniem relatywnie łatwym, a cechy związane z płcią mówcy są wyraźnie obecne w sygnale mowy. W rezultacie skuteczność klasyfikacji może być w mniejszym stopniu zależna od zastosowanego sposobu reprezentacji danych wejściowych.

W zadaniu rozpoznawania wieku zaobserwowano znacznie większe różnice pomiędzy obiema reprezentacjami akustycznymi. Model MLP osiągnął dokładność na poziomie 0,36 dla reprezentacji Mel oraz 0,63 dla współczynników MFCC. Odwrotną zależność zaobserwowano w przypadku modelu CNN, dla którego dokładność wyniosła 0,78 przy zastosowaniu reprezentacji Mel, natomiast dla MFCC spadła do 0,38. Modele Bi-LSTM wykazały znacznie mniejsze różnice, osiągając dokładność odpowiednio 0,84 i 0,80 dla reprezentacji Mel i MFCC. Podobną zależność zaobserwowano w przypadku makro uśrednionej czułości. Dla modelu MLP uzyskano wartości 0,18 i 0,55, dla modelu CNN 0,74 i 0,20, natomiast dla modelu Bi-LSTM 0,83 i 0,80, odpowiednio dla reprezentacji Mel i MFCC. Wyniki te wskazują, że wybór reprezentacji akustycznej ma szczególnie istotny wpływ na skuteczność rozpoznawania wieku, a jego znaczenie jest ściśle związane z zastosowaną architekturą sieci neuronowej. Przeciwne zależności obserwowane dla modeli MLP i CNN sugerują, że obie architektury wykorzystują różne właściwości analizowanych reprezentacji akustycznych podczas rozróżniania grup wiekowych. Model Bi-LSTM wykazuje natomiast znacznie mniejszą wrażliwość na wybór reprezentacji, uzyskując zbliżone wyniki dla Mel i MFCC.

Podobną, lecz jeszcze wyraźniejszą zależność od zastosowanej reprezentacji akustycznej zaobserwowano w zadaniu rozpoznawania akcentu języka angielskiego. Model MLP osiągnął dokładność na poziomie 0,49 dla reprezentacji Mel oraz 0,68 dla współczynników MFCC, podczas gdy dla modelu CNN uzyskano odpowiednio 0,81 i 0,58. Modele Bi-LSTM ponownie wykazały znacznie mniejsze różnice pomiędzy obiema reprezentacjami, osiągając dokładność 0,85 dla reprezentacji Mel oraz 0,81 dla współczynników MFCC. Różnice pomiędzy reprezentacjami są również widoczne w przypadku uśrednienia makroskopowego wartości czułości. Dla modelu MLP jej wartość wzrosła z 0,09 do 0,37 po zastosowaniu współczynników MFCC, natomiast dla modelu CNN wzrosła z 0,14 do 0,51 przy zastosowaniu reprezentacji Mel. Model Bi-LSTM uzyskał wartości makro uśrednionej czułości wynoszące odpowiednio 0,70 i 0,56 dla reprezentacji Mel i MFCC.

Wyniki te potwierdzają, że wybór reprezentacji akustycznej ma istotne znaczenie dla skuteczności klasyfikacji, a jej wpływ jest silnie związany z zastosowaną architekturą sieci neuronowej. Znacznie niższe wartości średniej makro czułości w porównaniu z miarami uśrednionymi z uwzględnieniem liczebności klas wskazują również na istotny wpływ niezrównoważenia zbioru danych. Zależność ta jest szczególnie widoczna w zadaniu rozpoznawania akcentu, w którym niektóre klasy zawierały znacznie mniej próbek niż pozostałe.

# 7. Wnioski

Podsumowując uzyskane wyniki, można stwierdzić, że modele Bi-LSTM mogą być szczególnie dobrze przystosowane do bardziej złożonych, wieloklasowych zadań rozpoznawania cech mówcy przy zastosowaniu reprezentacji w postaci spektrogramów Mel. Zarówno w przypadku rozpoznawania wieku, jak i akcentu języka angielskiego modele Bi-LSTM uzyskały najwyższe wartości makro uśrednionej czułości spośród analizowanych architektur. Jednocześnie wykazały stosunkowo niewielkie różnice w wynikach uzyskiwanych dla reprezentacji Mel i współczynników MFCC.

W przeciwieństwie do modeli Bi-LSTM, modele CNN wykazywały znacznie większą zależność od zastosowanej reprezentacji akustycznej. Wykorzystanie współczynników MFCC jako danych wejściowych wiązało się w ich przypadku z wyraźnym pogorszeniem wyników. Jednym z możliwych wyjaśnień tego zjawiska jest sposób przedstawienia współczynników MFCC w postaci obrazów dwuwymiarowych. Chociaż taka forma reprezentacji umożliwia ich przetwarzanie za pomocą warstw splotowych, organizacja przestrzenna współczynników MFCC różni się od struktury typowych danych obrazowych. Może to powodować, że sieci CNN nie wykorzystują w pełni informacji zawartych w tej reprezentacji, co może przekładać się na niższą skuteczność klasyfikacji. Powyższe wyjaśnienie należy jednak traktować jako hipotezę, która wymaga dalszej weryfikacji. Uzyskane wyniki wskazują, że skuteczność poszczególnych architektur może być zależna nie tylko od rodzaju rozpoznawanej cechy mówcy, ale również od sposobu reprezentacji sygnału wejściowego.

Uzyskane wyniki pozwalają również lepiej odnieść się do obserwacji przedstawionej przez Costantiniego i in. [5], którzy uzyskali niższą skuteczność dla reprezentacji opartych na współczynnikach MFCC niż dla reprezentacji w postaci spektrogramów w zadaniu rozpoznawania mówcy z wykorzystaniem sieci CNN. Podobną zależność zaobserwowano w niniejszej pracy, ponieważ modele CNN we wszystkich trzech analizowanych zadaniach osiągały lepsze wyniki przy zastosowaniu spektrogramów Mel niż współczynników MFCC. Odmienną zależność zaobserwowano w przypadku modeli MLP w zadaniach rozpoznawania wieku i akcentu, dla których lepsze wyniki uzyskano przy zastosowaniu współczynników MFCC. Modele Bi-LSTM wykazywały natomiast mniejsze różnice pomiędzy obiema reprezentacjami, przy czym we wszystkich analizowanych zadaniach uzyskiwały lepsze wyniki dla spektrogramów Mel. Wyniki te sugerują, że zależność zaobserwowana przez Costantiniego i in. [5] może być związana nie tylko z samym sposobem reprezentacji sygnału akustycznego, ale również z architekturą sieci neuronowej

wykorzystywanej do jego przetwarzania. Z tego względu większy stopień dyskretyzacji reprezentacji MFCC nie musi w pełni wyjaśniać różnic zaobserwowanych pomiędzy obiema reprezentacjami. Na uzyskane wyniki może wpływać również różnica pomiędzy zadaniem rozpoznawania mówcy analizowanym w pracy [5], a zadaniami rozpoznawania cech mówcy rozpatrywanymi w niniejszej pracy.

Jednym z ograniczeń niniejszej pracy jest fakt, iż podział zbioru danych nie odbył się na poziomie mówcy, co oznacza, że nie można wykluczyć sytuacji, w której różne nagrania dźwiękowe tego samego mówcy mogły trafić do więcej niż jednego zbioru. To podejście może skutkować przeciekiem informacji ze zbioru testowego do treningowego lub walidacyjnego, gdyż ten sam głos może mieć bardzo zbliżone parametry zawarte w spektrogramie w skali Mel lub współczynnikach MFCC. Zatem nie jest wykluczone, że model głębokiego uczenia może uczyć się klasyfikacji nagrań dźwiękowych poprzez staranie się zapamiętania poszczególnych parametrów związanych z konkretnym głosem. Innym ograniczeniem jest wykonanie podziału zbioru danych na treningowy, testowy i walidacyjny tylko jednokrotnie. Poszczególne obserwacje zawarte w zbiorze danych trafiają zatem do jednego z trzech tych zbiorów, a modele głębokiego uczenia nie są trenowane i ewaluowane na innym podziale tych obserwacji. Ograniczenie to można wyeliminować poprzez przeprowadzenie tych badań przy użyciu techniki k-krotnej walidacji krzyżowej oraz agregacji wyników klasyfikacji.

## Wykaz literatury


[1] Ayranci, A. A., Atay, S., Yıldırım, T. (2021). Speaker Accent Recognition Using MFCC Feature Extraction and Machine Learning Algorithms. *International Journal of Advances in Engineering and Pure Sciences*, 33, 17-27. https://doi.org/10.7240/jeps.896427

[2] Alnuaim, A. A., Zakariah, M., Shashidhar, C., Hatamleh, W. A., Tarazi, H., Shukla, P. K., Ratna, R. (2022). Speaker Gender Recognition Based on Deep Neural Networks and ResNet50. *Wireless Communications and Mobile Computing*, article 4444388. https://doi.org/10.1155/2022/4444388

[3] Angadi, D., Manoj, K. R., Nagendra, N. S., Nithin Kumar, B. (2021). Voice based age, accent and gender recognition. *International Journal of Innovative Research in Technology, 8*(2), 841–845. https://ijirt.org/article?manuscript=152296

[4] Basak, S., Agrawal, H., Jena, S., Gite, S., Bachute, M., Pradhan, B., Assiri, M. (2023). Challenges and Limitations in Speech Recognition Technology: A Critical Review of Speech Signal Processing Algorithms, *Tools and Systems. Computer Modeling in Engineering & Sciences*, 135(2), 1053–1089. https://doi.org/10.32604/cmes.2022.021755

[5] Costantini, G., Cesarini, V., Brenna, E. (2023). High-Level CNN and Machine Learning Methods for Speaker Recognition. *Sensors*, 23(7):3461. https://doi.org/10.3390/s23073461

[6] Dave, N. (2013). Feature extraction methods LPC, PLP and MFCC in speech recognition. *International journal for advance research in engineering and technology*, 1(6), 1-4.

[7] Faisal, M. R., Hidayat, M. T., Kartini, D., Indriani, F., Budiman, I., Saragih, T. H. (2023). Comparison of Machine Learning Algorithms on Classification of Covid-19 Cough Sounds Using MFCC Extraction. *Journal of Computer Sciences Institute*, 29, 399–404. https://doi.org/10.35784/jcsi.4447

[8] Garg, A., Aribi, Y., Althobaiti, T., Bhowmik, T. (2025). An analysis of acoustic features for accented speech classification. *Egyptian Informatics Journal*, Volume 31, 100743. https://doi.org/10.1016/j.eij.2025.100743

[9] Ghosh, K., Basak, A., Sagnik Bhattacherjee, S., Mohanta, P. P., Saiyed, U. S. (2025). Multilingual and gender classification of speech using acoustic and deep learning methods. *Procedia Computer Science*, Volume 269, 1584-1593. https://doi.org/10.1016/j.procs.2025.09.100

[10] Karimi Jafarbigloo, S., Danyali, H. (2021). Nuclear atypia grading in breast cancer histopathological images based on CNN feature extraction and LSTM classification. *CAAI Trans. Intell. Technol. 6*(4), 426–439. https://doi.org/10.1049/cit2.12061

[11] Ke, K.-C., Huang, M. S. (2020). Quality Prediction for Injection Molding by Using a Multilayer Perceptron Neural Network. *Polymers*, *12*(8), 1812. https://doi.org/10.3390/polym12081812

[12] Koli, R. N. (2021). Classification of Speaker's Age, Gender and Nationality using Transfer Learning. *School of Computing National College of Ireland*, https://norma.ncirl.ie/id/eprint/5177

[13] Krichen, M. (2023). Convolutional Neural Networks: A Survey. *Computers*, *12*(8), 151. https://doi.org/10.3390/computers12080151

[14] Mavaddati, S. (2024). Voice-based age, gender, and language recognition based on ResNet deep model and transfer learning in spectro-temporal domain. *Neurocomputing*, Volume 580, 127429. https://doi.org/10.1016/j.neucom.2024.127429

[15] McLoughlin, I., Pham, L., Song, Y., Miao, X., Phan, H., Cai, P., Gu, Q., Nan, J., Song, H., & Soh, D. (2026). Spectrogram Features for Audio and Speech Analysis. *Applied Sciences*, *16*(2), 572. https://doi.org/10.3390/app16020572

[16] O'Shaughnessy, D. (2023). Review of analysis methods for speech applications, *Speech Communication*, Volume 151, p. 64-75. https://doi.org/10.1016/j.specom.2023.05.008

[17] Shalbbya, A., Safdar, T., Syed, S. K., Naseem, R. (2021). Mel Frequency Cepstral Coefficient: A Review. *ICIDSSD EAI.* https://doi.org/10.4108/eai.27-2-2020.2303173

[18] Shiri, F.M., Perumal, T., Mustapha, N., Mohamed, R. (2024). A Comprehensive Overview and Comparative Analysis on Deep Learning Models. *Journal on Artificial Intelligence*, 6(1), 301–360. https://doi.org/10.32604/jai.2024.054314

[19] Sokolova, M., Lapalme, G. (2009). A systematic analysis of performance measures for classification tasks. *Information Processing & Management*, 45(4), p. 427-437. https://doi.org/10.1016/j.ipm.2009.03.002

## Zasoby internetowe

[20] Dokumentacja biblioteki Librosa w wersji 0.11.0: https://librosa.org/doc/0.11.0/tutorial.html, [16.09.2026].

[21] Dokumentacja biblioteki Scikit-learn w wersji 1.7.2: https://scikit-learn.org/stable/user_guide.html, [16.09.2026].

[22] Zbiór Mozilla Common Voice wykorzystany w badaniu: https://www.kaggle.com/datasets/mozillaorg/common-voice, [11.09.2026].

[23] Repozytorium zawierające kod źródłowy wykorzystany do przeprowadzenia badań: https://github.com/mogebycavailable/Bednarski-Brzozowski-ekstrakcja-cech-audio, [16.09.2026].